

推荐系统技术扩展介绍

议程

高度维数据

位置敏感的哈希

聚类

尺寸减小

图形数据

PageRank, SimRank

社区检测

垃圾邮件检测

无限数据

过滤数据流

网络广告

对流的查询

机器学习

声纳

决策树

感知器, kNN

附录

推荐系统

协会规则

重复文档检测

示例应用程序

amazon.com



Browse

Featured Holiday Links

Holiday Sales & Deals in Sports
Sports & Outdoors Gift Guide

2012 Editors' Picks

Featured Fitness Links

Clothing
Footwear
Fitness & Yoga DVDs
Items eligible for FREE Super Saver Shipping and Amazon Prime

Accessories

Exercise Balls
Bands
Jump Ropes
Mats
Stopwatches
> All Accessories

Cardio Training

Bike Trainers
Elliptical Trainers
Exercise Bikes
Rowers
Step Machines
Treadmills
> All Cardio Training

Exercise & Fitness

Find [treadmills](#), [elliptical trainers](#), [home gyms](#), [athletic apparel](#), [heart rate monitors](#), [yoga gear](#), and more.

Great Fitness Gifts

> Shop Fitness DVDs

> Shop Weights & Benches

> Shop Fitness Technology

> Shop Yoga Essentials

> See more



**Best-Selling
Ellipticals**
> Shop now



**New Trend:
Office Fitness**
> Shop now

Seasonal Fitness Markdowns



Yoga



Boxing & MMA



Fitness Technology



Cardio Training



Accessories



Weights

Google

Top Stories

Miami Heat
International Lease
Finance Corporation
HSBC
Mali
X-37B
Google Maps
Tom Brady
Golden State Warriors
Zack Greinke
Prostate cancer

Tokyo, Japan

World

U.S.

Business

Technology

Entertainment

Sports

Science

Health

Top Stories



See
realtime
coverage

Commentary: Right to work will bring jobs home

The Detroit News - 54 minutes ago
Gov. Rick Snyder and legislative leaders embarked last week on the bumpy journey to make Michigan a right to work state. If they succeed, they will vault Michigan to the top tier of states competing for new business and more jobs.

Opinion: Worker Liberation in Michigan Wall Street Journal
In Depth: Michigan's Right to Work Law Washington Times

Related Rick Snyder » Trade union » United Auto Workers »




The fiscal cliff's whale of a tale
Albany Times Union - 58 minutes ago
A "grand bargain" to avert the fiscal cliff and defuse our growing debt bomb must include tax increases and spending cuts.



Navy identifies SEAL killed in hostage rescue in Afghanistan

Reuters - 40 minutes ago
Tue Dec 11, 2012 1:23am EST. (Reuters) - A U.S. Navy SEAL was killed in Sunday's rescue mission in Afghanistan that freed an American doctor kidnapped by the Taliban, the Defense Department said on Monday.



Recent

Nikkei eases, investors cautious after recent sharp rally
Reuters - 13 minutes ago

Mexican president confident of key reforms in 2013
Reuters - 36 minutes ago

AP Exclusive: ACLU seeks OAS probe of Padilla case
Houston Chronicle - 57 minutes ago

Tokyo, Japan » - Change location

示例应用程序



People listening right now:



thesoozbutton is listening to **Geographer** (indie pop, electronic, indie)
Scrobbling from Spotify



scot77 is listening to **Shawn Colvin** (female vocalists, singer-songwriter, folk)
Scrobbling from iTunes in United Kingdom



JayLady is listening to **Fefe Dobson** (pop, female vocalists, rock)
Scrobbling from iTunes



Stritoh is listening to **Metallica** (thrash metal, metal, heavy metal)
Scrobbling from The Last.fm Scrobbler in Chile



kunprof is listening to **Coldplay** (rock, alternative, britpop)
Scrobbling from The Last.fm Scrobbler in Russian Federation

Artists & Labels



Join your fans, upload your music, and earn royalties. [Learn more »](#)

Developers & Designers



Looking for resources? Grab a [logo pack](#) or head over to our [API »](#)

Last.fm recommendations give you:



★ Music

Recommendations based on what you love with a little twist of something different.

📶 Radio

Listen to endless personalised radio stations based on an artist, tag — or even a friend's taste!

🎫 Concerts

Never miss another gig. Based on your taste, Last.fm recommends you events and festivals.

👤 People

Get connected with 'musical neighbours' - people who love the same music as you.

Featured

Most Popular

Recent Edits

Subjects

Series & Lists

Tags

Authors

The New York Times® Bestsellers in Fiction

Browse America's best-selling books, according to The New York Times.



The New York Times® Bestsellers in Non-Fiction

Browse America's best-selling books, according to The New York Times.



Featured Books

Browse featured books, editorially selected by Shelfari.



SIGN IN

POWERED BY
amazon.com

Legacy Shelfari sign in

Our Favorite Quotes
Memorable quotes from
the classics.

"Now, I entertain a
ridiculous partiality
for my head, it
seems to suit my
shoulders so
correctly."

See quotes from
The Three
Musketeers

"Nothing travels
faster than the
speed of light with
the possible
exception of bad
news, which obeys
its own special
laws."

示例应用程序




企业内联网



系统输入

- 交互数据（用户↔ 项目
 - 明确反馈-评分、评论
 - 隐式反馈-购买、浏览
- 用户/项目个人数据
 - 用户端：
 - 结构属性信息
 - 个人描述
 - 社交网络
 - 物品侧面：
 - 结构属性信息
 - 文本描述/内容信息
 - 项目（类别）分类

用户与项目之间的交互



观察到的偏好

(购买、评分、页面浏览量、书签等)

用户和项目简介



用户配置文件：

(1) 属性

国籍、性别、
年龄、爱好等



(2) 文本

个人描述



(3) 链接

社交网络



产品简介：

(1) 属性

价格、重量、
颜色、品牌等

(2) 文本

产品描述

(3) 链接

项目（类别）
分类

有关用户和项目的全部信息

用户配置文件：

(1) 属性


国籍、性别、
年龄、爱好等

(2) 文本

个人描述

(3) 链接

社交网络



产品简介：

(1) 属性

价格、重量、
颜色、品牌等

(2) 文本

产品描述

(3) 链接

项目（类别）
分类

观察到的偏好

(购买、评分、页面浏
览量、书签等)

建议方法

□ 协同过滤

- 使用交互数据（用户-项目矩阵）
- 流程：识别相似用户，根据他们的评分进行推断

□ 基于内容的策略

- 使用用户/项目（特征）的配置文件
- 流程：生成用于对新项目进行分类的规则/分类器

□ 基于潜在因素的策略

建议方法

- 协同过滤
 - 基于最近邻
 - 基于用户
 - 已添加商品
- 基于内容的策略
- 基于潜在因素的策略

协同过滤的问题

- ❑ 冷启动：系统中需要有足够的其他用户来找到匹配。
- ❑ 稀疏性：如果要推荐的项目很多，即使用户很多，用户 / 评分矩阵也是稀疏的，很难找到对相同项目进行评分的用户。
- ❑ 第一评价者：不能推荐以前没有被评价过的项目。
 - 新商品
 - 神秘物品
- ❑ 人气偏见：无法向具有独特品味的人推荐商品。
 - 倾向于推荐热门商品。

建议方法

- 协同过滤
- 基于内容的策略
- 基于潜在因素的策略

用户和项目简介



用户配置文件：

(1) 属性

国籍、性别、
年龄、爱好等



(2) 文本

个人描述



(3) 链接

社交网络



产品简介：

(1) 属性

价格、重量、
颜色、品牌等

(2) 文本

产品描述

(3) 链接

项目（类别）
分类

基于内容的方法的优势

- 不需要其他用户的数据。
 - 没有冷启动或稀疏性问题。
- 能够向具有独特品味的用户推荐。
- 能够推荐新的和不受欢迎的商品
 - 没有一级问题。
- 可通过列出导致某项被推荐的内容特征来解释建议项目。

建议方法

- 协同过滤
- 基于内容的策略
 - 基于文本相似度
 - 聚类
 - 分类
- 基于潜在因素的策略

基于文本相似性的技术

- 向量空间模型 (VSM)
 - 词频-信息度-重要性
- 基于语义资源
 - Word网络
 - 维基百科
 - 蜘蛛网

有关用户和项目的全部信息

用户配置文件：

(1) 属性

国籍、性别、
年龄、爱好等

(2) 文本

个人描述

(3) 链接

社交网络



产品简介：

(1) 属性

价格、重量、颜色、品牌等

(2) 文本

产品描述

(3) 链接

商品之间的关联关系（即，由同一用户共同购买的物品）

观察到的偏好（购买、评分、页面浏览量、播放列表、书签等）

有关用户和项目的全部信息



剖面表示-向量空间模型

用户配置文件

- 结构化数据属性：书、汽车、电视...
- 自由文本
我喜欢汽车、电影、音乐.....

产品简介

- 结构化数据
属性：名称、颜色、价格...
- 自由文本
“这辆车装有自动空调，设备齐全。”

	用户A	项目B
小汽车	1	1
书	0	0
电视机	0	0
自行车	1	1
...	...	...


余弦相似度

$$\text{sim}(A, B) = \cos(\theta) = \frac{A \bullet B}{\|A\| \|B\|}$$

加权余弦相似度

$$\text{sim}(A, B) = \frac{\sum_{j=1}^n w_{a_j} * w_{b_j}}{\sqrt{\sum_{j=1}^n (w_{a_j})^2 * \sum_{j=1}^n (w_{b_j})^2}}$$

weight



TF*IDF加权

□ TF*IDF加权

$$w(t, d) = tf_{t,d} \times idf_t$$

- 文档d中术语t的出现频率 $tf_{t,d}$ ，即 $n_{t,d}$ ，表示术语t在d中出现的次数

$$tf_{t,d} = \frac{n_{t,d}}{\sum_k n_{k,d}}$$

- 术语t的逆文档频率 idf_t

即， df_t 表示t在所有文档中出现的次数

$$idf_t = \log \left(\frac{N}{df_t} \right)$$

其中N是所有文档的数量

个人资料介绍

■ 非结构化数据

例如，餐厅的文字描述或评论，或者新闻文章

- 没有具有明确定义值的属性名称

- 自然语言复杂性

 - 同义词含义不同

 - 不同词，意思相同

■ 需要对自由文本进行结构化处理，才能用于推荐算法

有关用户和项目的全部信息

用户配置文件：

(1) 属性

国籍、性别、年龄、爱好等

(2) 文本

个人描述

(3) 链接

社交网络



产品简介：

(1) 属性

价格、重量、颜色、品牌等

(2) 文本

产品描述

(3) 链接

商品之间的关联关系（即，由同一用户共同购买的商品）

观察到的偏好
(购买、评级、

页面浏览量、播放列表、

我喜欢汽车，

电影、音乐……书签等) 自动空调……

his的车装备得很好


基于文本相似性的技术

- 向量空间模型 (VSM)
 - 词频-信息度-重要性
- 基于语义资源
 - Word网络
 - 维基百科
 - 蜘蛛网

基于知识的相似性

□ 知识数据

Word网络



□ 直觉：

如果两个词彼此相近，那么它们就是相似的

□ 测量方法

■ 基于最短路径

[Rada, SMC ' 89][Wu, ACL ' 94][Leacock ' 98]

■ 基于内容

[Resnik, IJCAI ' 95][Jiang, ROLING ' 97][Lin, ICML ' 98]

基于知识的词义相似性

- (Leacock & Chodorow, 1998)

$$sim_{lch} = \frac{len}{2 * D}$$

- (Wu & Palmer, 1994)

$$sim_{wup} = \frac{2 * depth(LCS)}{depth(concept_1) + depth(concept_2)}$$

- (Lesk, 1986)

- 查找两个单词的字典条目之间的重叠部分


基于文本相似性的技术

- 向量空间模型 (VSM)
 - 词频-信息度-重要性
- 基于语义资源
 - Word网络
 - 维基百科
 - 蜘蛛网

显式语义相似性 (ESA)

- 由Gabrilovich提出[IJCAI, 07]
- 将文本映射到Wiki中的概念（即，向量）
- 通过常用向量（即，余弦）测量计算ESA评分

ESA流程



这个图来自Gabrilovich IJCAI '07。

ESA示例

- ❑ 狗抓住了红球。
- ❑ 一只拉布拉多在公园里玩耍。

	台球术语表	美式足球战略	棒球	波士顿红袜
T1:	2711	402	487	528
T2:	108	171	107	74

- ❑ 相似度评分：14.38%

基于文本相似性的技术

- 向量空间模型 (VSM)
 - 词频-信息度-重要性
- 基于语义资源
 - Word网络
 - 维基百科
 - 蜘蛛网

基于语料库的相似性

□ 语料库数据

- 网络（搜索引擎）

□ 直觉：

- 如果两个词经常出现在同一页面中，则它们是相似的
- PMI - IR [Turney, ECML, 01]

PMI-IR

- 逐点互信息 (Church和Hanks, 1989)

$$PMI(w1, w2) = \log_2 \left(\frac{p(w1 \wedge w2)}{p(w1) * p(w2)} \right)$$

- PMI - IR (Turney '01)

$$PMI - IR(w1, w2) = \log_2 \left(\frac{HitRatio(w1 \wedge w2)}{HitRatio(w1)HitRatio(w2)} \right)$$

$$= \log_2 \left(\frac{\frac{Hit(w1 \wedge w2)}{N}}{\frac{Hit(w1)}{N} * \frac{Hit(w2)}{N}} \right)$$

$$= \log_2 \left(\frac{Hit(w1 \wedge w2) * N}{Hit(w1) * Hit(w2)} \right)$$

其中N是网页数量

建议方法

- 协同过滤
- 基于内容的策略
 - 基于文本相似度
 - 聚类
 - 分类

有关用户和项目的全部信息

用户配置文件：

(1) 民族、性别、年龄、爱好等
(2) 文字

个人描述

(3) 链接

社交网络



产品简介：

(1) 属性

价格、重量、颜色、品牌等

(2) 文本

产品描述

(3) 链接

商品之间的关联关系（即，由同一用户共同购买的商品）

观察到的偏好 (Purchases, Ratings, page views, play lists,

书签等)

聚类

聚类

- K-均值
- 层次聚类


K-均值

- 由MacQueen, J. B.介绍 (1967)
- 当我们知道k, 即我们想要找到的聚类数量时, 该方法有效
- 想法：
 - 随机选取k个点作为k个聚类的“质心”
 - 环
 - 对于每个点, 将该点放入其最近质心的聚类中
 - 重新计算群集质心
 - 重复循环 (直到两个连续迭代之间的簇没有变化为止)。

目标函数的迭代改进：

每个点到其聚类中心的平方距离之和

K-均值示例 (K=2)



随机选择种子重新分配

簇计算质心

重新分配群集

计算质心重新分配聚
类

已聚合！

聚类

- K均值
- 层次聚类

层次聚类

- 两种类型：
 - 聚合（自下而上）
 - 分裂（自上而下）
- 聚类：如果两组之间的距离小于阈值，则将它们合并
- 分裂性：如果组间距离超过阈值，则一个组被分成两个组
- 可以用一种称为树状图的优秀图形表示法来表达

层次聚类

- 将集群中的每个点单独放置。

对于 $l=1$ 到 $N-1$, do{

 设 $C1$ 和 $C2$ 为最可合并的簇对, 创建 C_{l+1} 作为 $C1$ 和 $C2$ 的父簇

}

- 例如：为了简化, 我们使用一维对象。

- 数值对象：1、2、5、6、7


- 聚类：

- 找到两个最近的对象并合并；

- $\Rightarrow \{1, 2\}$, 所以现在我们有 $\{1.5, 5, 6, 7\}$ ；

- $\Rightarrow \{1, 2\}, \{5, 6\}$, 所以 $\{1.5, 5.5, 7\}$ ；

- $\Rightarrow \{1, 2\}, \{\{5, 6\}, 7\}$.



建议方法

- 协同过滤
- 基于内容的策略
 - 基于文本相似度
 - 聚类
 - 分类


说明分类任务

潮汐	属性1	属性2	归因3	课
1	是	大的	125K	不
2	不	中等	100K	不
3	不	小的	70K	不
4	是	中等	120K	不
5	不	大的	95K	是
6	不	中等	60K	不
7	是	大的	220K	不
8	不	小的	85K	是
9	不	中等	75K	不
10	不	小的	90K	是

训练集

潮汐	属性1	属性2	归因3	课
11	不	小的	55K	?
12	是	中等	80K	?
13	是	大的	110K	?
14	不	小的	95K	?
15	不	大的	67K	?

测试集




分类

- k-近邻 (kNN)
- 决策树
- 朴素贝叶斯
- 人工神经网络
- 支持向量机
- 集合方法

k-近邻分类 (kNN)

- kNN不从训练数据中构建模型。
- 方法
 - 为了对测试实例 d 进行分类，定义 k 邻域 P 为 d 的 k 个最近邻
 - 计算 P 中属于类别 c_j 的训练实例数 n
 - 估计 $Pr(c_j | d)$ 为 n/k (多数投票)
- 无需培训。每个测试用例的分类时间与训练集大小呈线性关系。
- k 通常通过验证集或交叉验证经验选择，尝试一系列的 k 值。
- 距离函数至关重要，但取决于应用程序。

示例：k=1 (1NN)




● 汽车

● 书 ● 服

装

■ 哪个班级？
书

示例：k=3 (3NN)



● 汽车
● 书 ● 服
装

■ 哪个班级?
汽车

讨论

■ 优势

- 非参数架构
- 简单
- 强大
- 无需培训时间

■ 劣势

- 内存密集型
- 分类/估计速度慢
- 对 k 敏感

分类

- k-近邻 (kNN)
- 决策树
- 朴素贝叶斯
- 人工神经网络
- 支持向量机
- 集合方法

决策树示例

判断作弊可能性：是/否

categorical
categorical
continuous
class

	退款	婚姻状况 状况	应纳税 收入	
1	是	单人	125K	不
2	不	已婚	100K	不
3	不	单人	70K	不
4	是	已婚	120K	不
5	不	离婚	95K	是
6	不	已婚	60K	不
7	是	离婚	220K	不
8	不	单人	85K	是
9	不	已婚	75K	不
10	不	单人	90K	是

训练数据


决策树示例

□ 判断作弊可能性：是/否

categorical
categorical
continuous
class

潮汐	退款	婚姻状况	应税收入	作弊
1	是	单人	125K	不
2	不	已婚	100K	不
3	不	单人	70K	不
4	是	已婚	120K	不
5	不	离婚	95K	是
6	不	已婚	60K	不
7	是	离婚	220K	不
8	不	单人	85K	是
9	不	已婚	75K	不
10	不	单人	90K	是

训练数据




模型：决策树

另一个决策树示例

□ 判断作弊可能性：是/否

	退款	婚姻状况	应税收入	
		categorical	categorical	continuous class
1	是	单人	125K	不
2	不	已婚	100K	不
3	不	单人	70K	不
4	是	已婚	120K	不
5	不	离婚	95K	是
6	不	已婚	60K	不
7	是	离婚	220K	不
8	不	单人	85K	是
9	不	已婚	75K	不
10	不	单人	90K	是



可能有不止一棵树符合相同的数据！

决策树-构建

□ 创建决策树

- 手册-基于专家知识
- 自动化-基于训练数据 (DM)

□ 两个主要问题：

- 问题#1：拆分时应采用哪种属性？
 - 问题#2：何时停止分裂？
-

分类

- k-近邻 (kNN)
- 决策树
 - 马车
 - C4.5
- 朴素贝叶斯
- 人工神经网络
- 支持向量机
- 集合方法

CART算法

- 分类和回归树
- 由Breiman等人（UCB）于80年代初开发。
 - 将树模型引入统计主流
 - 采用交叉验证的严格方法来选择最佳树

关键思想

递归分区

- 取走您所有的数据。
- 考虑所有变量的所有可能值。
- 选择在目标中产生最大“分离”的变量/值 ($X=t_1$)。
- ($X=t_1$) 称为“分裂”。
- 如果 $X < t_1$ ，则将数据发送到“左侧”；否则，将数据点发送到“右侧”。
- 现在在这些两个“节点”上重复相同的过程
 - 你得到一棵“树”
 - 注：CART仅使用二元分割。

关键思想

- 设 $\Phi(s|t)$ 为节点 t 处候选分割 s 的“好坏”度量，其中：

$$\Phi(s|t) = 2P_L P_R \sum_{j=1}^{\# \text{ classes}} |P(j|t_L) - P(j|t_R)|$$

t_L = left child node of node t

t_R = right child node of node t

$$P_L = \frac{\text{number of records at } t_L}{\text{number of records in training set}}$$

$$P_R = \frac{\text{number of records at } t_R}{\text{number of records in training set}}$$

$$P(j|t_L) = \frac{\text{number of class } j \text{ records at } t_L}{\text{number of records at } t_L}$$

$$P(j|t_R) = \frac{\text{number of class } j \text{ records at } t_R}{\text{number of records at } t_R}$$

- 然后，最优分割在节点 t 的所有可能分割中最大化 $\Phi(s|t)$ 度量。

关键思想

□ 当两个主要成分都较大时， $\Phi(s|t)$ 较大：

$$2P_L P_R \text{ 和 } \sum_{j=1}^{\# \text{ classes}} |P(j|t_L) - P(j|t_R)|$$

1. $2P_L P_R$ - 如果子节点大小相等（支持度相同）：最大值为
 $0.5*0.5 = 0.25$ 和 $0.9*0.1 = 0.09$

2. $Q(s|t) = \sum_{j=1}^{\# \text{ classes}} |P(j|t_L) - P(j|t_R)|$

- 如果每个类的子节点完全相同（纯），则为最大值
- $Q(s|t)$ 的理论最大值为k，其中k是目标变量的类别数

CART示例

客户	节余	资产	收入 (\$1000s)	信用风险
1	中等	高	75	好的
2	低	低	50	坏的
3	高	中等	25	坏的
4	中等	中等	50	好的
5	低	中等	100	好的
6	高	高	25	好的
7	低	低	25	坏的
8	中等	中等	75	好的

信用风险分类记录的设置

CART示例-候选人分割

□ CART仅限于二元分割

候选人分割	左子节点, tL	右子节点, tR
1	节省=低	Savings={medium, high}
2	储蓄=中等	Savings={low, high}
3	节省=高	Savings={low, medium}
4	资产=低	Assets={medium, high}
5	资产=中等	Assets={low, high}
6	资产=高	Assets={low, medium}
7	收入 $\leq 25,000$ 美元	收入 $> 25,000$ 美元
8	收入 $\leq 50,000$ 美元	收入 $> 50,000$ 美元
9	收入 $\leq 75,000$ 美元	收入 $> 75,000$ 美元

候选分裂, t=根节点

CART入门

□ 分割1. ->节省=低 (L-真, R-假)

■ Right:1,3,4,6,8

■ Left:2,5,7

$$\Phi(s|t) = 2P_L P_R \sum_{j=1}^{\# \text{ classes}} |P(j|t_L) - P(j|t_R)|$$

□ $P_R = 5/8 = 0.625$ $P_L = 3/8 = 0.375$ ->
 $2 * P_L P_R = 15/64 = 0.46875$

□ $P(j=\text{Bad} | t)$

■ $P(\text{坏} | t_R) = 1/5 = 0.2$

■ $P(\text{坏} | t_L) = 2/3 = 0.67$

□ $P(j=\text{Good} | t)$

■ $P(\text{良好} | t_R) = 4/5 = 0.8$

■ $P(\text{良好} | t_L) = 1/3 = 0.33$


□ $Q(s|t) = |0.67 - 0.2| + |0.8 - 0.33| = 0.934$

CART示例

分裂	平地	公关	$P(j t_L)$	$P(j t_R)$	$2P_L P_R$	$Q(s t)$	$\Phi(s t)$
1	0.375	0.625	G:0.333 B:0.667	G:0.8 B:0.2	0.46875	0.934	0.4378
2	0.375	0.625	G:1 B:0	G:0.4 B:0.6	0.46875	1.2	0.5625
3	0.25	0.75	G:0.5 B:0.5	G:0.667 B:0.333	0.375	0.334	0.1253
4	0.25	0.75	G:0 B:1	G:0.833 B:0.167	0.375	1.667	0.6248
5	0.5	0.5	G:0.75 B:0.25	G:0.5 B:0.5	0.5	0.5	0.25
6	0.25	0.75	G:1 B:0	G:0.5 B:0.5	0.375	1	0.375
7	0.375	0.625	G:0.333 B:0.667	G:0.8 B:0.2	0.46875	0.934	0.4378
8	0.625	0.375	G:0.4 B:0.6	G:1 B:0	0.46875	1.2	0.5625
9	0.875	0.125	G:0.571 B:0.429	G:1 B:0	0.21875	0.858	0.1877

□ 对于每个候选分割，检查度量 $\Phi(s|t)$ 的各种组成部分的

CART示例




初始分割后的CART决策树

CART示例

分裂	平地	公关	$P(j t_L)$	$P(j t_R)$	$2P_L P_R$	$Q(s t)$	$\Phi(s t)$
1	0.167	0.833	G:1 B:0	G:0.8 B:0.2	0.2782	0.4	0.1112
2	0.5	0.5	G:1 B:0	G:0.667 B:0.333	0.5	0.6666	0.3333
3	0.333	0.667	G:0.5 B:0.5	G:1 B:0	0.4444	1	0.4444
5	0.667	0.333	G:0.75 B:0.25	G:1 B:0	0.4444	0.5	0.2222
6	0.333	0.667	G:1 B:0	G:0.75 B:0.25	0.4444	0.5	0.2222
7	0.333	0.667	G:0.5 B:0.5	G:1 B:0	0.4444	1	0.4444
8	0.5	0.5	G:0.667 B:0.333	G:1 B:0	0.5	0.6666	0.3333
9	0.167	0.833	G:0.8 B:0.2	G:1 B:0	0.2782	0.4	0.1112


决策节点A上每个候选分割的度量 $\Phi(s|t)$ 的分量值

CART示例



决策节点A分裂后的CART决策树

CART示例



CART决策树，完全生长形式

分类

- k-近邻 (kNN)
- 决策树
 - 马车
 - C4.5
- 朴素贝叶斯
- 人工神经网络
- 支持向量机
- 集合方法

C4.5算法

- ❑ Quinlan于1993年提出
- ❑ 内部节点表示对属性的测试。
- ❑ 分支表示测试的结果，例如，Color=red。
- ❑ 叶节点表示一个类别标签或类别标签分布。
- ❑ 在每个节点上，选择一个属性尽可能地将训练示例分成不同的类别
- ❑ 通过沿着匹配路径到达叶节点来对新案例进行分类。

C4.5算法

- CART与C4.5之间的差异：
 - 与CART不同，C4.5算法不受二元分割的限制。
 - 它为分类属性的每个值生成一个单独的分支。
 - C4.5测量节点均匀性的方法与CART不同。

C4.5算法-测量

- 我们有一个候选分割S，它将训练数据集T划分为几个子集，T1、T2，...，Tk。
- C4.5使用熵减少的概念来选择最佳的分割。
- 熵减少(S)=H(T)-HS(T)，其中熵H(X)为：

$$H(X) = - \sum_j p_j \log_2(p_j)$$

其中Pi表示子集i中记录的比例。

- 各子集T1、T2，...，Tk的熵加权和
-
- C4.5选择最优分割，即熵减少最大的分割

分类

- k-近邻 (kNN)
- 决策树
- 朴素贝叶斯
- 人工神经网络
- 支持向量机
- 集合方法

贝叶斯规则

□ 推荐系统问题

- L_i 是项目 i 的类 (即, 用户喜欢项目 i)

- A 是与项目 i 相关联的特征集

- 估计 $p(L_i | A)$

□ $p(L_i | A) = p(A | L_i) p(L_i) / p(A)$

□ 我们总是可以用条件概率来重述

- 反向条件 $p(A | L_i)$

- 两个先验概率

- $p(L_i)$

- $p(A)$

□ 通常, 反向条件更容易知道

- 我们可以计算一个功能在用户喜欢的项目中出现的频率

- 频率假设

朴素贝叶斯

□ 独立性 (Naive Bayes假设)

■ $a_1, a_2, \dots, a_k$ 是独立的

□ 联合概率

$$p(a_1, \dots, a_k) = \prod_{j=1..k} p(a_j)$$

□ 用于条件概率

$$p(a_1, \dots, a_k | L_i) = \prod_{j=1..k} p(a_j | L_i)$$

□ 贝叶斯规则

$$p(L_i | a_1, a_2, \dots, a_k) = \frac{p(L_i) \prod_{j=1}^k p(a_j | L_i)}{\prod_{j=1}^k p(a_j)}$$

示例

计算分类所需的全部概率

A	B	C
m	b	t
m	s	t
g	q	t
h	s	t
g	q	t
g	q	f
g	s	f
h	b	f
h	q	f
m	b	f

$$\Pr(C = t) = 1/2,$$

$$\Pr(C = f) = 1/2$$

$$\Pr(A=m \mid C=t) = 2/5$$

$$\Pr(A=g \mid C=t) = 2/5$$

$$\Pr(A=h \mid C=t) = 1/5$$

$$\Pr(A=m \mid C=f) = 1/5$$

$$\Pr(A=g \mid C=f) = 2/5$$

$$\Pr(A=h \mid C=f) = 2/5$$

$$\Pr(B=b \mid C=t) = 1/5$$

$$\Pr(B=s \mid C=t) = 2/5$$

$$\Pr(B=q \mid C=t) = 2/5$$

$$\Pr(B=b \mid C=f) = 2/5$$

$$\Pr(B=s \mid C=f) = 1/5$$

$$\Pr(B=q \mid C=f) = 2/5$$

Now we have a test example:

$$A = m \quad B = q \quad C = ?$$

示例

□ 对于 $C = t$ ，我们有

$$\Pr(C = t) \prod_{j=1}^2 \Pr(A_j = a_j \mid C = t) = \frac{1}{2} \times \frac{2}{5} \times \frac{2}{5} = \frac{2}{25}$$

□ 对于 $C = f$ ，我们有

$$\Pr(C = f) \prod_{j=1}^2 \Pr(A_j = a_j \mid C = f) = \frac{1}{2} \times \frac{1}{5} \times \frac{2}{5} = \frac{1}{25}$$

□ $C = t$ 更有可能。t 是最终类别。

朴素贝叶斯分类器

□ 优点：

- 易于实施
- 效率高
- 在许多应用中获得良好的结果

□ 缺点

- 假设：类条件独立，因此当严重违反该假设时（高度相关数据集），准确度会降低

分类

- K-最近邻 (kNN)
- 决策树
- 朴素贝叶斯
- 人工神经网络
- 支持向量机
- 集合方法

机器学习参考文献

- T. Mitchell, 《机器学习》, McGraw Hill出版社, 1997年
- C. M. Bishop, 《模式识别与机器学习》, Springer出版社, 2006年
- T. Hastie、R. Tibshirani和J. Friedman, 《统计学习的要素》, Springer出版社, 2001年。
- V. Vapnik, 《统计学习理论》, Wiley-Interscience, 1998。
- Y. Kodratoff, R. S. Michalski, 《机器学习：一种人工智能方法》, 第3卷, Morgan Kaufmann出版社, 1990年