


Harnessing Sparsification in Federated Learning: A Secure, Efficient, and Differentially Private Realization

Clover 安全、高效、差分隐私的稀疏联邦学习实现

Shuangqing Xu, Yifeng Zheng, Zhongyun Hua
ACM CCS 2025

汇报人：林晖鹏
2026.7.3

联邦学习：数据不出本地，共同训练模型



关键转折：虽然原始数据没有上传，但上传的梯度并不一定安全。

MOTIVATION

为什么要稀疏化：梯度通信太贵

每轮每个客户端都上传完整梯度，通信量会随着模型维度和客户端数量线性放大。

- 大量梯度分量很小，不一定都值得上传。
- 已有梯度压缩工作显示，top-k/稀疏化能带来数量级通信节省。

99%

Aji & Heafield: 许多小更新可以被置零。

**270x-
600x**

Deep Gradient Compression 报告的大幅压缩比。

**97MB ->
0.35MB**

DGC 中 ResNet-50 梯度通信的示例量级。

DENSE GRADIENT VS SPARSE GRADIENT



稀疏化可以大大减少通信；Clover 接下来解决的是：稀疏 top-k 在隐私保护下如何聚合。

TOP-K

top-k 稀疏化： 只上传最重要的梯度 坐标

客户端从完整梯度中选择绝对值最大的 k 个坐标，只上传这些坐标和值。

$\text{TopK}(g) = \{(i, g_i) \mid i \text{ belongs to largest-}k \text{ coordinates of } |g|\}$

GRADIENT VECTOR



上传内容 100%
通信节省 0%

PRIVACY RISK

top-k index 本身也是隐私暴露面

即使梯度值被保护，客户端反复选中的坐标仍会暴露本地数据对模型参数的影响。

- 服务器可观察每轮被选中的 top-k 坐标。
- 坐标模式与本地标签、特征分布存在相关性。
- Clover 的目标是同时隐藏 value 和 index。

泄露面：selected indices over rounds

SERVER-OBSERVED TOP-K INDICES

$i = 2$

$i = 4$

$i = 6$

?

服务器观察到的是 top-k 位置 and 值

标签推断

哪些类别更可能出现在本地数据中

分布推断

客户端数据是否偏向某类样本

相似性分析

哪些客户端的数据分布更接近

跨轮追踪

多轮 index 模式会累积泄露

要保留 **top-k**，传统路线仍有缺口

常见方案要么假设梯度是密集向量，要么隐私保护不完整，要么开销过高，难以同时满足效率与安全。

方法1：FedAvg + 全量梯度 + SecAgg

Dense update: $g \in \mathbb{R}^d$ (每轮上传完整梯度)

- 与传统 SecAgg 语义匹配，协议成熟。
- 通信成本随模型规模线性，面对大模型/弱网络时压力大。
- 直接违背 top-k 目标，无法享受稀疏压缩收益。

方法2：top-k + 通用 ORAM / 通用安全计算

Index + value 全部隐藏 (理论上更全面)

- 可以规避位置与数值一起泄露的问题。
- 密态/访问模式开销高，轮次与通信都更重。
- 对大规模联邦训练，性能常不够实用。

方法3：只保护值，不保护 index

上传 (index, value) 中 value 加密, index 明文

- 实现相对容易，工程负担较低。
- index 暴露仍泄露客户端特征与数据分布信息。
- 无法满足 Clover 对 top-k 完整隐私的目标。

因此 Clover 的核心是：在保留标准 top-k 的同时，隐藏 index 与 value，并高效完成稀疏聚合与 DP 控制。

PROBLEM DEFINITION

为什么需要 Clover?

Top-k 稀疏联邦学习



通信高效

保持 Top-k 稀疏上传
避免恢复为 dense 上传

Clover



隐私保护

隐藏 index 和 value
单客户端更新不外泄

正确聚合

聚合多个 top-k 稀疏
向量
恢复可用于更新的结果

如何在隐藏 index 与 value 的情况下，正确聚合多个客户端的 top-k 稀疏梯度?

隐藏单个更新，只暴露聚合结果

服务器不能看到任一客户端选择的 index 和 value，但最终仍要得到按坐标求和后的全局更新。

PRIVATE INPUT

客户端私有 **top-k**

Client A: (2,+0.8), (7,-1.1)

Client B: (3,-0.5), (7,+0.6)

Client C: (1,+1.2), (5,-0.4)

隐藏 index

隐藏 value

->

Clover

安全聚合

->

PUBLIC OUTPUT

只暴露全局聚合

G[1]=+1.2

G[2]=+0.8

G[3]=-0.5

G[5]=-0.4

G[7]=-0.5


按坐标求和

不可回溯单个客户端

目标不是恢复每个客户端的更新，而是在隐藏 index 和 value 的前提下得到按坐标求和的结果。

用三个服务器分散信任

客户端不把明文 top-k 交给单个服务器，而是拆成多份 share；服务器协作计算，但单台服务器看不全 index/value。



核心思想：单个服务器看不全 index/value，多个服务器协作才能完成聚合。

SparVecAgg: 用随机置换掩码隐藏 index

1

原始 **sparse vector**

0	+0.8	0	0
0	0	-1.1	0

这里的 2 和 7 表示客户端选择了哪些梯度坐标；即使 value 加密，位置模式本身也会泄露信息。

->

2

compact 后只保留值

+0.8	-1.1	0	0
0	0	0	0

先把真正要上传的 value 收到前面，让通信仍然保持 top-k 稀疏，而不是上传完整 d 维向量。

->

3

随机置换掩码位置

$$\pi_0 \cdot \pi_1 \cdot \pi_2$$

两个随机置换掩码真实位置

客户端用随机 π_0 、 π_1 掩码真实 π ，只发送 π_2 的前 k 项；服务器无法直接读出真实 top-k index。

->

4

secret-shared shuffle

0	+0.8	0	0
0	0	-1.1	0

三台服务器在 share 上完成洗牌和求和，最后只得到聚合后的向量 share，看不到单个客户端的位置和值。

Clover 不直接上传 index；它用随机 permutation shares 掩码位置关系，再让服务器在秘密分享域里完成 shuffle 和聚合。

DISTRIBUTED DP NOISE

安全聚合之后，还要给输出加噪

SparVecAgg 隐藏单个客户端更新；DP 噪声限制最终释放的聚合结果继续泄露训练数据。

- 服务器先得到聚合梯度的 secret share: $J\Delta K$ 。
- 每台服务器本地采样一份噪声，并把噪声也 secret-share 成 $J\eta K$ 。
- 最终释放的是 $\Delta + \eta$ ，而不是无噪的真实聚合。



$J\Delta K + J\eta_0 K + J\eta_1 K + J\eta_2 K$

secret-shared addition

EPSILON 越小，隐私越强，噪声越大

中

隐私强度

中

噪声规模

中

模型效用

噪声

epsilon=5

EXPERIMENT 1 · MODEL UTILITY


Clover 保留标准 top-k，模型效用接近 DP-FedAvg

论文在 MNIST、CIFAR-10、Fashion-MNIST 上比较 Clover、DP-FedAvg、FedSMP-randk 和 FedSel。核心问题是：安全聚合和 DP 加噪之后，模型还能不能训练好。

结论：Clover 的目标不是超过无保护 FL，而是在隐藏 index/value 并加入 DP 后，仍尽量接近 central DP 的模型效用。

MNIST final accuracy under practical privacy budget

from Fig. 3 / Fig. 4, approximate values reported in paper



ACROSS DATASETS

3 datasets

MNIST、CIFAR-10、Fashion-MNIST 上都观察到类似趋势：Clover 最终效果接近 DP-FedAvg。

UTILITY

Clover $\approx$ DP-FedAvg

稀疏化会让前期训练稍慢，但轮数足够后，Clover 的精度接近 dense DP baseline。

PRIVACY BUDGET

$\epsilon < 10$, MNIST $> 96\%$

相比 LDP 方法 FedSel，Clover 在实际可接受的 privacy budget 下保持更高准确率。

EXPERIMENT 2 · SYSTEM EFFICIENCY


SparVecAgg 比通用 ORAM 基线低几个数量级

论文用 synthetic sparse vector aggregation 比较 SparVecAgg 和 distributed ORAM baseline。任务是安全聚合 100 个稀疏向量，观察服务器间通信和服务器计算成本。

结论：Clover 的效率优势来自“把 index 编码成 permutation 并做 secret-shared shuffle”，避免了对每个 index-value pair 执行昂贵 ORAM write。

Cost trend when density λ increases

ORAM grows with sparse writes; SparVecAgg stays low by using permutation-based shuffle



INTER-SERVER COMMUNICATION

1602x

当 $d = 10^5$ 、 $\lambda = 1\%$ 时，SparVecAgg semi-honest 相比 ORAM 更少通信。

SERVER-SIDE COMPUTATION

12041x

同一设置下，SparVecAgg semi-honest 相比 ORAM 更少服务器侧计算。

MALICIOUS SECURITY OVERHEAD

2.67x comm. / 3.67x runtime

完整性检查有开销，但相比 ORAM 仍然低很多。

EXPERIMENT 3 · DP NOISE ERROR



误差主要来自 **DP** 噪声，而不是稀疏聚合错误

论文用 synthetic sparse vector summation 单独评估差分隐私噪声带来的误差。设置为 100 个客户端、 $d = 10^4$ ，比较不同 privacy budget ϵ 和稀疏密度 λ 下的 MSE。

结论：Clover 的聚合过程仍然正确；最终误差主要是为了 DP 而有意加入的噪声，这是隐私和效用之间的可控权衡。

MSE mainly follows privacy budget ϵ

from Fig. 7: larger ϵ means less noise; density λ has little effect when ϵ is fixed



PRIVACY-UTILITY TRADE-OFF

$\epsilon \uparrow \rightarrow \text{MSE} \downarrow$

privacy budget 越大，允许的噪声越小，因此输出更接近真实聚合。

AGGREGATION CORRECTNESS

MSE $\approx$ DP noise

论文指出，协议正确聚合非零元素；估计均值和真实均值的差异主要就是 DP 噪声。

SPARSITY DENSITY

λ effect is small

固定 ϵ 后，MSE 基本不随 λ 改变，说明误差不是由稀疏位置恢复失败导致。

Clover 解决了核心聚合问题，但部署仍有边界

论文的设计重点是让 top-k、安全聚合和 DP 同时成立；真正落地时，还需要面对信任组织、系统复杂度和威胁模型边界。



结论：Clover 更像一个面向 top-k 稀疏联邦学习的安全聚合与 DP 框架，而不是完整替代联邦学习部署中的所有安全机制。

未来展望：从加噪保护到密文域训练

DP 通过扰动输出来限制泄露，但噪声会损伤模型效用；在大模型、多轮训练中，这种损失可能持续累积。

DP Noise

问题

效用损失

多轮训练中噪声影响可能累积

HE

设想

Encrypted Training

模型参数、梯度和更新尽量保持密文态

研究问题：能否用 FHE-based encrypted training 隐藏梯度、模型参数和更新过程，从而降低 DP 噪声规模？

01 · MAIN IDEA

密文域联邦训练

让聚合、模型更新甚至部分训练步骤在密文域完成，服务器尽量不接触明文梯度和参数。

02 · OPEN QUESTION

降低噪声依赖

如果中间过程由密码学隐藏，就可以研究是否只对最终发布结果使用更轻量、更精细的 DP。

03 · CHALLENGE

大模型下的可行性

FHE 计算开销高，还要处理非线性算子、top-k 选择和多轮训练效率，这是后续创新点。

展望：用密文域训练把隐私保护从“加噪隐藏”部分转向“密文不可见”，再结合更轻量的 DP 控制最终模型发布风险。

总结与展望

Clover 的核心价值： 让 top-k 稀疏联邦学习 真正安全可用

它不是只优化通信，也不是只做安全聚合，而是把效率、正确性和隐私保护放进同一个训练流程中一起权衡。

FUTURE DIRECTION

更少信任假设 · 更低系统开销 · 更强密码学后端 · 更大模型场景

后续工作应继续把 Clover 从“协议可行”推进到“工程可部署”：降低三服务器协作成本，并探索 HE / MPC 与 DP 的互补组合。

01

通信效率

保留 top-k 稀疏上传，不退回 d 维密集梯度。

02

安全聚合

同时隐藏稀疏位置 index 和梯度 value，避免位置模式泄露。

03

输出隐私

通过分布式 DP 噪声限制最终聚合结果暴露的信息量。

THANK YOU

谢谢聆听

敬请批评指正

汇报人：林晖鹏 · 2026.7.3