



南开大学  
Nankai University

计算机学院

深度学习及应用（高阶课）实验报告

# 生成对抗网络——FashionMNIST 图像生成

姓名：林晖鹏

学号：2312966

专业：计算机科学与技术

2026 年 6 月 19 日

# 目 录

|                                |   |
|--------------------------------|---|
| 1 实验目的                         | 1 |
| 2 实验设置                         | 1 |
| 3 评估方法：为什么用 FID 而非 loss 或 IS   | 1 |
| 4 模型结构设计                       | 2 |
| 4.1 原始全连接 GAN (gan)            | 2 |
| 4.2 加深全连接 GAN (gan_deep, 自由调整) | 2 |
| 4.3 卷积版 DCGAN (dcgan, 加分项)     | 2 |
| 4.4 网络结构打印结果                   | 2 |
| 5 实验结果分析                       | 2 |
| 5.1 学习率搜索结果 (按 FID)            | 2 |
| 5.2 最终模型综合性能对比 (200 轮)         | 3 |
| 5.3 训练 loss 与 FID 曲线           | 3 |
| 5.4 训练轮数的影响 (100 轮 vs 200 轮)   | 4 |
| 5.5 固定噪声生成样例 (8 张)             | 4 |
| 5.6 三种网络生成质量差异分析               | 5 |
| 6 隐变量扰动对生成结果的影响 (重点)           | 5 |
| 6.1 分析方法                       | 5 |
| 6.2 扰动现象与解释                    | 6 |
| 7 实验结论                         | 6 |
| A 代码目录说明                       | 7 |

## 1 实验目的

1. 掌握生成对抗网络（GAN）的基本原理与对抗训练流程。
2. 学会使用 PyTorch 搭建全连接 GAN 在 FashionMNIST 上完成图像生成，并给出生成器/判别器结构与训练 loss 曲线。
3. 学会搭建卷积版 DCGAN（加分项），并与全连接 GAN 对比生成质量。
4. 自定义一组随机噪声生成样例图，并重点分析单个隐变量维度的扰动对生成结果的影响。

## 2 实验设置

本实验使用 FashionMNIST 数据集，包含 60000 张训练图与 10000 张测试图，均为  $28 \times 28$  的灰度衣物图像，共 10 个类别。训练时将像素归一化到  $[-1, 1]$ ，以与生成器末端的 Tanh 输出保持一致；训练集再按 val-ratio 随机划分出验证集，分别用于参数学习与模型选择，测试集用于最终评估。

为体现“原始版本 GAN  $\rightarrow$  自由调整网络  $\rightarrow$  卷积版 DCGAN”的递进关系，本文实现并对比了三个模型：原始全连接 GAN (gan)、加深全连接 GAN (gan\_deep) 与卷积版 DCGAN (dcgan)。三者统一采用 Adam 优化器 ( $\beta_1 = 0.5$ )、批大小 512、隐变量维度 100，损失函数为二元交叉熵 (BCELoss)，每个 batch 按标准两步法先更新判别器、再更新生成器。为减小调参压力并尽量公平对比，本文对学习率集合  $\{0.001, 0.0005, 0.0002, 0.0001\}$  进行搜索，并以验证阶段最低 FID 对应的学习率作为最终配置 (FID 的选择理由见第 3 节)。学习率搜索阶段统一训练 100 轮，最终模型训练 200 轮，权重初始统一采用 DCGAN 论文式的  $N(0, 0.02)$ 。

## 3 评估方法：为什么用 FID 而非 loss 或 IS

GAN 的评估比一般分类任务更困难，因为生成器/判别器的 loss 并不反映样本质量：当判别器过强或发生模式崩溃时，loss 仍可能很低，因此不能像分类任务那样直接用验证集 loss 选择 checkpoint。本文初期曾尝试用一个“对抗均衡分”（衡量  $G$ 、 $D$  损失与  $D(x)$ 、 $D(G(z))$  偏离理论均衡点的程度）来选模型，但发现它会把“训练初期  $D$ 、 $G$  都接近随机（输出约 0.5）”的早期 epoch 误判为最优，导致选到几乎没训练好的生成器。

因此本文改用 Fréchet Inception Distance (FID) [1] 作为主指标。FID 用 Inception-V3 在特征空间度量真实图与生成图两个分布的距离，越低表示越接近真实分布、生成质量越好；它是当前 GAN 论文选 checkpoint 与超参的主流指标。本文每训练 5 轮计算一次 FID（搜索阶段用 2048 个样本、最终模型用 5000 个样本），并以 FID 最低的 checkpoint 作为交付模型，同时用该模型评估测试集，保证交付指标与交付模型一致。

值得说明的是，本文未采用 Inception Score (IS)。IS 依赖 ImageNet 预训练 Inception 网络对生成图的分类语义，而 FashionMNIST 是灰度衣物图，ImageNet-Inception 对其分类没有意义，所得 IS 不可靠，这也是多数 FashionMNIST 相关工作省略 IS 的原因 [4]。此外需提醒，FID 的绝对数值高度依赖样本数、图像预处理与所用 Inception 版本，因此不宜跨实现直接比较，本文主要用它做同一协议下的相对比较。

## 4 模型结构设计

### 4.1 原始全连接 GAN (gan)

原始 GAN 由老师提供的最基础全连接结构，作为对照基线。生成器为单隐藏层 MLP ( $100 \rightarrow 128 \rightarrow 784$ , LeakyReLU 激活、Tanh 输出)，判别器对称地为  $784 \rightarrow 128 \rightarrow 1$  (LeakyReLU + Sigmoid)。其特点是结构简单、参数量小，但表达能力有限，难以刻画衣物的空间结构。

### 4.2 加深全连接 GAN (gan\_deep, 自由调整)

为说明“在全连接框架内提升容量”的效果，本文将生成器加深为经典的  $100 \rightarrow 256 \rightarrow 512 \rightarrow 1024 \rightarrow 784$  阶梯结构，每个隐藏层后接 BatchNorm 与 LeakyReLU[2]，末端 Tanh 输出；判别器为  $784 \rightarrow 512 \rightarrow 256 \rightarrow 1$ ，隐藏层使用 LeakyReLU 与 Dropout 以抑制判别器过强导致的生成器梯度消失。

### 4.3 卷积版 DCGAN (dcgan, 加分项)

DCGAN 使用转置卷积构建生成器、卷积构建判别器 [3]。生成器将 100 维噪声经转置卷积逐级上采样到  $28 \times 28$ （中间使用 BatchNorm 与 ReLU，末端 Tanh）；判别器对称地用步长卷积逐级下采样并以 Sigmoid 输出真假概率。卷积结构引入了图像的空间归纳偏置，因此对衣物纹理与轮廓的建模能力显著强于全连接网络。

### 4.4 网络结构打印结果

按照要求,模型结构可由 `print(net)` 直接打印,完整输出保存在各运行目录的 `model_structure.txt` 中。下面给出三个模型生成器与判别器的顶层结构骨架。

表 1: 三个模型生成器/判别器结构骨架 (`print(net)` 摘要)

| Model    | 结构摘要                                                                                                                                                                                      |
|----------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| gan      | G: <code>Linear(100,128) → LeakyReLU → Linear(128,784) → Tanh</code><br>D: <code>Linear(784,128) → LeakyReLU → Linear(128,1) → Sigmoid</code>                                             |
| gan_deep | G: <code>[Linear → BN → LeakyReLU] × 3 (100→256→512→1024) → Linear(1024,784) → Tanh</code><br>D: <code>[Linear → LeakyReLU → Dropout(0.3)] (784→512→256) → Linear(256,1) → Sigmoid</code> |
| dcgan    | G: <code>ConvTranspose2d 链 (100→256→128→64→1), BN+ReLU, 末端 Tanh, 输出 1×28×28</code><br>D: <code>Conv2d 链 (1→64→128→256→1), BN+LeakyReLU, 末端 Sigmoid</code>                                 |

## 5 实验结果分析

### 5.1 学习率搜索结果 (按 FID)

表 2 给出三个模型在 100 轮训练下、四个学习率对应的最佳 FID。可以看出：(1) 三个模型的最优学习率均为 0.0005，说明该值是本设置下较稳健的选择；(2) FID 修正了前述“均衡分”的误选——例如若按均衡分，DCGAN 会被错误地选到 0.0001（实际 FID 最差），而 FID 正确地选出了收敛更充分的 0.0005。

表 2: 学习率搜索：各模型不同学习率下的最佳 FID（100 轮，越低越好）

| Model    | lr=0.001 | lr=0.0005       | lr=0.0002 | lr=0.0001       |
|----------|----------|-----------------|-----------|-----------------|
| gan      | 161.6    | [待填:gan@0.0005] | 184.8     | [待填:gan@0.0001] |
| gan_deep | 135.7    | <b>128.4</b>    | 128.7     | 137.0           |
| drgan    | 23.3     | <b>21.2</b>     | 22.7      | 25.3            |

## 5.2 最终模型综合性能对比（200 轮）

表 3 汇总三个最终模型（lr=0.0005，训练 200 轮）的最佳 FID、参数量与训练时间。FID 清晰地呈现出三级质量递进：原始全连接 GAN 最差、加深全连接 GAN 居中、卷积 DCGAN 最优，定量地印证了卷积结构对图像生成的价值。

表 3: 三个最终模型综合对比（lr=0.0005，200 轮）

| Model    | 最佳 FID ↓ | 最佳轮次  | 生成器参数量    | 判别器参数量    |
|----------|----------|-------|-----------|-----------|
| gan      | [待填:]    | [待填:] | 114,064   | 100,609   |
| gan_deep | [待填:]    | [待填:] | 1,489,936 | 533,505   |
| drgan    | [待填:]    | [待填:] | 1,911,232 | 1,738,752 |

## 5.3 训练 loss 与 FID 曲线

图 5.1 给出三个模型在最优学习率下的训练曲线，每张包含生成器 loss、判别器 loss、判别器对真假样本的打分  $D(x)/D(G(z))$  以及随训练下降的 FID 曲线。可以观察到：[待填: 结合曲线描述——如 gan\_deep 的  $D(x) \approx D(G(z)) \approx 0.5$  处于均衡、DCGAN 判别器逐渐占优但 FID 持续下降、原始 gan 较早进入平台等]。




图 5.1: 三个模型的训练曲线 (G loss / D loss / 判别器打分 / FID)。

#### 5.4 训练轮数的影响 (100 轮 vs 200 轮)

对比学习率搜索 (100 轮) 与最终模型 (200 轮) 在  $lr=0.0005$  下的 FID 可以发现: DCGAN 从延长训练中获益最明显——其 100 轮时最佳 FID 仍出现在末轮附近 (说明尚未收敛), 延长到 200 轮后 FID 进一步下降至 [待填:dcgan 200 轮 FID]; gan\_deep 的 FID 已接近平台, 延长仅有小幅改善 ([待填:]); 而原始 gan 的最佳 FID 出现在约第 50 轮、之后不降反升, 说明其瓶颈在网络容量而非训练不足, 延长训练并不能改善。这说明“是否需要延长训练”应结合收敛曲线判断, 而非一概而论。

#### 5.5 固定噪声生成样例 (8 张)

按要求, 本文固定一组随机噪声, 分别输入三个模型的生成器得到样例图 (图 5.2)。从生成质量看: 原始 gan 只能产生模糊轮廓、噪点严重, 难以辨认类别; gan\_deep 已能看出上衣、裤子、鞋、包等类别, 但表面仍有明显的颗粒状噪声; dcgan 的样例最清晰, 衣物边缘锐利、纹理自然, 可清楚区分各类衣物。




图 5.2: 三个模型在同一组固定噪声下生成的 8 张样例图对比。

## 5.6 三种网络生成质量差异分析

1. **原始全连接 GAN**：生成器仅有单个隐藏层，缺乏对图像空间结构的建模能力，只能学到衣物的粗略灰度分布，因此样例图模糊且噪点多；其最佳 FID 高达 [待填:]，在三者中最差。这说明在没有空间归纳偏置、容量又很小的情况下，全连接 GAN 难以生成清晰的衣物图像。
2. **加深全连接 GAN**：通过加深网络并引入 BatchNorm，gan\_deep 的生成质量明显提升，能够生成可辨认的衣物轮廓，FID 从原始 GAN 的 [待填:] 降到约 [待填:]。但由于全连接结构本质上仍把图像当作一维向量处理、缺乏局部相关性建模，其生成图始终带有椒盐状噪声，质量存在上限。
3. **卷积 DCGAN**：卷积/转置卷积显式建模了局部空间相关性，因此 DCGAN 的 FID 大幅领先（约 [待填:]，比 gan\_deep 低数倍），生成图最清晰。这直接说明了卷积结构对图像生成任务的关键作用，也正是本实验加分项的意义所在。

值得强调的一个现象是：gan\_deep 在训练过程中  $D(x)$ 、 $D(G(z))$  最接近理论均衡（约 0.5），即从“对抗均衡”角度看它最“健康”，但其生成质量（FID）却明显不如判别器一度占优的 DCGAN。这再次说明对抗 loss 的均衡程度并不等价于生成质量，必须借助 FID 这类样本级指标来评估。

## 6 隐变量扰动对生成结果的影响（重点）

### 6.1 分析方法

本文固定一组 100 维随机噪声向量（共 8 个样本），从中随机挑选 5 个维度；对每个被选维度，在其原值基础上施加 3 档不同的扰动量，其余维度保持不变，从而观察“仅改变单个随机数”时生成图像的变化。每个维度的 3 档扰动  $\times$  8 个样本构成一行组，5 个维度共得到  $15 \times 8$  张图像，如图 6.3 所示。




图 6.3: 三个模型的隐变量扰动分析（每图  $15 \times 8$ : 5 个维度  $\times$  每维 3 档扰动  $\times$  8 个固定样本）。

## 6.2 扰动现象与解释

[待填: 结合图 6.3 描述具体现象, 要点可包括:]

1. **单维扰动的整体性影响**: 观察同一列（同一基础噪声）在某一维度上的三档变化可以发现, [待填: 描述——如衣物的明暗、粗细/厚度、长短或在相近类别之间的渐变等]。这说明单个隐变量并不单独控制某个清晰可解释的语义属性。
2. **潜空间的纠缠性**: 与 StyleGAN 等具有解耦隐空间的模型不同, 原始 GAN/DCGAN 的隐空间是高度纠缠的——单个维度的语义并不独立, 改变一个维度往往同时引起多个视觉属性的整体性变化, 且不同样本上同一维度的作用方向也不一致。因此普通 GAN 上很难找到“某一维就是亮度、某一维就是袖长”这种清晰对应, 这是本任务中“随机数影响”现象偏整体、偏微妙的根本原因。
3. **扰动幅度与模型差异**: 扰动幅度较小时生成图几乎不变, 幅度增大时变化才逐渐显现; 同时 [待填: 对比三模型——如全连接模型对单维扰动通常更敏感、DCGAN 变化更平滑等]。

综合来看, 隐变量扰动实验说明: 在不加解耦约束的普通 GAN 中, 隐空间各维度与可见语义属性之间不是一一对应关系, 而是以纠缠方式共同决定生成结果; 要获得可解释、可独立操控的隐变量, 需要引入额外的解耦机制（如条件输入或风格解耦结构）, 这可作为后续改进方向。

## 7 实验结论

本文在 FashionMNIST 上实现并对比了原始全连接 GAN、加深全连接 GAN 与卷积版 DCGAN, 并以 FID 作为统一的质量评价指标。实验结果表明: (1) 三个模型呈现清晰的质量递进, DCGAN 的

FID 显著优于两种全连接 GAN，定量地体现了卷积结构对图像生成的关键作用；(2) 对抗 loss 的均衡程度并不等价于生成质量，FID 等样本级指标对 GAN 评估是必要的；(3) 训练轮数的影响因模型而异，DCGAN 从延长训练中获益明显，而容量受限的原始 GAN 延长训练并无帮助；(4) 普通 GAN 的隐空间高度纠缠，单个随机数的扰动以整体方式影响生成结果，难以对应到独立的语义属性。总体而言，本实验完整覆盖了作业要求的 loss 曲线、模型结构、固定噪声样例与隐变量扰动分析，并通过 FID 与多模型对比对 GAN 的训练与评估进行了较深入的探讨。

## Appendix A 代码目录说明

本实验代码位于 lab4/ 目录，核心文件如下：

- `train.py`: 单次训练入口；
- `sweep_lr.py`: 学习率扫描入口（按 FID 选最优学习率）；
- `src/models/`: 模型实现, 含 `gan.py` (原始与加深全连接 GAN)、`dcgan.py` (卷积版)、`registry.py` (统一构建与权重初始化)；
- `src/engine.py`: 训练/验证/测试主循环，含按 FID 选 checkpoint 的逻辑；
- `src/utils/fid.py`: 基于 Inception-V3 的 FID 评估器；
- `src/data.py`: FashionMNIST 数据加载与划分；
- `scripts/generate_report_assets.py`: 报告图表（固定噪声样例、隐变量扰动图、指标表）生成；
- `scripts/run_lab4_2gpu.sh`、`scripts/run_lab4_final200.sh`: 双卡总控与 200 轮最终训练脚本。

## 参考文献

- [1] Martin Heusel, Hubert Ramsauer, Thomas Unterthiner, Bernhard Nessler, and Sepp Hochreiter. Gans trained by a two time-scale update rule converge to a local nash equilibrium. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [2] Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *International Conference on Machine Learning (ICML)*, 2015.
- [3] Alec Radford, Luke Metz, and Soumith Chintala. Unsupervised representation learning with deep convolutional generative adversarial networks. In *International Conference on Learning Representations (ICLR)*, 2016.
- [4] Tim Salimans, Ian Goodfellow, Wojciech Zaremba, Vicki Cheung, Alec Radford, and Xi Chen. Improved techniques for training gans. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2016.