



南開大學  
Nankai University

计算机学院

深度学习及应用（高阶课）实验报告

显式对比，隐式收益：

中心-周边先验在小数据显著性检测中的价值与边界

题目：开放性题目二，显著性物体检测

组员：林晖鹏 陈培杰 金莫迪

学号：2312966 2312991 2312578

专业：计算机科学与技术 物联网工程

2026 年 6 月 30 日

# 目 录

|                             |    |
|-----------------------------|----|
| 摘要                          | 2  |
| 1 引言                        | 2  |
| 2 相关工作                      | 3  |
| 3 方法                        | 4  |
| 3.1 预备知识                    | 4  |
| 3.2 C3Net: 显式对比、上下文与线索      | 5  |
| 3.3 CA-ASPP: 对比感知多尺度空洞卷积    | 5  |
| 3.4 CSCM: 中心-周边对比调制         | 6  |
| 3.5 损失函数                    | 6  |
| 4 实验                        | 7  |
| 4.1 实验设置                    | 7  |
| 4.2 主对比                     | 7  |
| 4.3 消融研究                    | 8  |
| 4.3.1 模块消融                  | 8  |
| 4.3.2 CSCM 设计选择             | 9  |
| 4.4 跨数据集外部验证                | 10 |
| 4.4.1 跨数据集对比                | 10 |
| 4.4.2 外部消融                  | 10 |
| 4.4.3 多阶段对比                 | 10 |
| 4.5 对比先验分析                  | 11 |
| 4.5.1 对比先验的增益随训练数据减少而增大     | 11 |
| 4.5.2 增益来自对比先验本身而非额外参数      | 12 |
| 4.5.3 无参数对比门控对齐于物体边界        | 13 |
| 4.5.4 对比先验在低对比伪装目标上失效       | 13 |
| 4.6 进一步分析                   | 13 |
| 4.6.1 测试时增强                 | 13 |
| 4.6.2 CA-ASPP 的可视化分析        | 14 |
| 4.6.3 CSCM 的可视化分析           | 15 |
| 4.6.4 未取得稳定收益的探索            | 15 |
| 4.6.5 定性对比                  | 17 |
| 5 讨论                        | 17 |
| 6 结论                        | 19 |
| A CTD-lite 结构细节             | 19 |
| B 其他探索实验: 不确定性-Zoom 的残差塌缩分析 | 20 |
| C AI 使用说明                   | 21 |

## 摘要

显著性物体检测 (SOD) 在小数据条件下面临一个核心问题: 现代表征学习框架通常依赖从数据中隐式学习显著性线索, 却较少显式建模显著性的物理来源。为此, 本文提出 C3Net, 一个以显式中心-周边对比建模为核心、并融合上下文与边界线索的轻量级显著性检测网络。上下文分支利用 CA-ASPP 聚合高层多尺度上下文信息, 并强化目标与环境之间的对比信号。线索分支通过边缘分支和多级深监督强化边界恢复与尺度一致性。核心的 CSCM (Center-Surround Contrast Modulation) 则通过多尺度中心-周边差分显式计算局部对比响应, 并将其转化为对解码特征的空间调制信号。实验表明, 我们的模型在 ECSSD 上相较其他主流方法取得了最优的综合结果, 并在 DUTS-TE 与 DUT-OMRON 上表现出更稳定的跨数据集泛化能力。进一步的数据效率、外部验证与 CAMO 反例分析表明, 模型增益主要来自对比先验本身, 而不仅仅是额外的模型容量。整体来看, 本文说明, 将契合任务本质的视觉先验以显式、可微的方式注入网络, 是在有限数据条件下提升 SOD 性能的一条有效路径。本文代码已开源, 获取地址: <https://gitee.com/absurdaaa/deep-learning>

**关键词:** 显著性物体检测; 中心-周边对比; 归纳偏置; 数据效率

## 1 引言

显著性物体检测 (Salient Object Detection, SOD) 旨在为图像中每个像素估计其属于视觉上最突出物体的概率, 输出一张与输入同分辨率的显著图。作为一项基础的中层视觉任务, 它将显著前景从背景中分离, 为图像分割、目标检索、智能裁剪与图像编辑等下游应用提供前景先验。如何在有限标注下学到既准确又可泛化的显著性表示, 一直是该领域的核心问题。

现代 SOD 方法几乎都建立在全卷积的编码器-解码器范式之上, 并围绕多级特征的聚合发展出各类模块: PoolNet[14] 注入金字塔全局上下文, EGN[27] 引入边缘引导, F3Net[22] 提出结构损失与特征反馈, DSS[8] 以短连接做深监督, PFAN[29] 采用金字塔特征注意力, CTDNet[30] 设计语义、空间与边界三路互补解码。尽管思路各异, 这些方法都让网络从数据中隐式地学习哪些区域是显著的, 而显著性的物理来源并未作为先验被显式注入网络。在训练数据充足时这一策略通常可行, 但在小数据设定下, 例如本工作所用的 ECSSD[18] 仅含 700 张训练图像, 依赖网络从少量样本中自行发现本可由先验编码的规律, 可能降低样本利用效率。

事实上, 认知科学与早期视觉显著性研究早已表明, 显著性的一个根本来源是中心-周边对比: 一个区域之所以突出, 往往因为它与周围邻域在亮度、颜色或纹理上形成强烈反差。Itti 与 Koch[10] 以中心-周边差 (Difference-of-Gaussians) 建模显著性, Cheng 等 [5] 提出基于全局对比的区域显著性, 神经科学中的除性归一化 [2] 同样刻画了局部对比的规范计算。受此启发, 本文主张将这一对比先验以可微模块的形式显式编码进网络, 而非依赖网络从少量样本中隐式地重新发现它。在小数据配合强预训练骨干的条件下, 契合任务结构的归纳偏置可以作为额外约束, 辅助模型学习数据中难以充分估计的规律。

基于这一思路, 我们提出 C3Net, 一个以中心-周边对比为核心的显著性检测网络。其核心模块 CSCM 通过多尺度中心-周边差分显式计算局部对比响应, 并将其转化为空间调制信号以增强解码特征; 同时, CA-ASPP 在高层语义特征中聚合多尺度上下文信息并校准目标-环境对比, 边缘分支与多级深监督则进一步补充边界和尺度线索。围绕这一先验是否有效、增益从何而来、其作用边界何在, 我们在 ECSSD 与 DUTS-TE、DUT-OMRON 上展开系统的实验与分析; 由于 ECSSD 测试集仅 300 张、单数据集指标处于噪声量级, 我们以更大的外部集作为主要判据。

本文的主要贡献如下:

- 我们把中心-周边对比这一经典先验以可微模块 CSCM 显式编码，并据此构建 C3Net，使对比由需要隐式学习的规律变为网络内置的归纳偏置。
- 我们设计了 CA-ASPP 模块，在高层语义特征中聚合多尺度上下文信息，并通过空间校准增强目标-环境对比表达。
- 我们刻画了该先验的作用机理：其增益随训练数据减少而增大，依赖于对比这一信号（在低对比的伪装目标 CAMO[12] 上失效），且其无参数形式对齐于物体的对比边界。
- 我们表明，将对比贯穿编码器多阶段施加，可在两个外部数据集(DUTS-TE[20]、DUT-OMRON[25])上一致地改善跨数据集泛化。

## 2 相关工作

**从手工特征到基础模型。**显著性检测的研究大致经历了从手工特征到深度模型、再到大规模基础模型的演进。早期方法依赖手工特征与启发式先验，例如 Itti 与 Koch[10] 的中心-周边差、Achanti 等 [1] 的频率调谐显著性、Cheng 等 [5] 的全局对比，以及基于图与流形排序的方法 [25]；它们在简单场景下有效，但因缺乏语义而难以应对复杂背景。2015 年前后，卷积神经网络被引入该任务，LEGS[19]、MDF[13] 与 MCDL[28] 以区域或超像素为单位提取深度特征，显著超越传统方法；随后全卷积网络推动了端到端、逐像素的预测，代表工作有 DHSNet[15]、NLDF[17]、Amulet[26] 与 DSS[8]。近年来，纯 Transformer 架构（如 VST[16]）以序列建模捕捉长程依赖，而以 SAM[11] 为代表的大规模分割基础模型进一步带来了强大的零样本分割能力，并已被适配到显著性检测 [7]。然而，这些基础模型依赖海量训练数据与显式提示，在小数据、轻量骨干的设定下并不适用；因此，适用于该任务结构的归纳偏置在这一设定中具有研究价值。深度时代 SOD 的全貌可参考 Wang 等 [21] 的综述。

**基于 CNN 的显著性检测。**在深度学习时代，大量工作围绕如何更好地聚合多级卷积特征展开。上下文建模方面，PoolNet[14] 以金字塔池化注入全局上下文，PFAN[29] 引入金字塔特征注意力；边界建模方面，EGNet[27] 显式引入边缘引导，CTDNet[30] 设计语义、空间与边界三路互补解码；监督与损失方面，DSS[8] 以短连接做深监督，F3Net[22] 提出结构损失与特征反馈，LDF[23] 将物体主体与边界细节解耦监督。这些方法从不同角度改进了特征聚合、边界建模或监督方式，但大多主要依赖网络从数据中隐式学习显著性线索，鲜有将显著性的物理来源即局部对比作为显式先验注入。本文以这些上下文、边界与深监督线索为辅助，而以显式的对比建模为核心。

**对比先验与显著性。**一部分文献将显著性归因于中心-周边对比。Itti 与 Koch[10] 以中心-周边差建模视觉显著性，Cheng 等 [5] 提出基于全局对比的区域显著性，神经科学中的除性归一化 [2] 则刻画了局部对比的规范计算。这些方法多处于深度学习之前，对比以固定算子的形式出现。本文将这一经典先验重新引入现代 CNN，但以可微、可学习的模块实现，使其既保留对比的归纳偏置，又能与深度特征端到端协同。

**伪装物体检测。**与 SOD 相反，伪装物体检测 (COD) [6, 12] 关注那些与背景融为一体、呈现低对比的物体。这一相反的任务设定，为检验我们的对比先验是否真正依赖对比提供了天然的负对照：若 CSCM 确实是一种对比机制，它理应在高对比的 SOD 上有益，而在低对比的伪装物体上失效。我们在第 7 节用 CAMO 数据集验证了这一推断。

**注意力与特征调制。**通道与空间注意力是增强卷积特征的常用手段，例如 SE[9] 与 CBAM[24] 通过学习得到的权重对特征逐通道或逐位置地重标定。CSCM 在形式上也是一种空间注意力门控，但它的注意力是由显式的多尺度中心-周边对比导出。因此，本文通过对比先验约束注意力来源，使其聚焦于物体与背景的高对比边界，而非任意可学习的模式；第 7 节的可解释性分析进一步印证了这一点。



### 3 方法




图 3.1: C3Net 整体网络架构。网络包含基于 ResNet-18 的主干编码器、提取全局上下文的 CA-ASPP 模块、由解码块 (DB) 和中心-外围上下文模块 (CSCM) 组成的级联解码器，以及包含边缘特征与多尺度特征的深度监督分支。

#### 3.1 预备知识

本节简要介绍基于 ResNet-18 的特征金字塔网络骨干。给定输入图像  $I \in \mathbb{R}^{H \times W \times 3}$ ，采用 ResNet-18 作为编码器提取多层次特征表示。网络由多个残差阶段组成，输出一组分层特征：

$$\{C_0, C_1, C_2, C_3, C_4\} = \mathcal{E}(I), \quad (1)$$

其中  $C_0$  表示浅层特征， $C_4$  表示高层语义特征。

在特征金字塔结构中，通过自顶向下的逐层融合过程构建多尺度特征表示：

$$P_l = \phi_l(\text{Concat}[\text{Up}(P_{l+1}), C_l]), \quad (2)$$

其中  $\text{Up}(\cdot)$  表示双线性上采样,  $\text{Concat}[\cdot]$  表示通道融合,  $\phi_l(\cdot)$  表示卷积变换。该主干能够逐层融合高层语义信息与低层细节信息, 从而获得兼具语义表达能力与空间分辨率的多尺度特征表示。

### 3.2 C3Net: 显式对比、上下文与线索

本文提出的对比-上下文-线索网络 (Contrast-Context-Cue Network, C3Net) 旨在通过显式引入局部对比度先验和丰富的全局/边缘线索, 实现高精度的显著性目标检测。图 3.1 展示了其框架, C3Net 采用了经典的特征金字塔 (FPN) 架构, 整体网络包含编码器 (特征提取)、顶层上下文建模、自顶向下的级联解码以及多任务深度监督四个主要阶段。

给定输入图像  $\mathbf{I} \in \mathbb{R}^{3 \times H \times W}$ , 我们采用 ResNet 作为主干网络进行多尺度特征提取。编码器得到特征输出  $\mathcal{E}(\mathbf{I})$ 。为了获取具有强语义表示的全局感受野, 我们将顶层特征  $c_4$  送入 CA-ASPP 模块, 生成融合了多尺度全局信息的上下文特征  $t = \text{CA-ASPP}(c_4)$ 。

在解码阶段, 网络通过解码块逐步融合自顶向下的高级语义特征与来自编码器的同尺度侧边特征。首先, 最高层的解码输出  $d_3 = \text{DB}(t, c_3)$ 。对于后续的解码层  $i \in \{2, 1, 0\}$ , 网络首先通过解码块融合相邻特征, 将其输入至 CSCM 模块中对特征进行显著性增强。级联解码过程可表示为:

$$d_i = \text{CSCM}(\text{DB}(d_{i+1}, c_i),), \quad i \in 2, 1, 0 \quad (3)$$

### 3.3 CA-ASPP: 对比感知多尺度空洞卷积

在上下文分支中, 受显著性检测中心-周围对比先验的启发, 本文设计了对比感知空洞空间金字塔池化模块 (Contrast-aware Atrous Spatial Pyramid Pooling, CA-ASPP)。该模块借鉴 DeepLab 系列中 ASPP 的多尺度空洞卷积思想 [3, 4], 在并行空洞卷积分支与图像级池化分支的基础上, 引入可学习的空间门控分支, 对高层上下文响应进行自适应重标定, 从而增强目标区域与周围背景之间的对比表达。

对于多尺度上下文分支, 给定输入特征  $\mathbf{X} \in \mathbb{R}^{C \times H \times W}$ , 首先采用空洞率集合  $\mathcal{D} = \{1, 3, 5, 7\}$  的并行卷积分支提取局部多尺度特征  $\mathbf{B}_d = \phi(\text{Conv}_{k_d \times k_d}^d(\mathbf{X}))$  与全局平均池化提取的图像级特征  $\mathbf{B}_g = \text{AvgPool}(\mathbf{X})$  进行拼接, 经非线性映射融合为上下文特征  $\mathbf{C} \in \mathbb{R}^{C_o \times H \times W}$ :

$$\mathbf{C} = \phi(\text{Conv}(\text{Concat}[\mathbf{B}_1, \mathbf{B}_3, \mathbf{B}_5, \mathbf{B}_7, \mathbf{B}_g])) \quad (4)$$

为进一步突出目标与背景的空间对比, 引入轻量级门控分支。将映射后的输入特征  $\mathbf{P} = \phi(\text{Conv}_{1 \times 1}(\mathbf{X}))$  与  $\mathbf{C}$  拼接, 经门控网络  $\mathcal{G}$  和 Sigmoid 函数  $\sigma$  生成对比感知权重  $\mathbf{A} \in [0, 1]^{1 \times H \times W}$ , 以自适应定位判别性区域:

$$\mathbf{A} = \sigma(\mathcal{G}(\text{Concat}[\mathbf{P}, \mathbf{C}])) \quad (5)$$

最终, 采用残差式增强策略重标定上下文特征:

$$\mathbf{Y} = \mathbf{C} \odot (1 + \mathbf{A}) \quad (6)$$

其中,  $\odot$  表示逐元素乘法。与普通注意力增强不同, CA-ASPP 的门控机制对空间位置进行自适应重标定, 增强目标-环境之间的对比信号。这种强化后的高层对比信号能够为解码器中的 CSCM 模块提供更加明确的语义先验。其作用机制将在第 4.6.2 节的可视化分析中进一步说明。

### 3.4 CSCM: 中心-周边对比调制

为了更有效地提取图像中的显著性特征, 本文设计了中心-外围上下文模块 (Center-Surround Context Module, CSCM)。与依赖解码器隐式学习局部对比度特征的方法不同, CSCM 显式地计算多尺度的局部中心-外围对比度特征作为显著性先验, 从而增强模型对边界和模糊区域的感知能力。

给定输入特征图  $\mathbf{F} \in \mathbb{R}^{C \times H \times W}$ , 我们首先定义一个包含多个不同半径大小的尺度集合  $\mathcal{R} = \{r_i\}, i \in [1, K]$ , 对于集合中的任意尺度  $r_k \in \mathcal{R}$ , 我们通过平均池化操作提取局部外围的上下文响应  $\mathbf{S}_k$ , 并计算输入特征图与其对应外围响应的差异。对于给定的  $r_k$ , 其中心-外围对比响应  $\mathbf{D}_k$  定义为:

$$\mathbf{D}_k = \mathbf{F} - \text{AvgPool}_{r_k}(\mathbf{F}) \quad (7)$$

随后, 我们将所有尺度下的对比响应特征在通道维度上进行拼接, 得到  $\mathbf{D}_{cat} = [\mathbf{D}_1; \mathbf{D}_2; \dots; \mathbf{D}_K] \in \mathbb{R}^{(K \times C) \times H \times W}$ 。为了将这些多尺度的对比度信息转化为空间调制信号, 我们将  $\mathbf{D}_{cat}$  送入一个轻量级的注意力映射网络。该网络包含  $3 \times 3$  卷积、批归一化、ReLU 激活函数以及用于降维的  $1 \times 1$  卷积, 最终输出单通道的空间注意力逻辑图  $\mathbf{A} \in \mathbb{R}^{1 \times H \times W}$ 。

接下来由输入特征  $\mathbf{F}$  生成粗略显著性预测图  $\mathbf{P}_{coarse}$ , 并据此计算像素级的不确定性图  $\mathbf{G}$ 。该不确定性图用于突出模型难以判别的模糊或边界区域:

$$\mathbf{G} = \mathbf{1} - 2|\mathbf{P}_{coarse} - 0.5| \quad (8)$$

其中,  $\mathbf{P}_{coarse} = \sigma(\text{Conv}(\mathbf{F}))$ ,  $\sigma$  为 Sigmoid 激活函数。

将经过 Sigmoid 函数  $\sigma(\cdot)$  激活的空间注意力图与不确定性图  $\mathbf{G}$  进行逐元素相乘, 得到被限制在不确定区域的门控掩码注意力  $\mathbf{A}_{gate}$ :

$$\mathbf{A}_{gate} = \sigma(\mathbf{A}) \odot \mathbf{G} \quad (9)$$

最终, 我们采用残差门控的形式, 将计算得到的空间对比度注意力作用于原始输入特征图  $\mathbf{F}$ 。通过引入调节强度超参数  $\gamma$ , CSCM 模块的最终输出  $\mathbf{F}_{out}$  计算如下:

$$\mathbf{F}_{out} = \mathbf{F} \odot (\mathbf{1} + \gamma \cdot \mathbf{A}_{gate}) \quad (10)$$

其中,  $\odot$  表示哈达玛积,  $\mathbf{1}$  为与输入特征图尺寸相同的全 1 矩阵。这种残差门控设计既能保证原始特征的主体信息不被破坏, 又能有效地在局部特征突变或显著性边缘区域对其响应进行特异性的增强。

### 3.5 损失函数

为提升显著性预测的结构一致性与边界细节表达能力, C3Net 采用了多分支深度监督与边缘约束的联合优化策略。模型以加权二元交叉熵损失  $\mathcal{L}_{wbce}$  作为主要的像素级监督信号。

具体而言, 给定输入图像  $\mathbf{X}$  和真实标签图  $\mathbf{Y}$ , 网络模型  $f_\theta$  输出预测概率图  $\mathbf{P} = f_\theta(\mathbf{X})$ 。  $p_{i,j}$  表示像素  $(i, j)$  属于前景区域的预测概率,  $y_{i,j}$  表示对应的真实标签值。为避免符号混淆, 记  $\mathcal{Y}_{i,j}$  为像素  $(i, j)$  对应的标签随机变量。局部边缘感知权重图  $\mathbf{w}$  通过对真实标签进行平均池化生成, 旨在对结构不连续或难以预测的边界区域赋予更大的惩罚权重。

因此, 加权二元交叉熵损失  $\mathcal{L}_{wbce}$  可写为像素级条件分布的负对数似然:

$$\mathcal{L}_{wbce}(\mathbf{P}, \mathbf{Y}) = - \sum_{i,j} w_{i,j} \left[ y_{i,j} \log p_{i,j} + (1 - y_{i,j}) \log(1 - p_{i,j}) \right]. \quad (11)$$

为了在不同语义层级上实现一致性优化，我们将  $\mathcal{L}_{wbce}$  应用于网络的多个输出分支。最终预测分支的损失为：

$$\mathcal{L}_{final} = \mathcal{L}_{wbce}(\mathbf{P}_{final}, \mathbf{Y}). \quad (12)$$

粗粒度预测分支和侧输出分支的损失分别定义为：

$$\mathcal{L}_{coarse} = \mathcal{L}_{wbce}(\mathbf{P}_{coarse}, \mathbf{Y}), \quad \mathcal{L}_{side} = \sum_{k=1}^3 \mathcal{L}_{wbce}(\mathbf{P}_{side}^{(k)}, \mathbf{Y}). \quad (13)$$

此外，为了显式增强模型对目标轮廓的敏感度，构建边缘预测分支。利用 Sobel 算子从真实标签中提取边缘监督信号  $\mathbf{Y}_{edge} = \text{Sobel}(\mathbf{Y})$ 。令  $\mathbf{P}_{edge}$  表示边缘预测概率图， $p_{i,j}^{edge}$  表示像素  $(i, j)$  属于边缘区域的预测概率， $y_{i,j}^{edge}$  表示对应的边缘标签值。记  $\mathcal{Y}_{i,j}^{edge}$  为像素  $(i, j)$  对应的边缘标签随机变量。

因此，边缘损失定义为：

$$\mathcal{L}_{edge} = - \sum_{i,j} \left[ y_{i,j}^{edge} \log p_{i,j}^{edge} + (1 - y_{i,j}^{edge}) \log(1 - p_{i,j}^{edge}) \right]. \quad (14)$$

最终优化目标为：

$$\mathcal{L}_{total} = \mathcal{L}_{final} + \lambda_c \mathcal{L}_{coarse} + \lambda_s \mathcal{L}_{side} + \lambda_e \mathcal{L}_{edge}. \quad (15)$$

## 4 实验

### 4.1 实验设置

**数据：**ECSSD[18] 共 1000 张，按 seed 42 划分 700 train / 300 test，训练内部再分 600 train / 100 val。外部集为 DUTS-TE[20] (5019 张) 与 DUT-OMRON[25] (5168 张)，伪装目标集为 CAMO[12] 测试集 (250 张)。**训练：**输入  $352 \times 352$ ，batch 16，AdamW，lr  $3 \times 10^{-4}$ ，余弦退火，梯度裁剪 1.0；主实验与消融训练 200 epoch，数据效率实验训练 60 epoch；按验证集 max-F 选取最优权重。**指标：**max-F（主指标）、MAE、S-measure、E-measure、IoU。**统一协议：**除特别说明外，所有结果均为单尺度 max-F；标注 3-seed 者为 seed 42/3407/2026 三个 train/val 划分的均值，其余为 seed 42 的单次结果；外部集上 max-F 的随机噪声约为 0.004。各表的训练与评测协议在其标题中注明。

### 4.2 主对比

表 4.1 给出了 ECSSD 测试集上所有方法的性能。所有模型均以 ResNet-18 为编码器、在相同的 700/300 划分上以最优学习率训练，评测采用单尺度 max-F。我们同时报告了主要的参考指标 max-F 与 MAE，以及辅助的 S-measure、E-measure 和 IoU。每个指标取 3 个随机种子的均值与标准差，以反映统计上的散布程度。在这一比较下，C3Net 的 max-F (0.9130) 和 IoU (0.8393) 均最高，MAE (0.0344) 最低，表明其整体预测质量优于所列的对比方法。

如图4.2所示，本文在三类典型场景下对不同方法进行了可视化对比，包括普通样例、困难样例以及小目标显著性样例。在普通场景中，各方法均能较好地定位显著区域，但传统方法（如 DSS[8]、F3Net[22]）在边界细节上仍存在一定模糊，而本文方法（C3Net 与 CTD-lite）能够生成结构更完整、边界更清晰的预测结果。在困难场景（如复杂背景与强干扰）下，部分对比方法出现显著误检或区域断裂现象，例如 PoolNet[14] 与 EGNNet[27] 对背景纹理较为敏感，容易引入噪声响应；相比之下，本文方法在抑制背景干扰方面表现更稳定，能够保持目标区域的一致性。在小目标显著性场景中，多数

| 方法                  | max-F $\uparrow$                      | MAE $\downarrow$                      | S-m $\uparrow$                        | E-m $\uparrow$      | IoU $\uparrow$                        |
|---------------------|---------------------------------------|---------------------------------------|---------------------------------------|---------------------|---------------------------------------|
| Base (R18+FPN)      | 0.9068 $\pm$ 0.0037                   | 0.0355 $\pm$ 0.0025                   | 0.9084 $\pm$ 0.0030                   | 0.9437 $\pm$ 0.0048 | 0.8355 $\pm$ 0.0043                   |
| DSS-R18[8]          | 0.8815 $\pm$ 0.0044                   | 0.0445 $\pm$ 0.0013                   | 0.8873 $\pm$ 0.0042                   | 0.9304 $\pm$ 0.0011 | 0.7932 $\pm$ 0.0062                   |
| F3Net-R18[22]       | 0.8996 $\pm$ 0.0031                   | 0.0368 $\pm$ 0.0016                   | 0.9000 $\pm$ 0.0025                   | 0.9380 $\pm$ 0.0028 | 0.8242 $\pm$ 0.0055                   |
| EGNet-R18[27]       | 0.9048 $\pm$ 0.0091                   | 0.0403 $\pm$ 0.0057                   | 0.9066 $\pm$ 0.0050                   | 0.9374 $\pm$ 0.0089 | 0.8250 $\pm$ 0.0137                   |
| SINet-R18[6]        | 0.9053 $\pm$ 0.0019                   | 0.0365 $\pm$ 0.0010                   | 0.9062 $\pm$ 0.0006                   | 0.9473 $\pm$ 0.0004 | 0.8259 $\pm$ 0.0035                   |
| PFA-R18[29]         | 0.9063 $\pm$ 0.0037                   | 0.0382 $\pm$ 0.0033                   | 0.9046 $\pm$ 0.0041                   | 0.9373 $\pm$ 0.0069 | 0.8261 $\pm$ 0.0071                   |
| PoolNet-R18[14]     | 0.9071 $\pm$ 0.0015                   | 0.0352 $\pm$ 0.0020                   | 0.9069 $\pm$ 0.0016                   | 0.9427 $\pm$ 0.0033 | 0.8344 $\pm$ 0.0042                   |
| <b>C3Net (ours)</b> | <b>0.9130 <math>\pm</math> 0.0004</b> | <b>0.0344 <math>\pm</math> 0.0024</b> | <b>0.9090 <math>\pm</math> 0.0033</b> | 0.9424 $\pm$ 0.0060 | <b>0.8393 <math>\pm</math> 0.0053</b> |

表 4.1: 主对比 (ECSSD, 3-seed 均值  $\pm$  标准差, e200, 单尺度)。所有方法统一最优学习率, 在相同 700/300 划分上训练与评测。

方法存在目标遗漏或响应弱化问题, 而本文方法仍能较完整地保持目标响应, 体现出更强的细粒度建模能力与鲁棒性。




图 4.2: 本文方法与现有前沿方法在复杂场景下的定性可视化对比。图中各列从左至右依次为: 输入原图 (Input)、真值掩膜 (GT)、R18、PoolNet、PFA、EGNet、SINet、DSS[8]、F3Net[22], 以及本文方法 (C3Net 与 CTD-lite)。

如图4.3所示, 随着模型复杂度增加, 部分方法 (如 EGNet[27]) 能够获得较高的性能上限, 但代价是显著的参数开销; 而轻量级方法 (如 DSS[8]) 虽然计算成本较低, 但整体精度与稳定性均受到明显限制。相比之下, 本文提出的 C3Net 在较小参数预算下展现出更优的综合性能, 不仅在 F-measure 上超过多种参数规模更大的方法 (如 PoolNet[14] 与 EGNet[27]), 同时在多次随机实验中保持更低的波动, 体现出更强的鲁棒性与有效性。CTD-lite 在进一步压缩参数的同时仍保持具有竞争力的性能表现。




图 4.3: F-measure 随参数数量变化的对比结果。气泡大小表示三次随机实验的标准差。

### 4.3 消融研究

#### 4.3.1 模块消融

如表 4.2所示, 为验证各模块对整体性能的贡献, 我们采用留一消融策略, 在保持其余结构与训练设置不变的情况下, 分别移除 CA-ASPP、边缘分支、深监督以及 CSCM 模块, 并在 ECSSD 上进行三随机种子评测。实验结果表明, 完整模型在 Max-F 和 MAE 上取得最优表现, 分别为  $0.9130 \pm 0.0004$



和  $0.0344 \pm 0.0024$ ，任一模块的移除均会导致不同程度的性能下降，其中以 CSCM 与 CA-ASPP 的影响最为显著，说明显式对比建模与边界约束以及对高层上下文特征进行校准对性能提升起到关键作用，而深监督则主要在全局语义与训练稳定性方面提供辅助增益，整体验证了各组件之间的互补性与协同优化效果。

| Configuration   | max-F $\uparrow$                      | MAE $\downarrow$                      | IoU $\uparrow$                        |
|-----------------|---------------------------------------|---------------------------------------|---------------------------------------|
| C3Net           | <b><math>0.9130 \pm 0.0004</math></b> | <b><math>0.0344 \pm 0.0024</math></b> | $0.8393 \pm 0.0053$                   |
| w/o CSCM        | $0.9096 \pm 0.0022$                   | $0.1156 \pm 0.0015$                   | $0.8389 \pm 0.0022$                   |
| w/o Deep Sup.   | $0.9126 \pm 0.0004$                   | $0.0358 \pm 0.0005$                   | <b><math>0.8427 \pm 0.0006</math></b> |
| w/o Edge Branch | $0.9087 \pm 0.0042$                   | $0.0432 \pm 0.0027$                   | $0.8383 \pm 0.0087$                   |
| w/o CA-ASPP     | $0.9029 \pm 0.0039$                   | $0.0366 \pm 0.0032$                   | $0.8311 \pm 0.0047$                   |

表 4.2: 模块消融 (3-seed 均值  $\pm$  标准差, e200, 单尺度); 删除任一模块均导致降低, 四模块均有正的边际贡献。

如表4.3所示, 在 ECSSD 的内部累积消融中, 单独加入 CA-ASPP 后 max-F 明显提升; 继续加入深监督与边缘分支时, 受小数据集波动影响, max-F 与 MAE 出现一定起伏; 最终加入 CSCM 后, 完整模型在 Max-F 和 MAE 指标上恢复到该链条的最优水平, 说明对比调制仍是整条 C3Net 链的关键增益来源。

| 配置            | max-F $\uparrow$                      | MAE $\downarrow$                      | IoU $\uparrow$                        |
|---------------|---------------------------------------|---------------------------------------|---------------------------------------|
| Base          | $0.9051 \pm 0.0038$                   | $0.1120 \pm 0.0105$                   | $0.8312 \pm 0.0022$                   |
| + CA-ASPP     | $0.9121 \pm 0.0024$                   | $0.0917 \pm 0.0670$                   | <b><math>0.8417 \pm 0.0052</math></b> |
| + Deep Sup.   | $0.9104 \pm 0.0056$                   | $0.1517 \pm 0.1270$                   | $0.8351 \pm 0.0138$                   |
| + Edge Branch | $0.9099 \pm 0.0004$                   | $0.1297 \pm 0.0476$                   | $0.8389 \pm 0.0017$                   |
| + CSCM (完整)   | <b><math>0.9130 \pm 0.0004</math></b> | <b><math>0.0344 \pm 0.0024</math></b> | $0.8411 \pm 0.0028$                   |

表 4.3: C3Net 在 ECSSD 上的内部累积消融结果 (e200, 3-seed 均值  $\pm$  标准差)。

#### 4.3.2 CSCM 设计选择

为了确定 CSCM 中最关键的设计决策, 我们对对比响应函数、多尺度策略和门控形式分别做消融。表 4.4 按性能降序列出各设计变体在 ECSSD 上的 3-seed 均值与标准差。

| Contrast Formulation       | max-F                                 | MAE                                   |
|----------------------------|---------------------------------------|---------------------------------------|
| diff (default)             | <b><math>0.9130 \pm 0.0004</math></b> | <b><math>0.0344 \pm 0.0024</math></b> |
| CSCM only on Base          | $0.9042 \pm 0.0038$                   | $0.0375 \pm 0.0058$                   |
| Single scale $r=7$         | $0.9024 \pm 0.0012$                   | $0.0361 \pm 0.0027$                   |
| Gating only (w/o contrast) | $0.8996 \pm 0.0007$                   | $0.0460 \pm 0.0157$                   |
| Norm (local z-score)       | $0.8656 \pm 0.0494$                   | $0.1281 \pm 0.1256$                   |

表 4.4: CSCM 设计选择 (3-seed 均值  $\pm$  标准差, e200, 单尺度)。

中心-周边差分 (diff) 在所有指标上均最优。将 CSCM 单独施加在 Base 上 (不含 CA-ASPP 与边缘、深监督线索) 时增益有限, 再次说明模块需协同。单尺度  $r=7$  不及多尺度  $\{3, 7, 11\}$ , 说明多尺度对适配不同物体尺寸是必要的。纯门控 (Gating only, 不按对比计算  $A$ , 仅保留残差门控形式  $f' = f \cdot (1 + \gamma A)$ ) 的 MAE 明显变差, 说明门控中的信息必须来自对比特征。除性归一化 (Norm) 在小数据下极不稳定 (标准差 0.0494, 在各个随机种子上波动巨大), 远不及简单的差分, 说明在有限数据下, 直接的差分式对比建模更稳定。

## 4.4 跨数据集外部验证

### 4.4.1 跨数据集对比

为了检验各方法在独立于训练分布上的泛化能力，我们将所有模型直接在两个大规模外部测试集上进行评测：DUTS-TE (5019 张) 和 DUT-OMRON (5168 张)。与 ECSSD 仅 300 张测试图像不同，这两个大型数据集可以给出统计上更可靠的排序，它们收集自不同的来源、涵盖更丰富的场景。在此评测中，ECSSD 上所有模型均使用其最优权重，外部评测不加微调，且均采用单尺度。

| Method       | ECSSD         | DUTS-TE       | DUT-OMRON     | $\Delta$ DUTS  | $\Delta$ OMRON |
|--------------|---------------|---------------|---------------|----------------|----------------|
| Base         | 0.9068        | 0.7659        | 0.7068        | —              | —              |
| PoolNet-R18  | 0.9071        | 0.7804        | 0.6908        | +0.0145        | -0.0160        |
| PFA-R18      | 0.9063        | 0.7913        | 0.7147        | +0.0254        | +0.0079        |
| SINet-R18    | 0.9053        | 0.7725        | 0.7116        | +0.0066        | +0.0048        |
| EGNet-R18    | 0.9048        | <b>0.7992</b> | <b>0.7266</b> | <b>+0.0333</b> | <b>+0.0198</b> |
| F3Net-R18    | 0.8996        | 0.7648        | 0.6939        | -0.0011        | -0.0129        |
| DSS-R18      | 0.8815        | 0.7441        | 0.6803        | -0.0218        | -0.0265        |
| C3Net (ours) | <b>0.9130</b> | 0.7890        | 0.7124        | +0.0231        | +0.0056        |

表 4.5: 跨方法与双外部集对比（单尺度 max-F）。 $\Delta$  为相对 Base 的增益，粗体标记各列最优值。

由表 4.5 可得两点观察。第一，多数方法在两个外部集上都超过 base（正的  $\Delta$ DUTS），说明各自的改进整体可泛化；个别方法（F3Net、DSS 和 PoolNet 的 OMRON）在外部集上低于 base，进一步说明泛化并非自动成立、需要验证。第二，ECSSD 排名无法完全迁移到外部集：更新后的 C3Net 在 ECSSD 仍居首，但在 DUTS-TE 上 EGNet 与 PFA 的  $\Delta$ DUTS 仍分别高出约 +0.010 和 +0.002，说明小测试集排名依然需要更大外部集来校验。

### 4.4.2 外部消融

表4.6展示了我们外部消融实验的结果，在 C3Net 链上，CA-ASPP 带来明显的单步性能提升，加入深监督与边缘分支后在 ECSSD 上略有下降，但最后加入 CSCM 模块后，达到最优性能，说明 CSCM 模块能够协调各模块之间的工作。完整模型在三套数据上的 max-F 仍全部最高；这说明外部集上的稳定提升主要来自整条链的协同，尤其是最后加入的 CSCM。

| 链条类型    | 配置            | ECSSD max-F   | DUTS-TE max-F | DUT-OMRON max-F |
|---------|---------------|---------------|---------------|-----------------|
| C3Net 链 | Base          | 0.9051        | 0.7867        | 0.7033          |
|         | + CA-ASPP     | 0.9121 ↑      | 0.7918 ↑      | 0.7159 ↑        |
|         | + Deep Sup.   | 0.9104 ↓      | 0.7872 ↓      | 0.7148 ↓        |
|         | + Edge Branch | 0.9099 ↓      | 0.7875 ↑      | 0.7162 ↑        |
|         | + CSCM (完整)   | <b>0.9130</b> | <b>0.7930</b> | <b>0.7206</b>   |

表 4.6: C3Net 链的外部消融。CTD-lite 的消融结果见附录 A。

### 4.4.3 多阶段对比

原始 C3Net 仅在解码器的三个层级（s8、s4、s2 分辨率，即 decode2/decode1/decode0）中插入了 CSCM 模块。为进一步评估 CSCM 的扩展方式，我们探索将其扩展到编解码器的更多阶段，使其从解码器局部附加优化为跨阶段对比机制。

具体而言，我们考察两种扩展位置：

- **Skip**: 在编码器到解码器的侧边跳跃连接（lateral skip connections）上增加 CSCM，即对  $c_3$ 、 $c_2$ 、 $c_1$ 、 $c_0$  在进入解码器前进行中心-周边对比调制；

- $s_{16}$ : 在原始 C3Net 中唯一未放置 CSCM 的最高解码层级  $d_3$  ( $s_{16}$  分辨率) 增加 CSCM, 使对比调制覆盖所有解码阶段。

表 4.7 对比了上述三种多阶段对比配置的相对表现。所有配置均以 3 个随机种子(seed 42/3407/2026) 在完整 ECSSD 上训练 (e200), 以同协议下重新训练的原始完整模型 `full_ref` 为基准, 对双外部集进行单尺度评测。

| 配置                                        | ECSSD  | DUTS-TE       | DUT-OMRON     | $\Delta$ DUTS  | $\Delta$ OMRON |
|-------------------------------------------|--------|---------------|---------------|----------------|----------------|
| <code>full_ref</code> (原始 C3Net 基准)       | 0.8978 | 0.7565        | 0.6816        | —              | —              |
| +Skip (跳跃连接)                              | 0.9017 | 0.7561        | 0.6770        | -0.0004        | -0.0046        |
| + $s_{16}$ ( $d_3$ 解码层)                   | 0.9003 | 0.7581        | 0.6737        | +0.0016        | -0.0078        |
| <b>Skip + <math>s_{16}</math> (多阶段对比)</b> | 0.8991 | <b>0.7644</b> | <b>0.6917</b> | <b>+0.0079</b> | <b>+0.0101</b> |

表 4.7: 多阶段对比实验 (e200, 3-seed 均值, 单尺度; 外部集噪声约 0.004)。 $\Delta$  为相对 `full_ref` 基准的外部集增益。Skip 表示在编码器侧边跳跃连接上增加 CSCM,  $s_{16}$  表示在  $d_3$  ( $s_{16}$  分辨率) 解码层增加 CSCM。

实验结果表明, 同时施加 skip 与  $s_{16}$  的多阶段对比是唯一在两个外部集上均取得超过估计随机波动范围增益的配置 (DUTS-TE +0.0079、DUT-OMRON +0.0101)。单独将 CSCM 放在跳跃连接或  $s_{16}$  解码层上均不稳健。这说明仅靠单点扩展不足以形成有效的对比机制, 两个位置必须协同才能生效。这与消融研究中模块需协同的发现一致: CSCM 的收益来自将其从解码器局部附加扩展为跨越编码器和所有解码层级的多阶段机制, 使对比先验在更完整的特征空间中发挥作用。

我们也同时尝试了对比监督、无参数门控、可学习半径、边缘门控以及多阶段与监督的组合等增强方式, 这些改动在 ECSSD 上均未带来稳定的外部泛化收益 ( $\Delta$ DUTS 分布在 -0.0034 至 +0.0029 之间)。值得注意的是, skip only 配置在 ECSSD 上数值最高 (0.9017), 但在外部集上  $\Delta$ DUTS 为负 (-0.0004), 再次印证了 ECSSD 排名需要外部验证来校验的结论。

## 4.5 对比先验分析

本节从作用、来源与边界三个方面分析对比先验: 它在何种条件下有用、增益从何而来、又在何处失效。由于 ECSSD 在该设定下的性能已接近饱和, 以下分析以外部集与低数据区间为准。

### 4.5.1 对比先验的增益随训练数据减少而增大

为验证“显式对比先验的价值随数据稀缺而增大”这一假设, 我们在不同训练量下对比了 base 与单独加入 CSCM 模块 (+CSCM) 的性能差异。具体协议如下: 以完整 ECSSD 训练集的 seed-42 划分 (600 张) 为全集, 从中随机子采样  $n \in \{100, 200, 400, 600\}$  张作为训练集; 每个  $n$  下在 3 个随机种子 (seed 42/3407/2026) 上分别训练并取均值; 所有子实验统一使用 e60 协议 (60 epoch), 其余训练设置 (优化器、学习率、batch size 等) 与主实验一致。评测同时报告 ECSSD 测试集 (300 张) 和外部集 DUTS-TE (5019 张) 上的 max-F 增益 ( $\Delta = \text{model} - \text{base}$ )。可学习版 CSCM 和无参数固定门控版 `cscmfix` (定义见式 16) 一并比较, 以在一个实验中同时观察 H1 (先验随数据减少而增值) 和 H2 (增益来自先验本身而非参数)。

图 4.4 中呈现两个趋势:

其一是所有曲线随训练量增大而系统性下移:  $n = 100$  时全部  $\Delta$  为正,  $n = 600$  时全部趋近于零或跌入负值。这意味着显式对比先验的价值与训练数据量呈反向关系——数据越稀缺, 网络越难以自行从样本中归纳出对比规律, 此时显式编码的先验就能替代一部分“从数据中学习”的负担; 数据越充裕, 网络自己学到的表示越接近对比结构, 先验的边际增益自然收窄甚至归零 (H1)。




图 4.4: 数据效率曲线 (e60, 3-seed 均值, 单尺度)。Δ = model - base。实线为可学习版 CSCM，虚线为无参数固定门控版 `cscmfix`。灰色虚线标出 Δ = 0 参考线。两张图上，所有四条线均随 n 增大而下降，表明先验价值随数据增多而递减；可学习版始终在固定版之上，表明先验本身已有效，学习进一步放大信号。

$n = 600$  时 Δ 为负值，除了上述“数据足够、先验冗余”的宏观原因外，还有一个直接的工程因素：所有子实验统一使用 60 epoch，而 CSCM 引入了额外模块，其参数量更大、收敛更慢，60 epoch 不足以将其充分训练到位。在主节 200 epoch 协议下，同样用满 600 张训练数据时，完整 C3Net 相对于 Base 的 max-F 为 0.9087 vs 0.9068 (Δ = +0.0019，仍为正)，验证了这一判断——60 epoch 下的负值并不必然表示先验会造成负迁移，而更可能是收敛不充分的产物。但即便在 200 epoch 下，+0.0019 的增益也远小于  $n = 100$  时 +0.0126 的量级，趋势不变。

其二是实线（可学习门控）在所有数据量级别上均不低于虚线（固定门控）。 $n = 100$  时差距最明显：ECSSD 上 +0.0126 vs +0.0070，DUTS-TE 上 +0.0181 vs +0.0033。固定门控仅含两个标量参数  $s, b$ ，其注意力完全由对比幅值这一先验信号决定，在小数据下仍然给出了正增益；可学习版在此基础上叠加了可训练的 Conv，将先验信号进一步放大和重塑，从而取得更高的提升。两条线之间的差距，即先验之上可学习部分的价值，同样随数据增多而收窄 (H2)。

综上，显著性的中心-周边对比是一种与任务结构相匹配的归纳偏置，其价值随数据稀缺而增大；将这一偏置以可微模块的形式注入网络，可以在小样本条件下提供额外的结构约束，帮助模型学习原本需要更多数据才能稳定估计的视觉规律。

#### 4.5.2 增益来自对比先验本身而非额外参数

为隔离对比先验本身与额外可学习参数的贡献，我们把 CSCM 中可学习的 Conv 换成对比幅值的确定性函数，仅含两个标量  $s, b$ ：

$$m = \frac{1}{C} \sum_c |B_c|, \quad A_{\text{fix}} = \sigma\left(s \cdot \frac{m - \mu(m)}{\text{std}(m) + \epsilon} + b\right), \quad (16)$$

其中  $\mu(\cdot)$  与  $\text{std}(\cdot)$  为逐图统计，注意力的空间形态完全由对比幅值决定。该无参数版本 `cscmfix` 在数据效率实验（图 4.4）中与可学习版 CSCM 一同参与评测：在  $n = 100$  极小数据设定下，`cscmfix` 在两个数据集上均为正增益（ECSSD +0.0070，DUTS-TE +0.0033），在所有数据量级别上可学习版（实线）均不低于固定门控版（虚线）。这说明增益的来源是对比先验这一结构本身，而非额外的可学习参数；可学习版更强，则说明可学 Conv 在先验之上进一步放大了这一信号。

### 4.5.3 无参数对比门控对齐于物体边界

为了理解 CSCM 的注意力图  $A$  与显著物体的真实边界之间的关系，我们在 ECSSD 测试集上计算了  $A$  与 Sobel( $GT$ ) 图之间的逐像素 Pearson 相关系数，同时统计了位于  $GT$  边界上的像素的平均注意力与位于非边界区域的比值。这里对比了可学习的 CSCM (Learned) 和它的无参数版本 (Fixed, 即式 16 的  $A_{fix}$ ，其空间形态完全由对比幅值的标准化统计量决定，不含任何可训练参数)。

| Gating                 | Pearson( $A$ , $GT$ edge) | Edge/Non-edge Ratio            |
|------------------------|---------------------------|--------------------------------|
| Fixed (parameter-free) | <b>0.2226</b>             | <b>2.40<math>\times</math></b> |
| Learned                | 0.0168                    | 1.02 $\times$                  |

表 4.8: CSCM 注意力与  $GT$  Sobel 边界的对齐 (ECSSD 测试集, b4\_full, seed 42)。

固定门控 (Fixed) 的注意力 2.40 倍地集中在物体与背景的边界，Pearson 相关为 0.2226，说明其在构造上对应边界检测行为，将对比先验直接反映为边界强度 (图 4.5)；而可学习的门控 (Learned) 经过网络重塑后 Pearson 仅为 0.0168，比值也趋近于 1.0，表明其已偏离字面含义上的边界检测，转为一种更弥散的广域调制。值得注意的是，两者在小数据上均能提升性能，说明增益来自对比特征这一输入本身，而非要求注意力图精确形似边界。当先验被限制为无参数形式时，它表现为可解释的边界检测器，这为 CSCM 的对比机制提供了功能层面的直接证据。

### 4.5.4 对比先验在低对比伪装目标上失效

在伪装数据集 CAMO[12] (250 张) 上，于对比先验明显有效的  $n=100$  区，我们比较了各模型相对 base 的增益：

| 数据集                        | cscm-base      | full-base      |
|----------------------------|----------------|----------------|
| ECSSD (high contrast)      | <b>+0.0126</b> | +0.0061        |
| DUTS-TE (high contrast)    | <b>+0.0181</b> | +0.0143        |
| <b>CAMO (low contrast)</b> | <b>-0.0045</b> | <b>-0.0824</b> |

表 4.9: 高对比 SOD 集与低对比伪装集上的对比 ( $n=100$ , 3-seed 均值, 单尺度)。对比先验在 SOD 集上带来提升，在伪装集上符号翻转、转为负迁移。

对比先验在高对比的显著物体上有一定正向作用，但在低对比的伪装物体上会造成性能下降，这说明 CSCM 的作用依赖对比这一信号：伪装物体刻意降低中心-周边对比，先验因此失效并可能造成负迁移。值得注意的是，完整模型相对 base 在 CAMO 上下降更明显 ( $-0.0824$ )，这是因为它在对比之外还叠加了边缘与上下文等同样面向高对比显著性的线索，对这些线索的依赖在低对比伪装上被整体放大，因而迁移性能较低。结合数据效率、无参数性与边界对齐三方面的正向证据，这一反例从相反方向刻画了对比先验的作用边界。

## 4.6 进一步分析

### 4.6.1 测试时增强

测试时增强 (TTA) 以零额外参数的成本提高预测的稳健性，尤其适用于训练数据有限、预测方差较大时。我们对输入做  $\{0.75, 1.0, 1.25\}$  三尺度采样与水平翻转共 6 个视角，将各自的概率图取平均作为最终输出。在 ECSSD seed-42 上，C3Net 的单尺度 max-F 0.9149 提升至 0.9199，说明这类多视角自集成有助于降方差并改善小数据下预测的不稳定。






图 4.5: 固定对比门控的注意力可视化 (列: 图像 / GT / 预测 / contrast s4 / contrast s2)。注意力清晰聚焦于显著物体的高对比边界。

如图4.6所示, *single* 方式容易在复杂纹理、低对比度或局部遮挡场景下出现目标缺失与响应不连续; *disagreement* 反映模型在边界区域、弱显著区域及易混淆背景处的不确定性。不一致性响应通常集中在单次预测不稳定或结构缺失的位置, 为后续融合提供了有效补充信息。 *fused* 方式输出能够缓解单次预测的偶然误差, 增强目标区域的完整性与响应一致性, 尤其在船体边界不清晰和雪地长椅低对比度等困难样例中表现出更稳健的预测效果。

#### 4.6.2 CA-ASPP 的可视化分析

如图 4.7 所示, CA-ASPP 能够为解码阶段提供更加可靠的高层语义引导。从图 4.7(a) 的消融对比可以看出, 在移除 CA-ASPP 后, 模型更容易受到背景区域或复杂结构的干扰。例如, 在第一个样例中, 背景中的自行车区域被错误激活; 在第二个样例中, 目标的边界被环境抑制, 移除 CA-ASPP 后的预测结果出现明显的结构缺失; 在第三个复杂场景中, w/o CA-ASPP 的结果产生大面积误检, 而完整模型能够更好地保持目标区域的整体定位。

图 4.7(b) 进一步展示了 CA-ASPP 内部的上下文建模过程。不同膨胀率的 ASPP 分支能够从不




图 4.6: 基于测试时增强的预测结果与不一致性可视化, *single* 表示未融合的单分支预测; *disagreement* 表示不同增强分支预测之间的差异; *fused* 表示通过整合多增强视角下的预测结果。

同感受野提取多尺度高层语义。融合后的 Context (fused) 已经能够形成粗粒度上下文, 但其响应从目标区域向周围背景呈现连续的平滑过渡, 说明高层上下文中目标信号与背景信号仍存在一定程度的混合; 经过 Gate 校准后, CA-ASPP Output 中目标相关响应更加集中, 目标区域周围的黑色区域可以看出, 目标-环境之间的过渡减少, 从而减弱了二者之间的语义纠缠。

#### 4.6.3 CSCM 的可视化分析

图 4.8 的可视化消融结果表明, 相较于移除该模块的预测结果, 完整模型得益于 CSCM 对目标边界的精准聚焦与对复杂背景噪声的有效抑制, 显著提升了整体分割的准确性与边缘完整性。3 个例子中去除 CSCM 模块的预测结果会出现误检, 将环境误判为显著物体。注意力图的结果表明该模块能够自适应地将注意力高度集中于显著物体的边缘与轮廓结构上。进一步结合 before、after 以及 delta 的特征图对比可以看出, 在经过 CSCM 处理后, 背景中无关区域的冗余激活得到了大幅削弱 (例如第一行的下方建筑、第二行的远山以及第三行的树枝), delta 图中高亮的边缘残差证实了该模块在目标边界处产生了强烈的特征响应变化。

#### 4.6.4 未取得稳定收益的探索

在探索过程中, 我们也尝试了若干未能带来稳定收益的方向: 将 C3Net 和 CTD-lite 的模块融合, 未产生叠加增益; CSCM 的除性归一化和不确定性门控变体均不及差分形式 (前者在小数据上尤其不稳定); 频域感知损失在外部集上无增益; 以不确定性引导 (附录 B) 的两阶段细化 (coarse + refinement) 出现残差塌缩, 第二阶段的变化量在双外部集确认趋近于 0; 将强数据增强与 weight-decay 组合后, 模型在 ECSSD 上有所提升, 但在外部验证上表现不佳, 未取得一致收益。这些探索结果表明: 在 ECSSD + ResNet-18 这一组合下, 模型性能已接近饱和, 额外的工程改进更可能仅产生随机范围内的波动。




图 4.7: CA-ASPP 模块的消融对比与特征响应可视化。(a) 为预测结果对比，其中 Image 表示输入图像，GT 表示真实显著性掩码，Full 表示完整模型的预测结果，w/o CA-ASPP 表示移除 CA-ASPP 后的预测结果。(b) 为 CA-ASPP 内部响应可视化，其中  $ASPP\ d=i$  表示膨胀率为  $i$  的空洞卷积分支响应，Context (fused) 表示多尺度分支融合后的上下文特征，Gate 表示输入-上下文联合生成的空间校准权重，CA-ASPP Output 表示经过残差式校准后的高层上下文特征。




图 4.8: CSCM 模块消融实验的定性可视化分析。图中各列从左至右依次为：输入图像 (input)、真实掩膜 (GT)、移除 CSCM 模块的预测结果 (no\_cscm)、CSCM 处理前的特征激活图 (before)、处理后的特征激活图 (after)、特征变化残差 (delta)、注意力权重分布 (attn) 以及完整模型的最终预测结果 (pred)。

#### 4.6.5 定性对比

图 4.9 给出了若干典型测试图像上各方法的预测结果，以对数值指标提供直观参照。相比于基线，C3Net 通常在前景的边界精细程度和背景的误激活抑制上有直观改善，这与其更低的 MAE 和更高的 IoU 一致。

## 5 讨论

本文围绕一个核心命题展开：在显著性物体检测中，将中心-周边对比这一经典视觉先验显式编码为可微模块，能否在有限数据下带来可泛化的性能提升？为了回答这个问题，我们以 CSCM 为枢纽构建了 C3Net，并配套了上下文校准 (CA-ASPP)、边界与多级深监督等辅助线索，在 ECSSD、DUTS-TE、DUT-OMRON 三个数据集上展开系统的实验验证。

**对比先验的作用与边界。**从正面看，对比先验是稳定且可解释的增益来源。累积消融中，CA-ASPP 提供了最大的单步 max-F 提升 ( $0.9051 \rightarrow 0.9121$ )，CSCM 则是把因中间模块起伏而回落的性能恢复到链条最优 ( $0.9130$ ) 的收尾一步；留一消融中，移除 CA-ASPP 的 max-F 下降最大 ( $-0.0101$ )，移除 CSCM 则使 MAE 退化最为剧烈 ( $0.0344 \rightarrow 0.1156$ )，二者并列为最关键模块。CSCM 在  $n = 100$  极小数据下的增益 (ECSSD  $+0.0126$ 、DUTS-TE  $+0.0181$ ) 远超满数据下的收益；当其门控参数被限制为仅由对比幅值决定时，注意力在物体边界处集中 2.4 倍 (Pearson 相关  $0.2226$ )，从机制上印证了对比身份。从反面看，这一先验的作用边界同样清晰：在刻意压低对比的伪装数据集 CAMO 上，CSCM 在  $n = 100$  明显有效的低数据区反而出现负迁移 ( $\Delta = -0.0045$ )，完整模型下降更甚 ( $\Delta = -0.0824$ )。正反两面共同表明，中心-周边对比是一种与任务结构相匹配、且依赖对比信号的归纳偏置，而非单纯的额外容量。

**模块协同与性能天花板。**一个反复出现的主题是：在该设定下，性能改进来自模块间的互补而非数量堆叠。累积消融中，CA-ASPP 单步提升明显 (max-F  $0.9051 \rightarrow 0.9121$ )，而继续加入深监督与边缘分支后性能出现起伏甚至略降 ( $0.9104$ 、 $0.9099$ )，最终 CSCM 才将链条恢复到最优 ( $0.9130$ )；从完整模型中留一删除任一模块则都会造成一致的性能损失。多阶段对比实验同样表明，仅在跳跃连接或仅在  $s_{16}$  解码层施加 CSCM 均不足以稳定提升外部泛化，两者同时施加才获得唯一的双外部集超噪声增益。与此一致的是，我们记录的多条探索——除性归一化形式的 CSCM 在不同种子上剧烈波动 (标准差  $0.0494$ )、不确定性引导的两阶段细化出现残差塌缩、模块融合与频域损失等变体均未超噪声——都未能突破约  $0.92$  的 max-F 饱和区间。这说明在 ResNet-18 + ECSSD 这一组合下，额外的工程复杂度较难转化为统计上可靠的提升，与任务结构对齐的归纳偏置才是更稳定的杠杆。

**外部验证作为方法论。**ECSSD 仅 300 张的测试集不足以承载可靠的模型比较：累积消融在 ECSSD 与 DUTS-TE 上均呈非单调，但完整模型在三套数据上的 max-F 全部最高；跨方法排名在 ECSSD 与外部集之间不一致 (EGNet 在 ECSSD 上 max-F  $0.9048$ ，不及基线，却在 DUTS-TE 上以  $0.7992$  居首)；多阶段对比的 skip only 在 ECSSD 数值最高却在外部为负。这些反复出现的矛盾使我们将双外部集 (DUTS-TE 5019 张、DUT-OMRON 5168 张) 的跨数据集评测作为主要判据，以降低小测试集随机波动对结论的影响——这并非锦上添花，而是本工作方法论上的必要环节。

**局限与展望。**本工作存在若干局限。首先，所有实验均在 ResNet-18 这一单一骨干上完成，CSCM 与 CA-ASPP 在其他骨干 (如 Swin Transformer、ConvNeXt) 上的表现有待验证。其次，受课程条件限制，在主对比的 700/300、e200 协议下，C3Net 相对基线的 max-F 增益为  $+0.0062$  ( $0.9130$  vs  $0.9068$ )，虽为正且各模块均有边际贡献，但已接近外部集约  $0.004$  的噪声量级、远小于  $n = 100$  时的  $+0.0126$






图 4.9: 定性对比: C3Net 在边界与背景抑制上优于基线。

——在更大规模训练集（如 DUTS-TR, 10553 张）上验证各模块的上限，是后续工作的重要方向。此外，TTA 以零参数成本提升  $+0.005 \text{ max-F}$  的观察提示我们，小数据下的预测方差是一个值得系统处理的维度，将多视角一致性以正则形式融入训练，可能是比堆叠模块更高效的改进方向。

## 6 结论

本文从“显著性的物理来源是中心-周边对比”这一基本认识出发，将其显式实现为可微模块 CSCM，并以此为核心、辅以对对比感知的 CA-ASPP 上下文校准与边界、深监督线索，构建了 C3Net 显著性检测网络。实验结果表明，在小数据条件下，将契合任务本质的视觉先验以显式、可微的方式注入网络，比完全依赖网络从少量样本中自行发现规律更高效。CSCM 的增益随训练数据减少而增大，即便退化为无参数的固定门控、在小数据下仍能带来提升，在构造上天然对齐于物体的对比边界，而在故意压低对比的伪装物体上失效；CA-ASPP 则在高层语义上提供了最大的单步增益与最大的留一移除代价，与 CSCM 互补协同。这些证据从不同角度刻画了对比先验及其上下文校准的作用机理与适用边界。将 CSCM 从解码器的局部附加升级为贯穿编解码器多阶段的机制后，模型在双外部集上获得了一致且超过估计随机波动范围的泛化提升。多项未取得稳定收益的探索也表明，在小数据且性能接近饱和的设定下，与问题结构对齐的归纳偏置比单纯增加模型容量更稳定。

未来工作将沿着两个方向展开：在更大规模数据集（DUTS-TR）上验证各模块的上限并探索该先验是否能随数据规模进一步扩展；将测试时增强带来的方差降低效果以一致性正则的形式融入训练过程，从训练侧直接提升小数据下的预测稳健性。

## Appendix A CTD-lite 结构细节

受 CTDNet[30] 启发，我们实现 CTD-lite 作为一个对比方法，采用三路分工解码。语义路在最深特征上以语义聚合 (SAP) 注入全局上下文，并通过跨聚合模块 (CAM) 与其他路融合，负责定位；空间路沿 FPN 自顶向下保留分辨率，负责细节；边界路经边界细化模块 (BRM) 强化轮廓。三路互补融合，约 12.3M 参数。CTD-lite 与 C3Net、基线及其他对比方法一并评测，其中仅含语义路的轻量版本记为 CTD-lite-sem。

| 配置                | max-F $\uparrow$ | MAE $\downarrow$ |
|-------------------|------------------|------------------|
| Base (Spatial)    | 0.9056           | 0.0382           |
| <b>+ Semantic</b> | <b>0.9128</b>    | 0.0338           |
| + Boundary        | 0.9080           | 0.0311           |
| w/o CAM           | 0.8985           | —                |

表 A.10: CTD-lite 三路分工消融结果 (ECSSD)。

| 配置                     | ECSSD max-F         | DUTS-TE max-F     |
|------------------------|---------------------|-------------------|
| Base (Spatial)         | 0.9056              | 0.7681            |
| <b>+ Semantic</b>      | <b>0.9128</b>       | 0.7725 $\uparrow$ |
| <b>+ Boundary (完整)</b> | 0.9080 $\downarrow$ | <b>0.7756</b>     |

表 A.11: CTD-lite 链的外部消融结果。

语义分支贡献相对更大，是性能提升的主要来源；边界分支在 MAE 上有一定优势，但存在轻微过拟合现象；CAM 门控聚合机制优于简单融合，验证了跨分支特征自适应加权的有效性。外部消融趋势与 ECSSD 一致，语义分支带来的增益最大。



## Appendix B 其他探索实验：不确定性-Zoom 的残差塌缩分析


我们还研究了一种不确定性引导的两阶段细化方法（uncertainty-zoom）：粗预测  $\rightarrow$  取 top- $k$  不确定 patch  $\rightarrow$  refiner 预测残差  $\delta \rightarrow \text{final} = \text{coarse} + \delta$ 。实验中观察到  $\delta$  几乎恒为 0（细化分支未产生有效贡献）：

| 变体                         | final max-F | coarse max-F | $\Delta(\text{final} - \text{coarse})$ |
|----------------------------|-------------|--------------|----------------------------------------|
| baseline (含 $ \delta $ 正则) | 0.8953      | 0.8951       | +0.0001                                |
| 去正则 + 加大 patch 权重          | 0.8947      | 0.8945       | +0.0001                                |
| 更多 patch + 去正则             | 0.8883      | 0.8879       | +0.0004                                |

表 B.12: 不确定性-Zoom 策略在不同配置下的残差塌缩现象。

**探究过程：**我们先前假设塌缩是损失里的  $|\delta|$  正则项造成的。但去掉该正则、并把 patch 监督权重从 0.5 提到 1.0 后， $\delta$  仍然  $\approx 0$ 。这说明：残差塌缩与损失设计并非直接相关——在强预训练 base + 小数据下，单阶段粗预测在不确定区已接近最优，refiner 难以学习到有效残差，第二阶段主要增加了优化难度。这一负面结果与文献中“小样本下复杂/级联 decoder 易退化”的观察一致，也解释了本文最终采用单阶段设计的原因。

**跨数据集确认：**我们进一步在 DUTS-TE 与 DUT-OMRON 上评测， $\Delta(\text{final} - \text{coarse})$  仍分别仅 +0.0003 与 +0.0002——残差塌缩在两个外部集上同样成立，说明该现象具有跨数据集一致性，而非 ECSSD 单数据集的偶然结果。



(a) 部分场景下的有效细化与残差提取



(b) 复杂场景下的细化失效与残差塌缩

图 B.10: 不确定性-Zoom 策略的定性可视化分析。图中各列从左至右依次为：输入图像 (Input)、真实掩膜 (GT)、边缘提取、细化前预测 (Coarse)、细化后预测 (Final) 以及预测残差 ( $\delta$ )。

从可视化（图 B.10）可以看到，在一些场景下不确定性引导的两阶段细化有一定的效果，但是在某些复杂场景中，依然存在残差难以提取等问题。

## Appendix C AI 使用说明

### 一、使用概述

本说明用于披露 AI 工具在本小组作业中的辅助用途与适用场景。本次作业中，AI 仅作为学习辅助工具，服务于文献研读、实验代码编写、报告撰写等环节，用以提升作业效率与内容质量；核心的研究构思、实验设计、数据分析、结论判断与全部插图绘制均由小组成员独立完成。

### 二、具体适用场景与辅助用途

**1. 文献阅读与整理。** AI 辅助小组成员阅读相关论文、理解经典方法的技术细节，并协助整理参考文献条目，提升文献梳理效率。文献的选取、核心论点的判断与引用决策均由组员负责。

**2. 实验代码编写。** AI 在组员主导下协助搭建实验框架、书写部分实现代码并提供调试建议；全部代码均在组员指导下完成，并经组员审阅与人工 review，实验设计、超参与消融方案的选择由组员主导，AI 负责提出建议与具体实现。

**3. 报告撰写。** AI 辅助梳理报告框架、规范专业术语、润色段落语句与统一排版格式。写作思路、实验观察与结论均由组员构思后指导 AI 完成，不存在 AI 直接生成报告正文的情况。

**4. 插图绘制。** 报告中的框架图由人工绘制，其余可视化由 ai 辅助代码生成绘制。

### 三、使用原则

AI 的辅助以不替代小组成员的核心学习与创造为前提：实验动机的提出、方法设计的决策、实验结果的分析与论文结论的得出，均由小组共同讨论并独立完成；AI 输出均经组员核实与修改后方予采用，由小组对全部内容的准确性负责。

## 参考文献

- [1] Radhakrishna Achanta, Sheila Hemami, Francisco Estrada, and Sabine Susstrunk. Frequency-tuned salient region detection. In *CVPR*, pages 1597–1604, 2009.
- [2] Matteo Carandini and David J Heeger. Normalization as a canonical neural computation. *Nature Reviews Neuroscience*, 13(1):51–62, 2012.
- [3] Liang-Chieh Chen, George Papandreou, Iasonas Kokkinos, Kevin Murphy, and Alan L. Yuille. Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 40(4):834–848, 2018.
- [4] Liang-Chieh Chen, George Papandreou, Florian Schroff, and Hartwig Adam. Rethinking atrous convolution for semantic image segmentation. *arXiv preprint arXiv:1706.05587*, 2017.
- [5] Ming-Ming Cheng, Guo-Xin Zhang, Niloy J Mitra, Xiaolei Huang, and Shi-Min Hu. Global contrast based salient region detection. In *CVPR*, pages 409–416, 2011.
- [6] Deng-Ping Fan, Ge-Peng Ji, Guolei Sun, Ming-Ming Cheng, Jianbing Shen, and Ling Shao. Camouflaged object detection. In *CVPR*, pages 2777–2787, 2020.
- [7] Shixuan Gao, Pingping Zhang, Tianyu Yan, and Huchuan Lu. Multi-scale and detail-enhanced segment anything model for salient object detection. In *ACM International Conference on Multimedia*, 2024.
- [8] Qibin Hou, Ming-Ming Cheng, Xiaowei Hu, Ali Borji, Zhuowen Tu, and Philip HS Torr. Deeply supervised salient object detection with short connections. In *CVPR*, pages 3203–3212, 2017.
- [9] Jie Hu, Li Shen, and Gang Sun. Squeeze-and-excitation networks. In *CVPR*, pages 7132–7141, 2018.
- [10] Laurent Itti, Christof Koch, and Ernst Niebur. A model of saliency-based visual attention for rapid scene analysis. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 20(11):1254–1259, 1998.
- [11] Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C Berg, Wan-Yen Lo, et al. Segment anything. In *ICCV*, pages 4015–4026, 2023.
- [12] Trung-Nghia Le, Tam V Nguyen, Zhongliang Nie, Minh-Triet Tran, and Akihiro Sugimoto. Ana-branch network for camouflaged object segmentation. *Computer Vision and Image Understanding*, 184:45–56, 2019.
- [13] Guanbin Li and Yizhou Yu. Visual saliency based on multiscale deep features. In *CVPR*, pages 5455–5463, 2015.
- [14] Jiang-Jiang Liu, Qibin Hou, Ming-Ming Cheng, Jiashi Feng, and Jianmin Jiang. A simple pooling-based design for real-time salient object detection. In *CVPR*, pages 3917–3926, 2019.

- [15] Nian Liu and Junwei Han. Dhsnet: Deep hierarchical saliency network for salient object detection. In *CVPR*, pages 678–686, 2016.
- [16] Nian Liu, Ni Zhang, Kaiyuan Wan, Ling Shao, and Junwei Han. Visual saliency transformer. In *ICCV*, pages 4722–4732, 2021.
- [17] Zhiming Luo, Akshaya Mishra, Andrew Achkar, Justin Eichel, Shaozi Li, and Pierre-Marc Jodoin. Non-local deep features for salient object detection. In *CVPR*, pages 6609–6617, 2017.
- [18] Jianping Shi, Qiong Yan, Li Xu, and Jiaya Jia. Hierarchical image saliency detection on extended cssd. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 38(4):717–729, 2016.
- [19] Lijun Wang, Huchuan Lu, Xiang Ruan, and Ming-Hsuan Yang. Deep networks for saliency detection via local estimation and global search. In *CVPR*, pages 3183–3192, 2015.
- [20] Lijun Wang, Huchuan Lu, Yifan Wang, Mengyang Feng, Dong Wang, Baocai Yin, and Xiang Ruan. Learning to detect salient objects with image-level supervision. In *CVPR*, pages 136–145, 2017.
- [21] Wenguan Wang, Qiuxia Lai, Huazhu Fu, Jianbing Shen, Haibin Ling, and Ruigang Yang. Salient object detection in the deep learning era: An in-depth survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(6):3239–3259, 2022.
- [22] Jun Wei, Shuhui Wang, and Qingming Huang. F3net: Fusion, feedback and focus for salient object detection. In *AAAI*, volume 34, pages 12321–12328, 2020.
- [23] Jun Wei, Shuhui Wang, Zhe Wu, Chi Su, Qingming Huang, and Qi Tian. Label decoupling framework for salient object detection. In *CVPR*, pages 13025–13034, 2020.
- [24] Sanghyun Woo, Jongchan Park, Joon-Young Lee, and In So Kweon. Cbam: Convolutional block attention module. In *ECCV*, pages 3–19, 2018.
- [25] Chuan Yang, Lihe Zhang, Huchuan Lu, Xiang Ruan, and Ming-Hsuan Yang. Saliency detection via graph-based manifold ranking. In *CVPR*, pages 3166–3173, 2013.
- [26] Pingping Zhang, Dong Wang, Huchuan Lu, Hongyu Wang, and Xiang Ruan. Amulet: Aggregating multi-level convolutional features for salient object detection. In *ICCV*, pages 202–211, 2017.
- [27] Jia-Xing Zhao, Jiang-Jiang Liu, Deng-Ping Fan, Yang Cao, Jufeng Yang, and Ming-Ming Cheng. Egnet: Edge guidance network for salient object detection. In *ICCV*, pages 8779–8788, 2019.
- [28] Rui Zhao, Wanli Ouyang, Hongsheng Li, and Xiaogang Wang. Saliency detection by multi-context deep learning. In *CVPR*, pages 1265–1274, 2015.
- [29] Ting Zhao and Xiangqian Wu. Pyramid feature attention network for saliency detection. In *CVPR*, pages 3085–3094, 2019.
- [30] Zhirui Zhao, Changqun Xia, Chenxi Xie, and Jia Li. Complementary trilateral decoder for fast and accurate salient object detection. In *ACM Multimedia*, pages 4967–4975, 2021.