



南開大學
Nankai University

深度学习及应用实验报告

注意力机制实验

课程名称：深度学习及应用

学院：密码与网络空间安全学院

姓名：金莫迪

学号：2312578

日期：2026 年 6 月 29 日

目录

1	实验目的	2
2	数据集与实验配置	2
3	模型原理	3
3.1	PlainSeq2Seq 结构	3
3.2	AttentionSeq2Seq 结构	4
4	实验过程	5
5	实验结果与可视化	5
6	结果分析与讨论	7
7	问题与改进方向	7
8	实验结论	8
	参考文献	9

表 1: Attention 实验训练配置

项目	设置
任务	法语到英语短句翻译
句对数量	8260
训练/验证划分	7434 / 826
源语言词表	3658
目标语言词表	2422
模型	PlainSeq2Seq、AttentionSeq2Seq
循环单元	GRU
Embedding 维度	128
隐藏层维度	128
batch size	64
优化器	AdamW, 学习率 0.001, weight decay 0.0001
最大轮次	150 epoch
早停机制	监控验证 loss, patience=10
运行设备	CUDA

1 实验目的

本实验实现法英短句翻译任务,对比基于 RNN 解码器的普通 Encoder-Decoder Seq2Seq 与带注意力机制的 Seq2Seq 模型。实验中采用的 GRU 属于门控循环神经网络单元,因此能够代表 RNN 解码器的序列生成过程。实验目标是理解编码器如何将源语言序列压缩为上下文表示,解码器如何逐步生成目标语言序列,以及注意力机制如何通过动态对齐缓解固定长度上下文向量的信息瓶颈。Seq2Seq 模型由 Sutskever 等用于神经机器翻译 [1], Bahdanau 等进一步提出联合对齐与翻译的注意力机制 [2], Luong 等系统比较了 global/local attention 形式 [3]。

实验共使用 8260 对过滤后的法英短句,训练 PlainSeq2Seq 与 AttentionSeq2Seq 两个模型,并输出训练曲线、翻译样例和注意力热力图。

2 数据集与实验配置

实验数据为法英平行句对,经过规范化、小写化、标点分离和长度过滤后保留 8260 对短句。其中 7434 对用于训练,826 对用于验证。源语言词表大小为 3658,目标语言词表大小为 2422。每个句子加入起止符,并在 batch 内进行 padding。

表 1 展示了训练配置。两个模型共享相同编码器和训练数据,差别主要在解码器是否显式利用编码器每个时间步的输出。




图 1: Seq2Seq 与注意力机制结构图

3 模型原理

普通 Seq2Seq 模型由编码器和解码器组成。编码器将源句 $\mathbf{x} = (x_1, \dots, x_T)$ 编码为隐藏状态序列：

$$\mathbf{h}_t = \text{GRU}_{enc}(\mathbf{E}_x(x_t), \mathbf{h}_{t-1}). \quad (1)$$

PlainSeq2Seq 只把最终隐藏状态作为上下文向量传给解码器：

$$\mathbf{s}_t = \text{GRU}_{dec}(\mathbf{E}_y(y_{t-1}), \mathbf{s}_{t-1}), \quad p(y_t | \mathbf{y}_{<t}, \mathbf{x}) = \text{softmax}(\mathbf{W}_o \mathbf{s}_t). \quad (2)$$

当源句较长时，所有信息被压缩到单一向量中，容易造成信息丢失。

注意力机制在每个解码步计算当前解码状态与所有编码状态的相关性：

$$e_{t,i} = a(\mathbf{s}_{t-1}, \mathbf{h}_i), \quad \alpha_{t,i} = \frac{\exp(e_{t,i})}{\sum_j \exp(e_{t,j})}. \quad (3)$$

随后根据权重得到动态上下文向量：

$$\mathbf{c}_t = \sum_i \alpha_{t,i} \mathbf{h}_i. \quad (4)$$

式 (3) 和式 (4) 使模型在生成每个目标词时都能重新关注源句中最相关的位置，从而缓解固定上下文瓶颈。

图 1 展示了 Seq2Seq 与注意力机制的典型结构。图 1a 中编码器只通过最终状态传递信息；图 1b 和图 1c 则强调解码时对源序列不同位置的动态选择。

3.1 PlainSeq2Seq 结构

PlainSeq2Seq 由一个 GRU 编码器和一个 GRU 解码器组成。编码器输入法语 token 序列，先经过 128 维 Embedding 层，再由 GRU 逐词更新隐藏状态。源句处理完成后，编

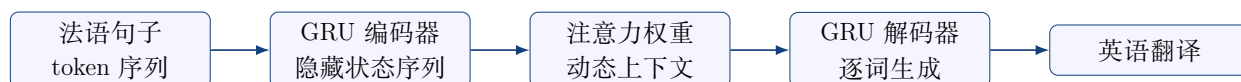


图 2: 带注意力的 Seq2Seq 翻译流程

码器最终隐藏状态被视为整句语义向量，并作为解码器的初始状态。解码器从起始符开始，每一步接收上一时刻目标词 embedding，输出目标词表上的概率分布。

该模型结构清晰，但核心限制也很明显：无论源句包含多少词，编码器都必须把信息压缩到最后一个隐藏状态中。对于短句，这种固定长度表示通常还能工作；但当句子变长、语序变化或源目标词对齐不规则时，单一上下文向量容易成为信息瓶颈。因此 PlainSeq2Seq 在本实验中作为注意力机制的对照模型。

3.2 AttentionSeq2Seq 结构

AttentionSeq2Seq 保留相同的 GRU 编码器，但解码器不再只依赖最终隐藏状态。编码器会输出每个源词位置的隐藏状态序列 $\{h_i\}$ ；解码第 t 个目标词时，模型根据当前解码状态与每个源隐藏状态计算注意力分数，再通过 softmax 得到权重 $\alpha_{t,i}$ ，最后加权求和得到上下文向量 c_t 。解码器将当前目标词 embedding 与上下文向量拼接后送入 GRU，再预测下一个词。

这种结构的优势在于，模型可以为不同目标词选择不同源词信息。例如生成主语时关注源句主语，生成形容词或状态词时关注相应修饰成分。注意力权重还可以被可视化为热力图，从而提供一定可解释性。本实验保存的 attention heatmap 正是由该权重矩阵绘制得到。

Listing 1: PlainSeq2Seq 与 AttentionSeq2Seq 网络结构打印结果

```

1  ===== PlainSeq2Seq =====
2  Seq2Seq(
3      (encoder): Encoder(
4          (embedding): Embedding(3658, 128, padding_idx=2)
5          (gru): GRU(128, 128, batch_first=True)
6      )
7      (decoder): PlainDecoder(
8          (embedding): Embedding(2422, 128, padding_idx=2)
9          (gru): GRU(128, 128, batch_first=True)
10         (fc): Linear(in_features=128, out_features=2422, bias=True)
11     )
12 )
13
14  ===== AttentionSeq2Seq =====
15  Seq2Seq(
16      (encoder): Encoder(
17          (embedding): Embedding(3658, 128, padding_idx=2)
18          (gru): GRU(128, 128, batch_first=True)
19      )
20      (decoder): AttentionDecoder(

```

表 2: Seq2Seq 模型结构对比

模型	编码器	解码器	主要特点
PlainSeq2Seq	Embedding(3658,128) + GRU(128,128)	使用最终隐藏状态初始化 GRU, Linear 输出 2422 类词表概率	结构简单, 但固定上下文存在信息瓶颈
AttentionSeq2Seq	与 PlainSeq2Seq 相同, 保留所有时间步输出	每步计算源词注意力, 拼接上下文后送入 GRU	能动态对齐源词, 验证 loss 更低且可解释性更好

```

21 (embedding): Embedding(2422, 128, padding_idx=2)
22 (attn): Linear(in_features=256, out_features=1, bias=True)
23 (gru): GRU(256, 128, batch_first=True)
24 (fc): Linear(in_features=128, out_features=2422, bias=True)
25 )
26 )

```

代码清单 1 给出了两个模型的实际打印结构。PlainSeq2Seq 解码器只接收目标词 embedding 和上一隐藏状态；AttentionSeq2Seq 解码器额外包含注意力打分层，并将 embedding 与上下文向量拼接后输入 GRU，因此其 GRU 输入维度由 128 增加为 256。

表 2 展示了两个模型的核心区别。注意力机制并没有完全替换循环网络，而是在编码器和解码器之间增加了可学习的软对齐模块，使翻译过程从“整句压缩”转向“逐词检索”。

4 实验过程

实验首先对句子进行规范化处理：统一小写、去除异常字符、将标点与单词分开，并筛选长度不超过设定阈值的短句。随后分别构建源语言和目标语言词表，将句子转换为 token 索引。训练时采用 teacher forcing，即解码器输入真实上一词，目标是预测下一个词。验证时使用贪心解码，根据模型当前输出逐步生成翻译。

PlainSeq2Seq 和 AttentionSeq2Seq 均使用 GRU 编码器。二者的训练上限为 150 epoch，并使用验证 loss 早停。PlainSeq2Seq 在第 33 个 epoch 触发早停，AttentionSeq2Seq 在第 29 个 epoch 触发早停。注意力模型额外保存一个样例句子的注意力权重矩阵，用于绘制热力图。

5 实验结果与可视化

表 3 显示，AttentionSeq2Seq 的最优验证 loss 明显低于 PlainSeq2Seq，并且更早触发早停，说明注意力机制提升了训练效率和验证集拟合能力。

图 3 与表 3 一致：AttentionSeq2Seq 在较早阶段达到更低验证 loss，后期虽然也出现

表 3: Seq2Seq 翻译实验结果汇总

模型	最优验证 loss	早停 epoch	主要特点
PlainSeq2Seq	1.6243	33	结构简单，但固定上下文容易丢失信息
AttentionSeq2Seq	1.4478	29	loss 更低，部分短句翻译更准确




图 3: PlainSeq2Seq 与 AttentionSeq2Seq 验证 loss 曲线

表 4: 翻译样例对比

模型	法语输入	目标翻译	模型输出
PlainSeq2Seq	je suis gras .	i m fat .	i m fat .
PlainSeq2Seq	je suis gros .	i m fat .	i m sorry .
PlainSeq2Seq	je suis touchee !	i m hit !	i m touched .
AttentionSeq2Seq	je vais bien .	i m ok .	i m fine .
AttentionSeq2Seq	je suis gros .	i m fat .	i m fat .
AttentionSeq2Seq	je suis touchee !	i m hit !	i m hit !

轻微过拟合，但整体曲线优于 PlainSeq2Seq。

表 4 展示了部分验证样例。AttentionSeq2Seq 对 “je suis gros .” 和 “je suis touchee !” 的输出更接近目标翻译，但仍会在部分样例中出现语义漂移，说明当前数据规模和贪心解码策略限制了生成质量。

图 4 展示了目标词生成时对源句各位置的关注程度。热力图中的高亮区域可以被理解为软对齐关系：模型在生成某个英文词时，会把更多权重分配给相关法语词，而不是完全依赖单个最终隐藏状态。




图 4: AttentionSeq2Seq 注意力热力图

6 结果分析与讨论

从表 3 和图 3 可以看出，注意力机制显著降低了验证 loss。PlainSeq2Seq 的主要瓶颈在于固定上下文向量：编码器必须把整句信息压缩到最后隐藏状态中，句子稍长或词序发生变化时，解码器容易丢失局部信息。AttentionSeq2Seq 则在每一步解码时重新访问编码器输出，因此能更直接地利用源句中当前目标词相关的部分。

表 4 说明注意力机制改善了部分短句翻译。例如“je suis gros.”在 PlainSeq2Seq 中被误译为“i m sorry.”，而 AttentionSeq2Seq 输出“i m fat.”，与目标一致；“je suis touchee!”也被 AttentionSeq2Seq 正确翻译为“i m hit!”。同时，模型在“ca va.”等样例上仍存在误译，说明训练数据规模、句型覆盖和贪心解码都会影响最终翻译质量。

图 4 的价值在于可解释性。与分类任务中的混淆矩阵类似，注意力热力图能展示模型内部对齐行为，使模型输出结果与源词依赖关系能够同时被观察。对于机器翻译任务，这种对齐可视化是分析错误和理解模型的重要工具。

7 问题与改进方向

本实验的主要限制是数据规模较小且句子经过长度过滤，模型学习到的是短句翻译模式而非完整机器翻译能力。此外，验证时使用贪心解码，容易在某一步输出错误后持续累积误差。后续可以使用 beam search 改善解码质量，引入 BLEU 分数进行定量评价，并尝试双向编码器或 Transformer 结构。若数据量增加，注意力机制的优势会在长句和复杂语

序场景下更加明显。

8 实验结论

本实验完成了 PlainSeq2Seq 与 AttentionSeq2Seq 的全量训练与比较。结果表明，AttentionSeq2Seq 的最优验证 loss 为 1.4478，低于 PlainSeq2Seq 的 1.6243，并且在多个翻译样例中输出更接近目标句。注意力机制通过动态上下文向量缓解了固定长度表示瓶颈，同时提供了可视化对齐信息。通过本实验，可以直观理解注意力机制为什么成为现代序列建模和机器翻译的重要基础。

参考文献

- [1] Ilya Sutskever, Oriol Vinyals, and Quoc V. Le. Sequence to Sequence Learning with Neural Networks. In *NeurIPS*, 2014. <https://papers.neurips.cc/paper/5346-sequence-to-sequence-learning-with-neural-networks>
- [2] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. Neural Machine Translation by Jointly Learning to Align and Translate. In *ICLR*, 2015. <https://arxiv.org/abs/1409.0473>
- [3] Minh-Thang Luong, Hieu Pham, and Christopher D. Manning. Effective Approaches to Attention-based Neural Machine Translation. In *EMNLP*, 2015. <https://aclanthology.org/D15-1166/>
- [4] Kyunghyun Cho, Bart van Merriënboer, Çağlar Gülçehre, Dzmitry Bahdanau, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation. In *EMNLP*, 2014. <https://aclanthology.org/D14-1179/>
- [5] Adam Paszke et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library. In *NeurIPS*, 2019. <https://arxiv.org/abs/1912.01703>