



南开大学
Nankai University

深度学习及应用实验报告

卷积神经网络实验

课程名称：深度学习及应用

学院：密码与网络安全学院

姓名：金莫迪

学号：2312578

日期：2026 年 6 月 29 日

目录

1 实验目的	2
2 数据集与实验配置	2
3 模型原理	3
3.1 原始基础 CNN 与 SimpleCNN 结构	3
3.2 MicroResNet 结构	5
3.3 MicroRes2Net 结构	5
3.4 MicroDenseNet 结构	6
3.5 MicroMobileNet 结构	6
4 实验过程	7
5 实验结果与可视化	7
6 结果分析与讨论	9
6.1 不同 CNN 结构训练过程差异	9
7 问题与改进方向	11
8 实验结论	11
参考文献	12




图 1: CIFAR-10 样本图像

1 实验目的

本实验围绕 CIFAR-10 图像分类任务，完成卷积神经网络从基础结构到现代改进结构的实现、训练与比较。实验不仅要求掌握卷积、池化、批归一化、全局平均池化等基本模块，还需要理解残差连接、稠密连接、深度可分离卷积以及 Res2Net 多尺度特征表达的设计动机。卷积神经网络是现代视觉识别的核心模型之一，LeCun 等早期工作已证明局部感受野和权值共享对图像建模的有效性 [1]；ResNet、DenseNet、MobileNet 和 Res2Net 则分别从优化深层网络、特征复用、轻量化和多尺度表达角度推动了 CNN 结构发展 [3, 4, 5, 6]。

实验实现了 SimpleCNN、MicroResNet、MicroRes2Net、MicroDenseNet 和 MicroMobileNet 五类模型，统一在 CIFAR-10 训练集上训练，并在官方测试集上评估 loss、accuracy、混淆矩阵和类别级表现。

2 数据集与实验配置

CIFAR-10 数据集包含 10 个类别、60000 张 32×32 彩色图像，其中训练集 50000 张、测试集 10000 张 [2]。图 1 展示了本实验读取到的样本图像。该数据集图像分辨率较低，目标姿态、背景和颜色变化明显，因此模型需要同时具备局部纹理提取和全局语义归纳能力。

表 1 给出了本次全量训练配置。所有模型使用相同数据增强、优化器和评价协议，因此表 3 中的差异主要来自网络结构本身。

表 1: CNN 实验训练配置

项目	设置
数据集	CIFAR-10, 全量训练集 50000 张, 测试集 10000 张
输入尺寸	$3 \times 32 \times 32$
数据增强	RandomCrop(32, padding=4)、RandomHorizontalFlip
模型	SimpleCNN、MicroResNet、MicroRes2Net、MicroDenseNet、MicroMobileNet
优化器	AdamW, 学习率 0.001, weight decay 0.0005
学习率调度	CosineAnnealingLR
最大轮次	50 epoch
早停机制	监控验证 loss, patience=8
运行设备	CUDA

3 模型原理

二维卷积层通过局部窗口提取空间特征。对输入特征图 $\mathbf{X}$ 和卷积核 $\mathbf{W}$, 卷积输出可写为:

$$\mathbf{Y}_{c,i,j} = \sum_k \sum_{u,v} \mathbf{W}_{c,k,u,v} \mathbf{X}_{k,i+u,j+v} + \mathbf{b}_c. \quad (1)$$

式 (1) 表明卷积层通过共享卷积核在不同空间位置检测相同视觉模式。随着网络加深, 浅层特征通常对应边缘和颜色, 中层特征对应纹理与局部部件, 深层特征逐渐接近类别语义。

SimpleCNN 使用两层卷积和池化构成基础分类器。MicroResNet 在卷积块中加入残差连接:

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{\mathbf{W}_i\}) + \mathbf{x}, \quad (2)$$

其中 $\mathcal{F}$ 表示卷积残差分支。式 (2) 构成了更直接的梯度传播路径, 有助于缓解深层网络训练退化问题。

图 2 汇总了本实验扩展模型所对应的论文结构图。ResNet 强调恒等快捷连接, DenseNet 将每一层的输出传给后续所有层, MobileNet 将标准卷积分解为 depthwise 和 pointwise 两步, Res2Net 则在单个残差块内部构造多尺度分支。四者分别对应优化稳定性、特征复用、计算效率和多尺度表达能力。

3.1 原始基础 CNN 与 SimpleCNN 结构


原始 `cnn-pytorch-cifar10.ipynb` 中的基础 CNN 由两层 5×5 卷积、最大池化和三层全连接层组成。其结构打印结果如下。该网络没有残差连接或稠密连接, 特征只能按层顺序向前传递, 因此可作为“无跳跃连接卷积网络”的基础参照。

Listing 1: 原始 CNN notebook 中基础网络的结构打印结果


```

1 Net (
2   (conv1): Conv2d(3, 6, kernel_size=(5, 5), stride=(1, 1))


```




(a) ResNet 残差块 [3]



(b) DenseNet 稠密块 [4]



(c) MobileNet 深度可分离卷积 [5]



(a) Bottleneck block

(b) Res2Net module

(d) Res2Net 多尺度模块 [6]

图 2: CNN 扩展模型结构图

```

3  (pool): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1,
4      ceil_mode=False)
5  (conv2): Conv2d(6, 16, kernel_size=(5, 5), stride=(1, 1))
6  (fc1): Linear(in_features=400, out_features=120, bias=True)
7  (fc2): Linear(in_features=120, out_features=84, bias=True)
8  (fc3): Linear(in_features=84, out_features=10, bias=True)
9  )

```

本实验训练曲线中的 SimpleCNN 在原始基础 CNN 思路作了适配：卷积核改为 3×3 并加入 padding，使特征图尺寸变化更平稳；分类器采用两层全连接层。SimpleCNN 仍然不包含跳跃连接，因此训练过程能够反映普通顺序卷积网络的典型特征。该模型参数少、结构直观，能够验证卷积和池化对图像分类的基本作用；受网络深度和通道数限制，其高层语义表达能力相对有限。

3.2 MicroResNet 结构

MicroResNet 采用残差块作为核心模块。每个残差块包含两层 3×3 卷积、BatchNorm 和 ReLU，并将输入特征与卷积分支输出相加，如式 (2) 所示。残差连接的意义在于让网络学习残差映射 $\mathcal{F}(\mathbf{x})$ ，而不是直接学习完整映射 $\mathcal{H}(\mathbf{x})$ 。当最优映射接近恒等映射时，残差结构更容易优化。本实验的 MicroResNet 先用 stem 层提取 32 通道特征，再经过 32 通道残差块、下采样层和 64 通道残差块，最后通过全局平均池化和线性层输出 10 类概率。该结构在保持模型较轻的同时，保留了 ResNet 最重要的优化优势。

Listing 2: 个人实现 MicroResNet 的结构打印结果

```
1 MicroResNet(  
2     (stem): Conv2d(3,32,3,padding=1) + BatchNorm2d + ReLU  
3     (layer1): ResBlock(32 -> 32, two 3x3 convolutions)  
4     (down): Conv2d(32,64,3,stride=2,padding=1) + BatchNorm2d + ReLU  
5     (layer2): ResBlock(64 -> 64, two 3x3 convolutions)  
6     (head): AdaptiveAvgPool2d(1) + Linear(64,10)  
7 )
```

3.3 MicroRes2Net 结构

MicroRes2Net 在残差块内部引入多尺度分组思想。具体做法是先使用 1×1 卷积调整通道，再将特征按通道分成若干组；除第一组外，其余组依次经过 3×3 卷积，并与前一组输出产生级联式依赖。这样，一个残差块内部就能形成不同等效感受野的特征分支。相比普通 ResNet 只在层级深度上扩大感受野，Res2Net 在单个 block 内部构造细粒度多尺度表达，更适合捕捉 CIFAR-10 中大小变化明显的目标区域。本实验实现的 MicroRes2Net 使用 scale=4 的分组结构，并保持与 MicroResNet 相近的总体宽度，便于观察多尺度模块本身的影响。

Listing 3: 扩展实现 MicroRes2Net 的结构打印结果

```
1 MicroRes2Net(  
2     (stem): Conv2d(3,32,3,padding=1) + BatchNorm2d + ReLU  
3     (layer1): Res2NetBlock(32 channels, scale=4, 3 grouped 3x3  
4         convolutions)  
5     (down): Conv2d(32,64,3,stride=2,padding=1) + BatchNorm2d + ReLU  
6     (layer2): Res2NetBlock(64 channels, scale=4, 3 grouped 3x3  
7         convolutions)  
8     (head): AdaptiveAvgPool2d(1) + Linear(64,10)  
9 )
```

3.4 MicroDenseNet 结构

MicroDenseNet 的核心思想是特征复用。Dense layer 不只接收上一层输出，而是接收前面所有层输出的拼接：

$$\mathbf{x}_l = H_l([\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_{l-1}]). \quad (3)$$

式 (3) 中 $[\cdot]$ 表示通道维拼接， H_l 通常由 BatchNorm、ReLU 和卷积组成。这样的连接方式可以让浅层边缘、纹理特征直接传递到深层，减少重复学习，并改善梯度传播。本实验的 MicroDenseNet 使用 24 通道 stem、4 个 dense layer，每层增长率为 12，随后通过 transition layer 将通道压缩到 64 并进行池化。由于本实验版本较轻，DenseNet 的原始优势没有完全展开，但它仍体现了“密集连接与特征复用”的结构思想。

Listing 4: 个人实现 MicroDenseNet 的结构打印结果

```
1 MicroDenseNet(  
2   (stem): Conv2d(3,24,3,padding=1)  
3   (dense): 4 x DenseLayer, growth_rate=12  
4           input channels: 24 -> 36 -> 48 -> 60 -> 72  
5   (trans): BatchNorm2d(72) + ReLU + Conv2d(72,64,1) + AvgPool2d(2)  
6   (head): AdaptiveAvgPool2d(1) + Linear(64,10)  
7 )
```

3.5 MicroMobileNet 结构

MicroMobileNet 使用深度可分离卷积替代标准卷积。标准卷积同时完成空间滤波和通道混合，而深度可分离卷积将其拆成两步：

$$\text{DepthwiseConv} : \text{逐通道空间卷积}, \quad \text{PointwiseConv} : 1 \times 1 \text{通道融合}. \quad (4)$$

这种分解显著减少参数量和计算量。本实验中，MicroMobileNet 先用普通卷积获得 32 通道特征，再堆叠三个 depthwise block，通道数依次扩展到 64、96 和 128，最后使用全局平均池化分类。它的设计目标不是追求最高准确率，而是在较低计算成本下保持可接受的分类性能。

Listing 5: 个人实现 MicroMobileNet 的结构打印结果

```
1 MicroMobileNet(  
2   Conv2d(3,32,3,padding=1) + BatchNorm2d + ReLU  
3   DepthwiseBlock(32 -> 64, stride=1)  
4   DepthwiseBlock(64 -> 96, stride=2)  
5   DepthwiseBlock(96 -> 128, stride=2)  
6   AdaptiveAvgPool2d(1) + Linear(128,10)  
7 )
```


表 2: CNN 模型结构对比

模型	核心模块	本实验结构特点	主要作用
SimpleCNN	卷积、ReLU、池化	两层卷积加两层全连接	基础对照, 验证 CNN 基本流程
MicroResNet	残差块	32/64 通道残差学习	改善梯度传播, 提高深层特征学习能力
MicroRes2Net	多尺度残差块	scale=4 的块内分组卷积	在单个 block 内获得多尺度感受野
MicroDenseNet	稠密连接	4 个 dense layer, growth rate=12	强化特征复用和梯度传递
MicroMobileNet	深度可分离卷积	depthwise + pointwise 堆叠	降低计算量, 体现轻量化设计




图 3: CNN 实验训练与评估流程

表 2 总结了五个模型的结构差异。本实验在 CIFAR-10 上实现的是轻量化版本，因此模型宽度和层数低于论文中的大规模网络，但核心连接方式保持一致。这样的设置更适合课程实验：既能在本地完成全量训练，又能观察不同结构思想对分类性能的影响。

4 实验过程

实验首先下载并读取 CIFAR-10 数据集，对训练图像执行随机裁剪和水平翻转，测试图像仅进行张量化和归一化。训练阶段，每个 epoch 遍历完整训练集，使用交叉熵损失优化分类结果；验证阶段关闭梯度，统计平均 loss、整体 accuracy 和混淆矩阵。为保证可复现性，训练脚本固定随机种子，并保存每个模型的指标 CSV、混淆矩阵 CSV 和可视化图片。

图 3 展示了完整实验流程。数据增强只作用于训练集，避免把随机扰动引入测试阶段；所有模型都保存最优验证 loss 对应的结果，便于横向比较。

5 实验结果与可视化

表 3 显示，MicroResNet 在本实验设置下取得最高测试准确率 84.92%，MicroRes2Net 达到 81.02%，高于基础 SimpleCNN。MicroDenseNet 的效果最低，表明在深度和增长率较小的轻量化设置下，DenseNet 的特征复用优势未能充分发挥。

图 4 展示了训练过程中各模型的收敛情况。MicroResNet 的 loss 下降更充分，准确率曲线也更高；MicroRes2Net 曲线较稳定，但最终略低于 MicroResNet；DenseNet 曲线相

表 3: CIFAR-10 全量训练结果汇总

模型	最优验证损失	测试准确率 (%)	训练耗时 (s)
SimpleCNN	0.6992	75.72	961.36
MicroResNet	0.4522	84.92	1281.78
MicroRes2Net	0.5556	81.02	1079.75
MicroDenseNet	0.8213	71.01	1372.69
MicroMobileNet	0.6860	76.13	1071.67




图 4: 五种 CNN 模型训练过程对比

表 4: 关键 epoch 验证准确率对比

模型	epoch 1	epoch 10	epoch 20	epoch 30	epoch 50
SimpleCNN	49.31	69.49	72.78	74.73	75.70
MicroResNet	49.45	66.82	76.83	79.91	84.82
MicroRes2Net	49.88	69.21	72.42	78.93	80.77
MicroDenseNet	38.49	58.79	66.22	68.16	71.02
MicroMobileNet	48.93	67.95	72.42	75.01	76.05

对滞后，说明该轻量实现的参数配置与 CIFAR-10 全量训练并不完全匹配。

表 4 从关键 epoch 角度补充了图 4 的观察。SimpleCNN 和 MicroMobileNet 在前 20 个 epoch 已接近后期水平，后续提升较小；MicroResNet 在 30 到 50 epoch 仍持续提升，说明残差结构在中后期优化中仍能有效利用更深特征；MicroDenseNet 的提升较平缓，表现出轻量配置下特征增长不足的问题。

图 5 更直观地呈现了表 3 中的准确率差异。残差类结构整体表现最好，说明在相同训练预算下，优化路径的稳定性比单纯增加连接复杂度更加关键。

图 6 从类别层面展示了模型差异。MicroResNet 的对角线最集中，说明多数类别召回率较高；SimpleCNN 和 MicroMobileNet 在动物类别之间更容易混淆，例如 cat、dog、deer、horse 等类别共享背景和纹理特征；MicroRes2Net 相比 SimpleCNN 已明显改善，但仍不及 MicroResNet 稳定。




图 5: 五种 CNN 模型最终测试准确率对比

6 结果分析与讨论

从表 3、图 4 和图 6 可以得到三个结论。第一，残差连接是本实验中收益最显著的结构改进。MicroResNet 的准确率比 SimpleCNN 高出 9.20 个百分点，验证损失也显著降低，说明快捷连接缓解了优化困难，使网络能更充分学习深层特征。第二，Res2Net 的多尺度思想在本实验中取得有效提升，但轻量版本的收益低于标准残差块。结合 CIFAR-10 的 32×32 输入分辨率和本实验较浅的网络深度，可以推断块内多尺度分支尚未完全发挥作用。第三，MobileNet 虽然精度只略高于 SimpleCNN，但它使用深度可分离卷积，计算量更小，适合资源受限场景；若评价指标加入参数数量和推理速度，MobileNet 的综合价值会更加突出。

DenseNet 在本实验中的结果低于预期，主要原因包括两点：一是 MicroDenseNet 为控制模型规模仅使用较少 dense layer 和较小 growth rate，特征复用链条较短；二是 DenseNet 对训练超参数和网络宽度较敏感，过窄结构会限制每层新增信息量。该现象说明，论文结构思想移植到课程实验时，不应只保留连接形式，还需要结合数据规模、输入分辨率和模型容量重新调整。

6.1 不同 CNN 结构训练过程差异

本实验的重点是比较没有跳跃连接的普通卷积网络、ResNet、DenseNet 和 MobileNet 在训练过程中的差异。结合图 4、表 4 和表 3，四类结构的差异主要体现在优化路径、特征传递方式、模型容量和训练后期提升空间上。

首先，没有跳跃连接的 SimpleCNN 训练过程较稳定，但后期进入平台期较早。由表 4 可见，SimpleCNN 在 epoch 10 已达到 69.49%，epoch 20 达到 72.78%，但到 epoch 50 仅提升到 75.70%。这说明普通卷积网络能够较快学习 CIFAR-10 的低层纹理和局部形状特征，但由于缺少跨层信息通路，后续层只能依赖逐层变换后的特征继续抽象，深层语义




图 6: 主要 CNN 模型混淆矩阵

表达能力有限。如果继续简单增加普通卷积层数，梯度需要连续穿过更多非线性层，训练难度通常会增加，容易出现深层网络退化或收益递减。因此，SimpleCNN 的曲线表现为前期快速上升、后期缓慢趋于饱和。

其次，ResNet 的训练过程体现出跳跃连接对优化的显著帮助。MicroResNet 在前 10 个 epoch 的准确率并非最高，但在 epoch 20 后逐渐拉开差距，epoch 40 已达到 84.43%，最终最优准确率达到 84.92%。残差连接使特征可以通过恒等路径跨层传递，反向传播时梯度也可以沿快捷分支回传，从而缓解深层网络的梯度衰减和退化问题。与 SimpleCNN 相比，ResNet 的优势不是单纯前期收敛更快，而是在训练中后期仍能继续降低验证损失、提升准确率。这一点正是图 4 中 MicroResNet 曲线持续改善的主要原因。

再次，DenseNet 的训练机制与 ResNet 不同。ResNet 通过相加实现残差学习，而 DenseNet 通过通道拼接复用前面所有层的特征。理论上，DenseNet 可以加强梯度传播并

减少特征重复学习；但本实验中的 MicroDenseNet 是轻量化实现，只有 4 个 dense layer, growth rate 为 12，新增特征通道较少。表 4 显示，MicroDenseNet 从 epoch 1 的 38.49% 逐步提升到 epoch 50 的 71.02%，训练过程较平缓，但整体精度低于其他模型。这说明 DenseNet 的优势依赖足够的层数、增长率和 transition 设计；当 dense block 较浅且新增通道不足时，密集连接带来的特征复用优势无法充分转化为分类性能，反而可能受到模型容量限制。

最后，MobileNet 的训练过程体现出轻量化结构的精度与效率折中。MicroMobileNet 使用 depthwise separable convolution，将空间滤波和通道融合拆开，减少了标准卷积中的参数耦合。其准确率从 epoch 10 的 67.95% 提升到 epoch 50 的 76.05%，最终略高于 SimpleCNN，但显著低于 MicroResNet。该结果说明深度可分离卷积能够以较少的计算结构学习有效图像特征，但由于 depthwise 卷积逐通道处理空间信息，跨通道交互主要依赖 1×1 pointwise 卷积，表达能力通常弱于同宽度的标准卷积或残差网络。因此，MobileNet 的训练曲线较平稳，上限接近普通 CNN，优势更多体现在轻量化部署而非最高精度。

综合来看，普通 CNN 的训练瓶颈主要来自缺少跨层信息传递；ResNet 通过恒等跳跃连接改善优化路径，因此在中后期表现最佳；DenseNet 通过密集拼接复用特征，但需要足够增长率和深度才能充分发挥优势；MobileNet 通过深度可分离卷积降低计算成本，但会牺牲一部分表达能力。上述差异说明，CNN 结构改进并不只是增加层数，而是在优化稳定性、特征复用、计算效率和模型容量之间进行权衡。

7 问题与改进方向

实验中最主要的问题是模型容量与训练预算之间的平衡。SimpleCNN 容量不足，容易欠拟合；DenseNet 连接复杂但轻量配置不足，未体现原论文优势；Res2Net 的多尺度分支需要更深、更宽的网络才能充分表现。后续可以加入参数量、FLOPs 和推理时间统计，从准确率、计算成本和稳定性三个角度综合评价模型。此外，可以使用更强的数据增强策略，例如 Cutout、Mixup 或 RandAugment，并尝试 SGD+momentum 与 AdamW 的对比，以进一步提高 CIFAR-10 性能。

8 实验结论

本实验完成了 CIFAR-10 全量训练，并比较了五种 CNN 结构。结果表明，MicroResNet 以 84.92% 的测试准确率取得最佳效果，MicroRes2Net 次之，SimpleCNN 和 MicroMobileNet 处于中间水平，MicroDenseNet 在当前轻量配置下精度相对较低。通过训练曲线、准确率柱状图和混淆矩阵的联合分析，可以看出残差连接对优化稳定性和分类精度具有显著帮助。实验也说明，网络结构设计需要与数据规模、模型容量和训练策略共同考虑，单独引入某种连接方式并不必然带来最优效果。

参考文献

- [1] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-Based Learning Applied to Document Recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.
- [2] Alex Krizhevsky. Learning Multiple Layers of Features from Tiny Images. Technical Report, University of Toronto, 2009. <https://www.cs.toronto.edu/~kriz/learning-features-2009-TR.pdf>
- [3] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep Residual Learning for Image Recognition. In *CVPR*, 2016. https://www.cv-foundation.org/openaccess/content_cvpr_2016/html/He_Deep_Residual_Learning_CVPR_2016_paper.html
- [4] Gao Huang, Zhuang Liu, Laurens van der Maaten, and Kilian Q. Weinberger. Densely Connected Convolutional Networks. In *CVPR*, 2017. https://openaccess.thecvf.com/content_cvpr_2017/html/Huang_Densely_Connected_Convolutional_CVPR_2017_paper.html
- [5] Andrew G. Howard, Menglong Zhu, Bo Chen, Dmitry Kalenichenko, Weijun Wang, Tobias Weyand, Marco Andreetto, and Hartwig Adam. MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications. arXiv:1704.04861, 2017. <https://arxiv.org/abs/1704.04861>
- [6] Shang-Hua Gao, Ming-Ming Cheng, Kai Zhao, Xin-Yu Zhang, Ming-Hsuan Yang, and Philip Torr. Res2Net: A New Multi-scale Backbone Architecture. *IEEE TPAMI*, 43(2):652–662, 2021. <https://arxiv.org/abs/1904.01169>
- [7] Adam Paszke et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library. In *NeurIPS*, 2019. <https://arxiv.org/abs/1912.01703>