



南开大学
Nankai University

深度学习及应用实验报告

生成对抗网络实验

课程名称：深度学习及应用

学院：密码与网络空间安全学院

姓名：金莫迪

学号：2312578

日期：2026 年 6 月 29 日

目录

1	实验目的	2
2	数据集与实验配置	2
3	模型原理	3
3.1	MLP-GAN 结构	3
3.2	DCGAN 结构	4
4	实验过程	5
5	实验结果与可视化	5
6	结果分析与讨论	8
6.1	不同随机数调整对生成结果的影响	8
7	问题与改进方向	9
8	实验结论	9
	参考文献	10

表 1: GAN 实验训练配置

项目	设置
数据集	FashionMNIST 全量训练集 60000 张
图像尺寸	$1 \times 28 \times 28$, 归一化到 $[-1, 1]$
潜变量维度	100
模型	MLP-GAN、DCGAN
MLP-GAN 轮次	30 epoch
DCGAN 轮次	50 epoch
损失函数	二元交叉熵损失
标签平滑	真实标签使用 0.9
优化器	Adam
运行设备	CUDA

1 实验目的

本实验实现并训练生成对抗网络，用于从随机潜变量生成 FashionMNIST 服饰图像。实验目标包括：理解生成器与判别器的极小极大博弈机制，掌握 GAN 的交替优化流程，比较全连接 MLP-GAN 与卷积式 DCGAN 在图像生成质量上的差异，并通过损失曲线、生成样本和潜变量插值分析模型表现。GAN 由 Goodfellow 等提出 [1]，DCGAN 则将反卷积、批归一化和卷积判别器引入生成模型训练，为后续图像生成模型提供了经典结构范式 [2]。

本报告使用全量 FashionMNIST 训练集，共 60000 张灰度服饰图像。实验训练 MLP-GAN 30 个 epoch，训练 DCGAN 50 个 epoch，并保存真实样本、生成样本、loss 曲线和潜变量插值图。

2 数据集与实验配置

FashionMNIST 是 Zalando 发布的服饰图像数据集，包含 10 类 28×28 灰度图像，设计上可作为 MNIST 的更具挑战性替代数据集 [3]。图 1 展示了本实验使用的真实样本。相比手写数字，服饰图像在轮廓、纹理和局部细节上更加复杂，因此更能检验生成模型是否学到数据分布。

表 1 给出了训练设置。



图 1: FashionMNIST 真实样本

3 模型原理

GAN 包含生成器 G 与判别器 D 。生成器将随机噪声 z 映射为生成图像 $G(z)$ ，判别器判断输入图像来自真实数据分布还是生成分布。经典 GAN 的目标函数为：

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z} [\log(1 - D(G(\mathbf{z})))] \quad (1)$$

式 (1) 表示判别器希望提升真假区分能力，而生成器希望欺骗判别器。两者交替优化，最终使生成分布逐步接近真实数据分布。

图 2 展示了两类结构的核心思想。本实验的 MLP-GAN 对应原始版本 GAN 的全连接网络结构，使用全连接层完成 $100 \rightarrow 784$ 的映射，判别器也由全连接网络构成；DCGAN 是在原始 GAN 对抗训练框架上的卷积化调整，使用 ConvTranspose2d 逐步上采样，并使用卷积判别器提取空间特征。由于图像具有明显空间结构，DCGAN 理论上比 MLP-GAN 更容易生成连续、平滑且具有局部一致性的样本。

3.1 MLP-GAN 结构

MLP-GAN 是本实验的基础生成对抗模型。生成器输入 100 维随机噪声 z ，先经过全连接层映射到 128 维隐藏表示，再通过第二个全连接层输出 784 维向量，最后 reshape 为




图 2: GAN 与 DCGAN 论文结构图

$1 \times 28 \times 28$ 图像。输出层使用 Tanh，使生成图像像素值与归一化后的真实图像保持在同一范围 $[-1, 1]$ 。

MLP 判别器首先将图像展平成 784 维向量，经过 128 维隐藏层和 LeakyReLU 激活后输出一个标量概率。该概率表示输入图像来自真实数据而非生成器的可能性。MLP-GAN 的优点是结构清晰、便于理解对抗训练机制；局限在于展平图像会破坏二维空间邻域关系，因此生成样本容易出现边界不连续和局部纹理粗糙的问题。

以下代码为原始网络结构。本实验的 MLP-GAN 保留了该原始全连接生成器和判别器结构，并在 FashionMNIST 全量训练集上重新训练和可视化。

Listing 1: 原始 GAN notebook 中生成器与判别器的结构打印结果

```

1 Discriminator(
2     (fc1): Linear(in_features=784, out_features=128, bias=True)
3     (nonlin1): LeakyReLU(negative_slope=0.2)
4     (fc2): Linear(in_features=128, out_features=1, bias=True)
5 )
6 Generator(
7     (fc1): Linear(in_features=100, out_features=128, bias=True)
8     (nonlin1): LeakyReLU(negative_slope=0.2)
9     (fc2): Linear(in_features=128, out_features=784, bias=True)
10 )

```

3.2 DCGAN 结构

DCGAN 在生成器和判别器中都使用卷积结构。生成器先将 100 维噪声看作 $100 \times 1 \times 1$ 的特征张量，通过转置卷积逐步上采样：第一层生成 $64 \times 7 \times 7$ 特征图，第二层生成 $32 \times 14 \times 14$ 特征图，最后输出 $1 \times 28 \times 28$ 灰度图像。中间层使用 BatchNorm 和 ReLU，输出层使用 Tanh。

DCGAN 判别器与生成器方向相反：输入图像先经过卷积下采样到更小的特征图，再经 BatchNorm、LeakyReLU 和线性层输出真假概率。卷积判别器能够关注局部边缘、轮廓和纹理，转置卷积生成器也能逐步组织空间结构。因此，与 MLP-GAN 相比，DCGAN 更适合 FashionMNIST 这类具有明确二维结构的图像数据。

表 2: GAN 模型结构对比

模型	生成器结构	判别器结构	结构特点
MLP-GAN	Linear(100,128) + Linear(128,784) + Tanh	Flatten + Linear(784,128) + Linear(128,1)	简单直观, 但忽略图像空间结构
DCGAN	ConvTranspose2d 逐级上采样, $1 \rightarrow 7 \rightarrow 14 \rightarrow 28$	Conv2d 逐级下采样后分类	保留局部空间关系, 生成样本更平滑




图 3: GAN 交替训练流程

表 2 总结了两类 GAN 的结构差异。由于 FashionMNIST 的类别主要由轮廓和局部形状决定, DCGAN 的卷积归纳偏置更符合数据特点。

4 实验过程

训练过程中, 每个 batch 先用真实图像和生成图像更新判别器, 再固定判别器更新生成器。判别器的真实标签采用 0.9 标签平滑, 以避免判别器过早过强导致生成器梯度不足。生成器输出层使用 Tanh, 使生成图像范围与归一化后的真实图像一致。

图 3 概括了本实验训练过程。与分类任务不同, GAN 的损失曲线存在动态平衡关系: 生成器 loss 和判别器 loss 的短期波动并不必然意味着模型退化, 需要结合样本质量共同判断。

为了满足随机数控制实验要求, 本实验在训练完成后固定一组自定义随机噪声。首先生成 8 个 100 维随机向量, 分别输入 MLP-GAN 和 DCGAN, 得到图 5 中的 8 张生成图像。随后保持这 8 个基础随机向量的其余维度不变, 选择第 0、3、7、21、42 共 5 个随机维度, 分别将每个维度设置为 -2、0、2 三个取值。这样每个维度产生 3×8 张图像, 5 个维度共生成 15×8 张图像, 用于观察单个潜变量维度变化对生成结果的影响。


5 实验结果与可视化

表 3 给出了最终记录的 loss。需要注意, GAN 的 loss 不是单调评价指标。DCGAN 的生成器 loss 较高, 并不意味着图像质量更差, 而是反映了判别器在训练后期仍具有较强区分能力。


图 4 显示了两类模型的对抗训练动态。MLP-GAN 的两条曲线相对接近, 说明生成器

表 3: GAN 全量训练结果概览

模型	训练轮次	最后记录判别器 loss	最后记录生成器 loss	主要观察
MLP-GAN	30	1.0236	1.1497	可生成大致服饰轮廓，但细节较模糊
DCGAN	50	0.8176	1.7900	轮廓更完整，潜空间变化更连续



(a) MLP-GAN loss 曲线



(b) DCGAN loss 曲线

图 4: GAN 训练损失曲线

和判别器较快进入弱平衡；DCGAN 的波动更明显，但这也与卷积模型容量更强、判别器学习到更多图像纹理有关。



(a) MLP-GAN 生成样本



(b) DCGAN 生成样本

图 5: 最终生成样本对比

图 5 是判断生成质量的关键可视化。MLP-GAN 能生成鞋、衣服、包等大致形状，但边界和纹理较粗糙；DCGAN 的样本整体更接近真实 FashionMNIST 图像，部分样本在轮廓连续性和灰度过渡上更自然。


$z[0]=-2$ $z[0]=0$ $z[0]=2$ $z[3]=-2$ $z[3]=0$ $z[3]=2$ $z[7]=-2$ $z[7]=0$ $z[7]=2$ $z[21]=-2$ $z[21]=0$ $z[21]=2$ $z[42]=-2$ $z[42]=0$ $z[42]=2$ 

图 6: DCGAN 潜变量维度调整结果：每三行对应同一随机维度取值 $-2, 0, 2$ ，每列对应同一个基础噪声样本

表 4: 不同随机维度调整对生成图像的影响

调整维度	观察到的主要变化
z_0	对整体灰度和轮廓强度影响较明显。取值变化时，鞋靴类样本的边缘亮度和衣物主体的厚实程度发生变化，但类别语义基本保持不变。
z_3	主要影响局部形状和边缘弯曲程度。部分鞋类样本在鞋头、鞋帮轮廓上出现轻微变化，衣物样本的下摆和主体宽度也有调整。
z_7	对纹理和局部细节影响较强。取值升高后，部分样本出现更明显的内部纹理或局部高亮，说明该维度与细节强度有关。
z_{21}	对类别相关结构有一定影响。部分样本在靴子、鞋和包状轮廓之间出现形态过渡，表明该维度可能参与控制较高层语义属性。
z_{42}	对图像位置、宽窄比例和局部亮度均有影响，但变化相对平滑。多数样本保持原有类别，仅在姿态和厚度上发生调整。

图 6 和表 4 展示了 DCGAN 潜变量空间的局部可控性。每一列保持同一个基础噪声样本，只改变一个维度的取值；若相邻三行图像在主体类别保持稳定的同时出现轮廓、纹理或亮度的连续变化，说明生成器并非简单记忆训练样本，而是在潜空间中学习到了可连续调节的服饰属性。

6 结果分析与讨论

结合图 1、图 5 和图 6 可以看出，DCGAN 的生成质量整体优于 MLP-GAN。原因在于 FashionMNIST 图像虽然分辨率较低，但仍具有空间局部结构。全连接网络会把图像展平成向量，容易破坏像素邻域关系；卷积生成器则通过逐级上采样保留空间拓扑，使生成图像更平滑。

从图 4 看，两类 GAN 的 loss 都存在波动，这属于对抗训练的正常现象。判别器变强会提高生成器 loss，生成器改进又会降低判别器信心，因此不宜将某一条曲线的下降直接解释为模型整体变优。更可靠的判断方式是同时观察生成样本是否清晰、类别是否多样、潜空间插值是否连续。表 3 中 DCGAN 的生成器 loss 高于 MLP-GAN，但图 5b 和图 6 显示其生成结果更合理，说明 GAN 评价不应只依赖数值损失。

6.1 不同随机数调整对生成结果的影响

GAN 的输入噪声是 100 维向量，理论上每个维度都可能对应生成图像中的某类潜在因素。由于训练过程中没有显式标签约束，单个随机维度通常不会严格对应“鞋”“包”“衣服”等明确类别，而是更常表现为多个视觉属性的组合控制。图 6 中的 15 组结果说明，第 0、3、7、21、42 维的变化都会影响生成图像，但影响方式并不完全相同。

从低层视觉属性看，部分维度主要控制灰度强弱、边缘清晰度和局部纹理。例如 z_0 和 z_7 改变时，图像主体的亮度、边缘厚度和内部纹理强度更容易发生变化；这类维度更接近

生成器中低层特征的调节因素。从形状属性看， z_3 和 z_{42} 的变化会影响鞋类轮廓、衣物宽窄和局部姿态，但多数样本仍保留原类别，说明这些维度更可能控制连续形态属性。从语义属性看， z_{21} 的变化对部分样本的类别相关结构影响更明显，个别图像在鞋、靴或包状轮廓之间出现过渡，表明该维度可能参与较高层语义方向。

需要注意的是，随机维度的作用不是完全独立的。生成器由多层非线性网络组成，最终图像由 100 个维度共同决定。单独改变一个维度时，其他 99 个维度仍然固定，因此观察到的是该维度在当前局部潜空间附近的影响。不同基础噪声样本对应不同位置，同一维度在不同列上产生的变化幅度也不完全一致。这说明 GAN 学到的是连续潜在流形，而不是人工可解释的一维开关。总体而言，随机数调整实验表明 DCGAN 的潜空间具有一定结构性：部分维度偏向控制亮度和纹理，部分维度偏向控制形状和姿态，少数维度会对类别语义产生更明显影响。

本实验也暴露出 GAN 训练的难点。部分生成样本仍然模糊，类别边界不清晰，说明模型还没有完全学到 FashionMNIST 的多模态分布。若训练更深的 DCGAN 或加入条件标签，可以进一步控制生成类别并提升样本质量。

7 问题与改进方向

GAN 训练容易出现模式崩溃、判别器过强和 loss 震荡等问题。本实验通过真实标签平滑缓解判别器过强，但仍存在部分类别生成不足的现象。后续可以尝试 Conditional GAN，使生成器在类别标签控制下生成指定服饰；也可以使用 WGAN-GP 改善训练稳定性，或引入 FID、Inception Score 等定量生成质量指标。对于 FashionMNIST，还可以保存固定噪声在不同 epoch 的生成结果，进一步观察同一潜变量如何逐步成形。

8 实验结论

本实验完成了 FashionMNIST 全量训练下的 MLP-GAN 与 DCGAN 对比。结果表明，MLP-GAN 能学习到服饰的大致轮廓，但图像细节和空间连续性不足；DCGAN 借助卷积和转置卷积结构，生成样本更清晰，潜变量插值也更连续。实验结果说明，GAN 的核心不是单模型优化，而是生成器与判别器之间的动态博弈；评价 GAN 时需要综合 loss 曲线、样本可视化和潜空间行为，而不应只依赖最终损失数值。

参考文献

- [1] Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative Adversarial Nets. In *NeurIPS*, 2014. <https://papers.neurips.cc/paper/5423-generative-adversarial-nets>
- [2] Alec Radford, Luke Metz, and Soumith Chintala. Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks. In *ICLR*, 2016. <https://arxiv.org/abs/1511.06434>
- [3] Han Xiao, Kashif Rasul, and Roland Vollgraf. Fashion-MNIST: A Novel Image Dataset for Benchmarking Machine Learning Algorithms. arXiv:1708.07747, 2017. <https://arxiv.org/abs/1708.07747>
- [4] Adam Paszke et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library. In *NeurIPS*, 2019. <https://arxiv.org/abs/1912.01703>