



南開大學
Nankai University

密码与网络空间安全学院
深度学习及应用（高阶课）实验报告

卷积神经网络

姓名：陈培杰

学号：2312991

专业：信息安全

2026 年 5 月 23 日

目录

1 网络结构设计	1
2 实验结果	3
2.1 训练曲线对比	3
2.2 测试集准确率	3
2.3 性能指标对比	4
2.4 深层特征空间可视化分析 (t-SNE)	5
2.5 浅层特征分析	6
3 网络架构演进与训练差异分析	6
3.1 不同结构网络在训练过程中的差异分析	6
3.2 扩展部分: Res2Net 实现及其与主流网络的优劣势对比	7

1 网络结构设计

老师提供的模型记为 SimpleNet,我自己实现的几个模型分别命名为 CustomNet、ResNet、DenseNet、MobileNet 和作为扩展练习的 Res2Net。

1. SimpleNet 网络结构

本实验中的 SimpleNet 模型主要由 encoder 和 fc 两个模块组成(这两个模块是我命名的,网络结构逻辑和老师的是一样的)。具体的网络层级和参数配置打印如下:

```
1 SimpleNet(  
2     (encoder): Sequential((0): Conv2d(3, 6, kernel_size=(5, 5), stride=(1, 1))  
3         (1): ReLU()  
4         (2): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)  
5         (3): Conv2d(6, 16, kernel_size=(5, 5), stride=(1, 1))  
6         (4): ReLU()  
7         (5): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False))  
8     (fc): Sequential((0): Flatten(start_dim=1, end_dim=-1)  
9         (1): Linear(in_features=400, out_features=120, bias=True)  
10        (2): ReLU()  
11        (3): Linear(in_features=120, out_features=84, bias=True)  
12        (4): ReLU()  
13        (5): Linear(in_features=84, out_features=10, bias=True)))
```

针对上述结构,各部分的具体功能解释如下:

- **Encoder:** 采用经典的双层卷积池化级联结构。首层通过 5×5 卷积 (3→6 通道)、ReLU 激活及 2×2 最大池化完成浅层特征提取与初步下采样;第二层结构一致,进一步提维至 16 通道并再次空间降维。
- **FC:** 首先由 Flatten 操作将多维特征图展平为一维向量(长度为 400);随后经三层 Linear 进行分类映射,特征维度按 $400 \rightarrow 120 \rightarrow 84 \rightarrow 10$ 逐级递减。前两级隐层均接入 ReLU,末层直接输出 10 维的类别预测结果。

2. CustomNet

在 [3] 中，作者使用 NAS 来搜索 MobileNetV3 的主干框架，受此启发，我将写好的卷积模块放到 NAS 中也进行搜索得到网络主干。

采用的是基于 SuperNet 的 NAS 方法 [4]。实验过程中会出现 SkipConnect Collapse 问题，因此我采用了 2 种策略来改进：使用 *Sigmoid* 替代 *Softmax*，并引入 $0-1$ Penalty[2]；在 Discretization 阶段采用基于全局阈值的 Hard Truncation 策略 [1]。

然后阐述一下网络主干。主要使用了 Conv-BN-ReLU 基础提取块（含无偏置卷积、批归一化与激活函数）。网络主干采用通道倍增的金字塔排布，依次为：初始 3×3 卷积（32 通道）；**Layer 1** 包含 1 个 5×5 与 4 个 3×3 卷积块（64 通道）；**Layer 2** 包含 5 个 3×3 卷积块（128 通道）；**Layer 3** 包含 3 个 3×3 卷积块（256 通道），此三层末端均接 2×2 最大池化进行下采样；**Layer 4** 包含 1 个 5×5 与 1 个 3×3 卷积块提维至 512 通道。末端经自适应全局平均池化压缩特征图，最后由全连接层输出分类结果。

3. ResNet

主要使用了 BasicBlock 残差块（主分支为双 3×3 卷积序列，空间下采样或通道数改变时，残差边采用 2×2 平均池化配合 1×1 卷积进行投影映射）。网络主干采用紧凑的四阶段特征金字塔排布：输入图像首先经 3×3 初始卷积；随后依次级联四个残差阶段（**Layer 1-4**），分别包含 **2、3、4、2** 个 BasicBlock。其中，第一阶段特征图分辨率与通道数（64）保持不变；后三个阶段的首个 Block 均执行步长为 2 的下采样，并将通道数逐层倍增（依次至 128、256、512 通道）。网络末端通过 AdaptiveAvgPool2d 将空间维度压缩至 1×1 ，展平后由单层全连接层直接输出分类结果。

4. DenseNet

主要由 _DenseBlock 与 _Transition 级联构成。核心特征层 _DenseLayer 采用 BN-ReLU-Conv(1×1)-BN-ReLU-Conv(3×3) 的 Bottleneck 结构，利用 1×1 卷积降维 (bn_size=4)，再通过通道拼接按设定增长率 (growth_rate=8) 逐层累加特征，并引入可选的 Dropout 防止过拟合。网络主干采用交替排布：首层经 3×3 卷积（含 BN 与 ReLU）提取基础特征（64 通道）；主体串联 4 个 _DenseBlock（分别包含 **6、12、32、32** 个子层），前三个 Block 后均衔接 _Transition 层（由 BN-ReLU- 1×1 卷积与 2×2 平均池化构成），执行空间下采样并强制通道数减半以压缩模型特征；网络末端依次经 BN、ReLU 与自适应全局平均池化（压缩至 1×1 ），最终展平并由单层全连接层输出分类结果。

5. MobileNet

主要采用深度可分离卷积块。该结构将标准卷积解耦为 3×3 DW 卷积与 1×1 PW 卷积（均接 BN 与 ReLU），大幅降低了参数量与计算复杂度。网络主干采用如下排布：首层经 3×3 标准卷积（含 BN 与 ReLU）提维至 32 通道；主体级联 13 个深度可分离卷积块。网络遵循“下采样（步长为 2）时通道数倍增，后接同维度 Block”的设计范式，通道数随下采样逐次递增（ $32 \rightarrow 64 \rightarrow 128 \rightarrow 256 \rightarrow 512 \rightarrow 1024$ ），其中在 512 通道阶段连续堆叠了 5 个不改变特征图尺寸的 Block。末端经自适应全局平均池化与 Dropout(0.2) 抑制过拟合，最终展平并由全连接层输出分类结果。此外，全网卷积层统一采用了 Kaiming 正态分布策略进行参数初始化。

6. Res2Net

主要使用了 Res2NetBlock。该结构在 1×1 卷积降维后，将特征图沿通道维度划分为 4 个子集 $xs[0]$ 至 $xs[3]$ ，并依次生成对应的特征输出 $ys[0]$ 至 $ys[3]$ ： $xs[0]$ 仅作直接映射（若需下采样则经过 3×3 平均池化）； $xs[1]$ 独立经过 3×3 卷积； $xs[2]$ 与 $xs[3]$ 在非下采样 (stride=1) 时，依次与前一支的输出 ($ys[1]$ 、 $ys[2]$) 按元素相加融合后，再分别经过 3×3 卷积，而在下采样 (stride=2) 时则跳过融合、直接进行卷积。最终将 4 个分支的 ys 沿通道维度拼接并激活，由 1×1 卷积升维，最后与残差边（下采样时辅以 2×2 平均池化与 1×1 映射）相加并激活。网络主干采用四阶段金字塔排

布：首层标准 3×3 卷积提维至 64 通道；主体依次级联四个特征阶段（分别包含 **2、3、4、2** 个 Block），后三个阶段的首个 Block 执行下采样（**stride=2**）并伴随通道数逐次倍增（ $64 \rightarrow 128 \rightarrow 256 \rightarrow 512$ ）；末端经自适应全局平均池化压缩空间维度，展平后由单层全连接层输出分类预测。

2 实验结果

2.1 训练曲线对比




图 2.1: model_comparison_lines

图 2.1 展示了各模型在 50 个 Epoch 下的训练集损失、验证集损失以及验证集准确率的对比曲线。

1. 训练集损失分析。从训练集损失曲线（左图）可以看出，随着迭代次数的增加，所有模型的损失均呈下降趋势。其中，SimpleNet 收敛速度最慢，且最终损失停留在较高水平，存在一定的欠拟合现象；相比之下，ResNet、DenseNet、Res2Net 以及 CustomNet 均展现出极强的数据拟合能力，损失曲线迅速断崖式下降，并在 15 个 Epoch 后基本逼近于 0；MobileNet 的训练损失也在中后期收敛至较低状态。

2. 验证集损失分析。验证集损失曲线（中图）直观地揭示了各模型的泛化差异。MobileNet 在此任务上呈现出严重的过拟合现象，其验证损失在最初几个 Epoch 短暂下降后急剧反弹攀升，最终高达 30 左右；SimpleNet 的验证损失相对平稳，但整体数值偏高（维持在 10 以上）；而 CustomNet、ResNet、DenseNet 与 Res2Net 的验证损失均保持在较低区间（约 6 至 12 之间），整体泛化性能良好。

3. 验证集准确率分析。验证集准确率曲线（右图）进一步印证了上述结论。MobileNet 与 SimpleNet 的分类表现较差，最高准确率分别仅停留在 55% 与 65% 左右。而 CustomNet、ResNet、DenseNet 与 Res2Net 的准确率曲线高度交织，在 10 个 Epoch 后迅速攀升，最终均稳定收敛在 80% 至 88% 之间的较高水平。

2.2 测试集准确率

为进一步验证各模型在未见数据上的泛化能力，我们统计了模型在测试集上的最终分类准确率，具体数据如表 1 所示。

表 1: 各模型测试集准确率对比

网络模型 (Model)	测试集准确率 (Test Accuracy)
SimpleNet	63.82%
CustomNet	84.75%
ResNet	85.86%
DenseNet	83.68%
MobileNet	53.98%
Res2Net	86.84%

结果分析:

由上表可知, 不同架构的网络模型在测试集上的表现差异显著, 具体表现如下:

- **主流深层网络表现稳健:** Res2Net 取得了本实验最高的测试集准确率 (86.84%), 这得益于其在细粒度级别的多尺度特征提取能力。经典的 ResNet 同样表现出众, 准确率达到 85.86%。DenseNet 虽然在参数利用率上较高, 但在本任务中准确率 (83.68%) 略逊于 ResNet 类架构。
- **CustomNet 搜索效果显著:** 值得重点关注的是, 基于 NAS 方法自主搜索构建的 CustomNet 在测试集上取得了 84.75% 的优异成绩。该结果不仅超越了经典的 DenseNet, 且与 ResNet 的表现非常接近。这充分证明了本实验引入的 0-1 Penalty 与 Hard Truncation 等策略有效缓解了架构搜索中的 Collapse 问题, 搜索得到的主干网络具备强大的特征表达与泛化能力。
- **轻量化与简单网络存在局限:** SimpleNet 由于网络层数较浅、结构过于简单, 特征提取能力有限, 仅取得 63.82% 的准确率, 未能充分拟合数据。而 MobileNet 的测试集准确率垫底, 仅为 53.98%, 结合验证集损失曲线可知, 该轻量化模型在本数据集上出现了严重的过拟合现象, 导致其在测试集上的泛化性能大幅下降。

2.3 性能指标对比

为了全面评估各网络模型的运行效率与计算资源消耗, 本实验在相同硬件环境下, 对各模型的 Params、FLOPs、Latency 以及峰值显存占用进行了测量与统计。具体对比数据如表 2 所示。

表 2: 各模型性能指标与计算资源消耗对比

网络模型	Params (M)	FLOPs (G)	Latency (ms)	Peak Mem (MB)
SimpleNet	0.06	0.001	0.30	9.38
CustomNet	7.98	1.12	3.38	59.69
ResNet	13.83	1.57	5.67	78.77
DenseNet	0.87	0.19	33.32	21.36
MobileNet	3.22	0.10	3.71	33.46
Res2Net	6.42	0.78	13.98	43.94

结果分析:

由表 2 可知, 不同网络架构在计算复杂度与实际运行效率上呈现出显著差异, 具体分析如下:

- **理论复杂度 (Params & FLOPs):** 作为传统的深层网络, ResNet 的参数量 (13.83M) 和计算量 (1.57G) 均居于首位。DenseNet 凭借特征重用机制极大地减少了参数量 (仅 0.87M); 而 MobileNet 则依托深度可分离卷积, 将 FLOPs 大幅压缩至 0.10G, 体现了其轻量化设计的初衷。

- **实际推理延迟 (Latency):** 实验数据表明, 理论计算量与实际运行速度并不完全成正比。DenseNet 虽然参数量与 FLOPs 极低, 但由于频繁的张量拼接操作导致内存访问成本过高, 其推理延迟高达 33.32 ms, 为全场最高。Res2Net 同样因复杂的细粒度多分支操作 (Split-Transform-Merge), 导致推理延迟增加至 13.98 ms。
- **CustomNet 的效能优势:** 结合前文的准确率表现, 本文基于 NAS 搜索构建的 **CustomNet** 展现出了极佳的综合效能。其参数量 (7.98M) 与计算量 (1.12G) 均约为 ResNet 的一半, 同时峰值显存占用控制在合理的 59.69 MB。更为突出的是, CustomNet 的推理延迟仅为 3.38 ms, 不仅大幅快于同级别的 ResNet 与 Res2Net, 甚至略优于主打移动端的 MobileNet (3.71 ms)。

2.4 深层特征空间可视化分析 (t-SNE)

为了直观探究各模型在特征提取层面的深层差异, 本实验提取了各个网络在送入最终分类器 (全连接层) 前的高维特征, 并利用 t-SNE 算法将其降维至二维空间进行散点图可视化。图 2.2 展示了测试集中各类别样本 (共计 10 类) 在不同模型特征空间中的分布情况。

结果分析:




图 2.2: tsne_clusters

结合可视化图像, 我们可以得出以下关键结论:

- **特征混叠严重 (SimpleNet 与 MobileNet):** 观察 SimpleNet 和 MobileNet 的特征分布图可以发现, 不同类别样本的特征点大量交织重叠, 基本呈弥散状态, 缺乏清晰的决策边界。这表明这两种模型未能有效学习到具有强判别性的深层特征。这一视觉现象与前文提及的 SimpleNet 特征提取能力不足 (欠拟合) 以及 MobileNet 遭遇的严重过拟合问题高度吻合, 解释了它们测试集准确率较低的根本原因。
- **聚类效果显著 (ResNet、DenseNet 与 Res2Net):** 主流深层网络展现出了极其强大的特征表征能力。在这三个模型的降维空间中, 同类样本紧密聚集 (类内方差小), 不同类别之间形成了

明显的拓扑间隔（类间距离大）。特别是 **Res2Net**，其各个特征簇结构最为紧密、边界最为分明，这为其取得最高的测试集准确率（86.84%）提供了强有力的底层特征支撑。

- **CustomNet 表征能力优越**：值得重点强调的是，本文基于 NAS 搜索构建的 **CustomNet** 同样呈现出了极为优异的聚类效果。其各个类别的特征分布清晰独立，成功分化出了与 ResNet 级别相媲美的高质量判别性特征簇。这充分证明，CustomNet 在大幅缩减参数量与推理延迟的同时，其提取特征的质量并未缩水，完美实现了模型轻量化与高精度的平衡。

2.5 浅层特征分析




图 2.3: 不同卷积神经网络浅层特征图对比（可视化）

图 2.3 展示了 CustomNet、ResNet 和 Res2Net 在处理同一输入图像（汽车）时的前端卷积层浅层特征图集合。这些可视化结果一致呈现出典型浅层卷积层对高分辨率边缘、角点和局部空间细节的强力捕捉能力。

网络间存在细微但关键的表征差异：传统 ResNet（图 2.3b）的特征图集中于捕捉特定的垂直和水平梯度边界，呈现出较强的线型检测属性；而 CustomNet（图 2.3a）由于其网络结构是通过 NAS 搜索得到的，其特征图显示出更强的边缘强化效果，多个通道生成了极其锐利的轮廓和细节；相比之下，Res2Net（图 2.3c）利用其特有的子组多尺度分支结构，所生成的特征图表现出更丰富的纹理多样性。

3 网络架构演进与训练差异分析

3.1 不同结构网络在训练过程中的差异分析

针对无跳跃连接网络（SimpleNet / CustomNet）、ResNet、DenseNet、MobileNet 以及 Res2Net，结合本实验的损失收敛曲线、精度表现与算力消耗数据，总结出以下核心架构差异：

- **直连结构网络（SimpleNet / CustomNet）**：信息流与梯度呈单向逐层传递。结构极浅的 **SimpleNet** 因模型容量严重不足，在此分类任务中呈现出明显的**欠拟合**现象（训练集损失收敛极其缓慢，验证集准确率仅勉强达到 63.82%）。相比之下，**CustomNet** 取得比肩深度网络的泛化精度（84.75%），还能将参数量（7.98 M）和延迟（3.38 ms）控制在极佳的平衡点。
- **ResNet**：其训练集损失下降梯度极陡，且快速收敛至接近 0 的极低水平，验证集表现平稳，最终取得了 85.86% 的高测试精度。其卓越的特征拟合能力背后的代价是全场最高的参数量（13.83 M）与算力开销（1.57 G FLOPs）。

- **DenseNet**: 具备卓越参数利用率 (仅需 0.87 M 参数即可达到 83.68% 的精度)。然而, 实验性能数据揭示了该架构在实际运行中的局限性: 频繁的张量拼接操作引发了巨大的内存访问成本, 导致其虽然理论计算量极小 (0.19 G FLOPs), 但实际推理延迟却高达 33.32 ms, 为所有模型中最慢。
- **MobileNet**: 但在此次实验中, 大幅度的参数缩减无可避免地削弱了网络的绝对特征表达容量, 导致模型陷入了**极其严重的过拟合状态** (验证集损失在中后期剧烈反弹至 30 左右, 测试集精度垫底, 仅为 53.98%)。这表明轻量化范式在特定复杂数据分布下表征瓶颈明显, 对正则化策略高度敏感。
- **Res2Net**: 斩获了全场最高的测试精度 (86.84%)。相较于标准 ResNet, 其参数量大幅缩减至 6.42 M, 但受限于复杂的多分支切分与融合操作, 其实际推理延迟 (13.98 ms) 高于 CustomNet 与 ResNet。

3.2 扩展部分: Res2Net 实现及其与主流网络的优劣势对比

1. 优势分析

Res2Net 通过在残差块内引入多尺度层级特征表示, 显著提升了模型的表征能力:

- **相比 ResNet: 更大的多尺度感受野**
采用通道分组与级联 3×3 卷积处理, 在几乎不增加 Params(M) 和 FLOPs(G) 的前提下, 同步捕获细粒度与全局结构特征, 其等效感受野远超传统瓶颈块中的单一卷积。
- **相比 DenseNet: 更优的显存效率与模块化**
DenseNet 的全局密集拼接会导致极高的峰值显存占用。Res2Net 将层级特征融合限制在 Block 内部, 既实现了局部多级特征复用, 又避免了全网特征堆积引发的显存灾难, 更利于网络加深。
- **相比 MobileNets: 更高的表征能力上限**
MobileNets 高度依赖深度可分离卷积, 牺牲了通道间信息交互。Res2Net 分组处理时保留了标准卷积逻辑, 提取的多尺度特征辨识度更高, 在面对复杂视觉任务时具有显著的精度上限优势。

2. 劣势分析

尽管多尺度表征优势显著, Res2Net 在算子运行效率与实际部署上仍存局限:

- **相比 ResNet: 推理延迟增加与高访存开销**
分组级联引入了序列依赖性 (后一组需等待前一组结果), 破坏了单一卷积的高效并行计算。频繁的张量切分与拼接增加了内存访问代价, 导致在 GPU 等并行设备上, 其实际 Latency(ms) 明显长于同等 FLOPs 的 ResNet。
- **相比 MobileNets: 移动端适配性较差与显存负担重**
缺乏底层算子的极限压缩机制, 难以在极低 Params(M) 下部署。此外, Block 内细碎的分支结构在前向传播时产生大量中间激活值, 导致计算图变复杂且 Peak Memory(MB) 偏高, 对显存受限的边缘设备不友好。
- **相比 DenseNet: 全局特征交互不足与参数分配冗余**
DenseNet 利用全局尺度信息流动与小增长率实现了极高的参数利用率。而 Res2Net 的特征融合仅局限于 Block 内部, 跨层连接仍沿用传统残差相加, 且主体通道扩充策略保留了 ResNet 的庞大设定, 缺乏深层全局复用机制, 参数紧凑度不及 DenseNet。

参考文献

- [1] Xin Chen, Lingxi Xie, Jugong Wu, and Qi Tian. Progressive differentiable architecture search: Bridging the depth gap between search and evaluation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 1294–1303, 2019.
- [2] Xiangxiang Chu, Tianbao Zhou, Bo Zhang, and Jixiang Li. Fairdarts: Eliminating unfair advantages in differentiable architecture search. In *European Conference on Computer Vision (ECCV)*, pages 465–480. Springer, 2020.
- [3] Andrew Howard, Mark Sandler, Grace Chu, Liang-Chieh Chen, Bo Chen, Mingxing Tan, Weijun Wang, Yukun Zhu, Ruoming Pang, Vijay Vasudevan, et al. Searching for mobilenetv3. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 1314–1324, 2019.
- [4] Hanxiao Liu, Karen Simonyan, and Yiming Yang. Darts: Differentiable architecture search. In *International Conference on Learning Representations*, 2019.