



南開大學
Nankai University

密码与网络空间安全学院
深度学习及应用（高阶课）实验报告

GAN

姓名：陈培杰
学号：2312991
专业：信息安全

2026 年 5 月 23 日

目录

1 实验要求	1
2 网络结构	1
2.1 SimpleGAN 网络架构	1
2.2 DCGAN 网络架构	1
3 实验结果	2
3.1 训练对比	2
3.2 不同训练阶段生成图像对比	3
3.3 自定义一组随机数，生成 8 张图	4
3.4 隐向量空间探索	4
3.5 定量评估与数据分布可视化	7

1 实验要求

1. 掌握 GAN 原理
2. 学会使用 PyTorch 搭建 GAN 网络来训练 FashionMNIST 数据集
3. 学会搭建 DCGAN 来训练 FashionMNIST 数据集

2 网络结构

2.1 SimpleGAN 网络架构

SimpleGAN 采用了最基础的 MLP 结构，其模型主要由 `nn.Linear` 线性层构成。

- **生成器**：网络接收维度为 100 的隐向量 z ，首先经过一个包含 128 个神经元的隐藏层，并使用 `LeakyReLU(negative_slope = 0.2)` 作为激活函数。随后，通过第二个线性层将其映射至 784 维，经 `Tanh` 激活函数将像素值归一化至 $[-1, 1]$ 区间，最后将一维向量 `reshape` 为 $1 \times 28 \times 28$ 的二维图像格式。
- **判别器**：输入为扁平化后的 784 维图像向量。网络经过一个具有 128 个神经元的隐藏层（使用 `LeakyReLU` 激活），最后由一个线性层输出 1 维标量，表示该输入为真实图像的置信度得分。

2.2 DCGAN 网络架构

DCGAN 采用了无池化层的全卷积架构。

- **生成器**：网络完全由转置卷积层构成。输入维度为 $100 \times 1 \times 1$ 的隐变量，逐层进行空间上采样与通道降维。特征图的具体演变过程为：

1. $100 \times 1 \times 1 \xrightarrow{\text{ConvTranspose2d (k=4, s=1, p=0)}} 256 \times 4 \times 4$
2. $256 \times 4 \times 4 \xrightarrow{\text{ConvTranspose2d (k=3, s=2, p=1)}} 128 \times 7 \times 7$
3. $128 \times 7 \times 7 \xrightarrow{\text{ConvTranspose2d (k=4, s=2, p=1)}} 64 \times 14 \times 14$

前置模块均配合 BatchNorm2d 与 ReLU 激活函数。最后一层通过转置卷积映射为 $1 \times 28 \times 28$ 单通道图像，并使用 Tanh 激活。

- **判别器：**网络完全由带步长的标准卷积层构成，利用步长 (stride = 2) 实现特征下采样。特征图的具体演变过程为：

1. $1 \times 28 \times 28 \xrightarrow{\text{Conv2d (k=4, s=2, p=1)}} 32 \times 14 \times 14$
2. $32 \times 14 \times 14 \xrightarrow{\text{Conv2d (k=4, s=2, p=1)}} 64 \times 7 \times 7$
3. $64 \times 7 \times 7 \xrightarrow{\text{Conv2d (k=3, s=2, p=1)}} 128 \times 4 \times 4$

为保证特征的有效提取，第一层不使用 BN，中间各块均配合 BatchNorm2d 与 LeakyReLU (0.2) 激活函数。最后利用一个 4×4 的卷积核进行全局映射，输出 1 维标量。

3 实验结果

3.1 训练对比

本实验在 FashionMNIST 数据集上对 SimpleGAN 和 DCGAN 分别进行了 60 个 Epoch 的训练。两者的生成器与判别器损失变化曲线如图 3.1 所示。




图 3.1: SimpleGAN 与 DCGAN 训练损失曲线对比 (左: 生成器, 右: 判别器)

损失曲线特征与对抗博弈分析

- **生成器损失 (G-Loss):** SimpleGAN 的 G-Loss 在前 10 个 Epoch 内从 0.6 快速攀升至 1.4, 随后震荡爬升并滞留在 1.6–1.7 高位, 表明生成器在与强势判别器的对抗中处于劣势。反之, DCGAN 的 G-Loss 虽初始值较高 (> 2.5), 但得益于卷积结构对空间特征的快速捕捉, 在前 10 个 Epoch 内即平滑下降并稳定在 0.8–0.9 的低位, 生成能力提升显著。
- **判别器损失 (D-Loss):** SimpleGAN 的 D-Loss 整体在 0.8 附近波动且伴随震荡, 反映出判别器过于强势, 二者未达成良好的博弈平衡。而 DCGAN 的 D-Loss 在初期快速攀升后, 长期平稳地维持在 1.2–1.25 之间, 该数值逼近理想对抗状态 (纳什均衡下理论损失约为 1.38), 证明其生成器与判别器形成了势均力敌的健康博弈。

对比表明, SimpleGAN 在图像特征提取和对抗稳定性上表现较弱; 而 **DCGAN** 凭借深度卷积架构, 展现出更快的收敛速度、更稳定的博弈动态以及更优的生成质量, 更适合处理二维图像生成任务。

3.2 不同训练阶段生成图像对比

为了直观评估生成器在训练过程中的学习效果，本实验分别提取了模型在第 1、5、10 和 15 个 Epoch 时的生成器权重，并让其生成随机噪声对应的图像进行对比。

SimpleGAN 生成效果演变

SimpleGAN 在不同训练阶段生成的图像如图 3.2 所示。




图 3.2: SimpleGAN 在不同训练 Epoch 下生成的 FashionMNIST 图像

效果分析:

- **Epoch 1:** 图像基本为无规律的随机噪点，生成器尚未学习到有效的数据分布。
- **Epoch 5:** 图像中心开始出现高亮区域，隐约可见衣物的粗略轮廓，但仍极其模糊。
- **Epoch 10 ~ 15:** 衣物（如上衣、裤子）的整体形状和边缘逐渐成型，模型已初步掌握了 FashionMNIST 图像的基础特征。但受限于全连接网络的结构劣势，生成的图像仍伴有明显的“椒盐”噪点，缺乏局部细节。

DCGAN 生成效果演变

与 SimpleGAN 的训练过程相对应，DCGAN 在相同 Epoch 下提取的生成图像如图 3.3 所示。




图 3.3: DCGAN 在不同训练 Epoch 下生成的 FashionMNIST 图像

效果分析:

- **Epoch 1:** 图像呈现出具有一定聚集性的模糊光块。虽然尚未形成清晰物体，但相比 SimpleGAN 同期的纯随机噪点，DCGAN 已经展现出了对局部空间特征的初步捕捉能力。
- **Epoch 5:** 已经能够非常清晰地辨认出衣物的类别和基本轮廓（如长袖、裤子、鞋子），模型的收敛速度和特征学习效率显著优于 SimpleGAN。
- **Epoch 10 ~ 15:** 生成图像的边缘逐渐变得锐利，内部的灰度分布与细节（如袖口、鞋底轮廓）更加丰富且自然。得益于卷积网络（CNN）强大的空间结构建模能力，DCGAN 生成的样本基本消除了明显的噪点，视觉逼真度和多样性远超全连接架构的 SimpleGAN。

横向对比两种网络的演变过程可以得出结论：**DCGAN 的网络架构在处理图像数据时具有压倒性优势**。其生成器能够更快地从随机隐变量中映射出具有高层语义的二维空间结构，而判别器也能提供更精准的梯度指导，最终产出了高质量、低噪声的 FashionMNIST 伪造样本。

3.3 自定义一组随机数，生成 8 张图

为了更直观地评估训练完成后模型的生成能力，本实验构建了一组包含 8 个样本的自定义随机噪声（隐向量），并分别输入至 SimpleGAN 和 DCGAN 的生成器中，其输出结果对比如图 3.4 所示。




图 3.4: 输入同一组自定义随机噪声后，两种模型生成的 8 张图像对比

对比分析

观察图 3.4 的输出结果，两种模型的生成能力存在显著的代差：

- **图像质量与细节再现：** SimpleGAN 的输出充斥着强烈的“椒盐”噪点，边缘极其模糊，仅能提供一个“类似衣物”的粗糙轮廓，缺乏任何实质性的纹理。而 DCGAN 的输出不仅背景干净，且边缘锐利、灰度过渡平滑，能够清晰地还原出袖口、领口、裤缝以及鞋帮等逼真的局部结构细节。
- **样本多样性与语义映射：** 在面对相同的一组随机输入时，SimpleGAN 生成的类别较为单一且难以辨认，表现出一定程度的模式崩塌倾向。相反，DCGAN 成功且准确地映射出了长袖上衣、短袖、裤子、连衣裙、包包和靴子等多种不同的 FashionMNIST 类别。

3.4 隐向量空间探索

本部分实验旨在探究生成模型是否将随机隐向量 z 映射到了具有明确意义的连续语义空间。实验固定了 8 组 100 维的基础随机噪声（列），并选取了第 10、30、50、70、90 维这 5 个特定维度。针对每个被选维度，依次将其数值强制替换为 -2.0 、 0.0 和 2.0 （其余维度保持不变），从而生成了 15×8 的图像网格（每 3 行为一维度的调整对比）。

SimpleGAN 隐空间映射分析

SimpleGAN 针对特定维度进行受控调整后生成的图像网格如图 3.5 所示。




图 3.5: SimpleGAN 隐空间探索（行：不同维度的 3 次取值变化；列：8 组不同基础噪声）

维度调整对生成结果的影响：

- **高度的特征纠缠：**观察图像的每一列可以发现，当改变单一隐变量维度（如从 -2.0 变至 2.0 ）时，生成图像并没有呈现出局部特征（如衣物袖长、领口形状）的有规律微调，而是发生了整体轮廓、全局亮度及噪点分布的剧烈且无序的改变。
- **缺乏语义解耦与连续性：**这种现象的本质在于 SimpleGAN 使用了全连接网络架构。在全连接层中，输入向量的每一维神经元都与输出图像的所有像素直接进行线性映射计算（即全局感受野）。这导致 z 中的各个维度高度纠缠，无法解耦出独立的语义属性。
- **非平滑的跳变：**部分样本在数值调整时，图像直接从“极暗的噪点图”突变为“极亮的模糊团块”，隐空间缺乏平滑过渡的特性，证明基础 GAN 在构建高质量的流形空间上能力有限。

DCGAN 隐空间映射分析

使用与 SimpleGAN 完全相同的 8 组基础噪声和 5 个维度的调整策略，DCGAN 生成的隐空间探索结果如图 3.6 所示。




图 3.6: DCGAN 隐空间探索 (行: 不同维度的 3 次取值变化; 列: 8 组不同基础噪声)

与 SimpleGAN “牵一发而动全身”的像素崩塌不同, DCGAN 展现出了极其优异的特征解耦能力, 修改单一随机数主要引发图像局部或特定高层语义的平滑改变:

- 第 1–3 行调整第 10 维

变化特征: 该维度主要影响类别的平滑过渡与局部重叠。

具体表现: 观察第 8 列 (长袖上衣), 随着数值增加, 袖子与躯干部分的间隙逐渐发生重叠融合; 第 2 列高跟靴的整体形状从变形到规整, 鞋帮的厚度呈现出微调; 第 5 列的高跟鞋从变形 (垂直方向拉长) 到逐渐规整; 第 6 列发生了显著的跨类别渐变, 从类似长裤的形态 (第 1 行) 逐渐变成了高跟鞋 (第 3 行)。

- 第 4–6 行调整第 30 维

变化特征: 该维度的变化明显控制了物体的局部几何形态走向与角度。

具体表现: 例如第 3 列 (长裤), 其裤腿的宽窄和整体笔直程度在数值变化中发生了明显的过渡; 第 5、6 列 (高跟凉鞋) 的鞋跟倾斜角度以及鞋面的包裹面积也随之出现了平滑的偏移。

- 第 7–9 行调整第 50 维

变化特征: 该维度似乎更偏向于控制物品的细节结构与纹理特征。

具体表现：第 4 列（包包），随着数值的改变，其顶部的闭合结构、提手部分以及表面的花纹发生了形变；第 5 列（凉鞋）的脚踝绑带粗细也呈现出由模糊到清晰的连续变化。

- **第 10–12 行调整第 70 维**

变化特征：该维度的剧烈变化会导致部分生成结果的语义崩塌或大幅度跨物种形变。

具体表现：以第 2、5、6 列为例，在第 10 行（数值 -2.0 ）时仍保持清晰的高跟靴形态，但到第 12 行（数值 2.0 ）时，靴子顶部被极度拉伸变形，视觉轮廓上已经异化得像是一件上衣。

- **第 13–15 行调整第 90 维**

变化特征：此维度主要控制物体的尺度、比例和量感。

具体表现：当改变此数值时，第 2 列（靴子）的鞋底厚度和鞋跟粗细发生了显著的增减；第 8 列（上衣）肩部的宽阔感也有所改变，呈现出类似“服装尺码大小（S 码到 L 码）”的渐变效果。

特殊现象分析（第 5、6 列样本）

在整个探索过程中，第 5、6 列样本表现出了极强的不稳定性。无论是在第 10, 30, 70 还是 90 维的调整中，它都在发生剧烈的形状变化：有时看上去像一条长裤，有时又变成了款式各异（带子数量不同）的高跟凉鞋或长裙，有时是被扭曲拉长的高跟鞋。

这说明高跟鞋对应的基准隐向量恰好位于隐空间中多个类别（裤子、鞋子、裙子）的决策边界交叉区域。在这个区域，微小的数值扰动就会导致生成器输出完全不同类别的图像，体现了特征的高度纠缠。

3.5 定量评估与数据分布可视化

为客观衡量模型的生成质量，并探究真实数据与伪造数据在深层特征上的分布差异，本实验计算了 FID 与 IS 两项定量指标，并利用 t-SNE 算法对高维特征进行了降维可视化对比。




图 3.7: 真实样本 (Real) 与生成样本 (Fake) 的 t-SNE 特征降维可视化对比

评估结果与分布特征分析

表 1: SimpleGAN 与 DCGAN 定量评估指标对比

模型	FID (↓)	IS (↑)
SimpleGAN	215.74	2.53 ± 0.06
DCGAN	31.73	4.08 ± 0.10

分析：FID 越低代表生成分布与真实分布越接近，IS 越高代表图像清晰度与多样性越好。DCGAN 的 FID 值实现了数量级式的下降，且 IS 得分大幅提升。这在客观数据上证明了卷积架构在提升生成逼真度与克服模式崩塌方面的巨大优势。

2. t-SNE 特征空间分布

- **分布割裂 (SimpleGAN)：**如图 3.7(a) 所示，真实样本（蓝点）与生成样本（橙点）在二维空间中形成了截然分离的两个聚簇，几乎没有交集。这表明 SimpleGAN 生成的流形完全偏离了真实数据分布，判别器可以轻易在特征空间画出决策边界。
- **分布融合 (DCGAN)：**如图 3.7(b) 所示，DCGAN 的生成样本与真实样本高度重合、均匀交杂。这直观且有力地证明了 DCGAN 成功捕获了 FashionMNIST 的部分真实数据流形。