



南開大學
Nankai University

密码与网络空间安全学院
深度学习及应用（高阶课）实验报告

注意力机制

姓名：陈培杰

学号：2312991

专业：信息安全

2026 年 5 月 11 日

目录

1 网络结构	1
2 关键代码	1
3 实验结果	2
3.1 训练结果与分析	2
3.2 测试集结果	3
3.3 自定义用例测试与定性分析	4
3.4 注意力机制可视化分析	5
4 加入注意力机制对模型及实验结果的综合影响	7
4.1 理论层面的突破：打破信息瓶颈与长程依赖建模	7
4.2 对实验结果的量化提升	7
4.3 对局部复杂语法的解析能力增强	7
4.4 存在的局限性	7

1 网络结构

老师提供的 RNNSeq2Seq 模型结构如下：

```
1 EncoderRNN(  
2     (embedding): Embedding(21328, 128)  
3     (gru): GRU(128, 128, batch_first=True)  
4     (dropout): Dropout(p=0.1, inplace=False)  
5 )  
6 DecoderRNN(  
7     (embedding): Embedding(13036, 128)  
8     (gru): GRU(128, 128, batch_first=True)  
9     (fc): Linear(in_features=128, out_features=13036, bias=True)  
10 )
```

这是一个基于 GRU 架构的标准 Seq2Seq 模型，其编码器将源输入映射为 128 维的词向量后，利用单层 GRU 提取序列特征并配合 Dropout 机制防止过拟合。它的解码器同样先进行 128 维的词嵌入并经过单层 GRU 处理，最后通过一个全连接层将输出维度映射回 13036，从而预测目标词汇。

2 关键代码

这里主要是有注意力机制的 Decoder 和 Encoder。老师给的代码也是没有 pad 和 mask 的，我添加了这部分，然后就可以用 DataLoader 来训练了。

这是 Encoder 的 forward 函数，添加了 pack_padded_sequence 函数和 pad_packed_sequence，来屏蔽对 PAD_token 进行计算隐藏向量。

```
1 def forward(self, x, lengths):  
2     embedded = self.dropout(self.embedding(x))
```

```

3 packed = rnn_utils.pack_padded_sequence(embedded, lengths, batch_first=True,
4     enforce_sorted=False)
5 packed_outputs, h_n = self.gru(packed)
6 outputs, _ = rnn_utils.pad_packed_sequence(packed_outputs, batch_first=True)
7 return outputs, h_n

```

这是 BahdanauAttention 类的 forward 函数，将 mask=0 的部分设置成 -1e9，经过 softmax 之后就是接近 0 的数，表示对于 PAD 位置计算出来的 hidden 选择屏蔽。这里计算注意力的时候，query 是 s_{t-1} ，表示 Decoder 解码完 t-1 步正在进行 t 步；keys 是 Encoder 输出出来的最后一层的 hidden

```

1 def forward(self, query, keys, mask=None):
2     scores = self.Va(torch.tanh(self.Wa(query) + self.Ua(keys)))
3     scores = scores.squeeze(-1)
4     if mask is not None:
5         scores = scores.masked_fill(mask == 0, -1e9)
6     weights = F.softmax(scores, dim=1)
7     weights_t = weights.unsqueeze(1)
8     context = torch.bmm(weights_t, keys)
9     return context, weights_t

```

mask 是在训练（或者测试的时候）构造的，例如下面的代码。x 的维度是 [batch_size, seq_len]，构造出来的 mask 也是相同的维度，所以 lengths 的维度是 [batch_size]

```

1 for x, y in train_loader:
2     x, y = x.to(device), y.to(device)
3     mask = (x != PAD_token)
4     lengths = mask.sum(dim=1).cpu()

```

3 实验结果

我把 eng-fra.txt 文件的内容按 9: 1 划分了训练集和测试集。

3.1 训练结果与分析




图 3.1: Base RNN 与 Attention RNN 在训练过程中的各项指标对比

如图3.1所示，本次实验在 30 个 Epoch 的训练周期内，分别对比了基础的 Seq2Seq 模型（Base RNN）与引入 Bahdanau 注意力机制的 Seq2Seq 模型（Attention RNN）的训练损失、验证集损失以及验证集 BLEU 分数。具体的数据特征与原理分析如下：

1. 损失函数收敛性分析

从前两张子图的损失曲线可以看出，两种模型在初期均表现出下降趋势，但 Attention RNN 的收敛速度与最终拟合效果均显著优于 Base RNN。

- **数据表现：**在第 30 个 Epoch 时，Attention RNN 的训练损失降至 0.6 左右，验证损失稳定在 1.4 左右；而 Base RNN 的训练损失仍在 0.9 附近，验证损失则停留在 1.8 左右的较高水平。
- **机制解析：**基础 RNN 结构在处理序列到序列任务时，由于所有源语言信息都被强制压缩成一个固定维度的上下文向量，极易导致长序列信息的丢失（信息瓶颈）以及反向传播时的梯度衰减。引入 Bahdanau Attention 后，解码器在每一步生成时都不再依赖单一的上下文向量，而是动态地对编码器的所有隐藏状态计算对齐分数，这使得梯度能够更直接地回传到相关的源词位置，极大加快了网络的收敛速度。

2. 翻译质量（BLEU Score）分析

验证集上的 BLEU 分数是衡量机器翻译质量的核心指标。从第三张子图可以直观地观察到，Attention 机制为模型带来了质的飞跃。

- **数据表现：**Attention RNN 的 BLEU 分数在训练早期就呈现出陡峭的上升曲线，并在后期稳定收敛至 46-48 左右的高分。相比之下，Base RNN 的 BLEU 分数上升较为平缓，存在明显的性能天花板，最终仅达到 33 左右。
- **机制解析：**这种显著的性能差距源于注意力机制赋予了模型“软对齐”的能力。与自注意力机制在计算序列内部相关性的逻辑类似，当前 Seq2Seq 架构中的 Bahdanau Attention 本质上是一种交叉注意力。它使得解码器在预测目标语言的下一个词时，能够根据当前的隐藏状态（Query）动态地“聚焦”于源语言句子中最相关的部分（Keys/Values），从而有效解决了长句翻译中的语义对齐问题，生成了更准确、更流畅的译文。

3.2 测试集结果

为了最终评估模型的泛化能力与实际翻译质量，我们将训练完成的两个模型在独立的测试集上进行了评测。具体的定量评估结果如表1所示。

表 1: 模型在测试集上的 BLEU 分数对比

Model	测试集 BLEU 分数
Base RNN	0.35
Attention RNN	0.50

测试集的最终数据进一步印证了注意力机制的有效性。Attention RNN 在未见过的数据上取得了 0.50 的 BLEU 分数，相较于 Base RNN 的 0.35 实现了显著的性能跃升。这表明，引入 Bahdanau Attention 后，模型不仅在训练集上拟合得更好，其泛化能力也得到了实质性的增强。

3.3 自定义用例测试与定性分析

为了进一步评估模型在面对非分布内（OOD）数据的泛化能力与实际翻译体感，本节采用了由大语言模型（Gemini 3.1 Pro）生成的 10 条包含不同场景和句法复杂度的法语句子作为自定义测试集进行推理。

1. 定量表现 (BLEU Score)

表 2: 10 条自定义用例的 BLEU 分数对比

模型 (Model)	自定义集 BLEU 分数
Base RNN	24.33
Attention RNN	24.66

如表2所示，在自定义测试集上，两者的 BLEU 得分差距缩小（分别为 24.33 和 24.66），整体表现非常接近且均低于标准测试集。这表明脱离特定训练语料的分布后，基础 Seq2Seq 架构（无论是否带有注意力机制）均会面临一定的泛化挑战。

2. 翻译实例对比

以下为 10 条测试句子的标准化输入（FR）与参考输出（EN），以及两个模型的实际预测结果：

表 3: 自定义测试集翻译实例对比

编号	输入 (FR) 与参考 (EN)	模型生成结果 (Base vs. Attention)
1	FR: <i>bonjour comment allez vous aujourd'hui ?</i> EN: <i>hello how are you today ?</i>	Base: who are you today ? Attn: hello how close you today ?
2	FR: <i>le chat noir dort sur le canape</i> EN: <i>the black cat is sleeping on the couch</i>	Base: the cat is sleeping on the black market Attn: the cat black is on the couch
3	FR: <i>ou est la gare la plus proche s'il vous plait ?</i> EN: <i>where is the nearest train station please ?</i>	Base: where s the nearest train station ? Attn: where s the closest train please ?
4	FR: <i>je ne comprends pas ce que vous dites</i> EN: <i>i do not understand what you are saying</i>	Base: i don t understand what you re saying Attn: i don t understand what you re saying
5	FR: <i>nous voyagerons en france l'annee prochaine</i> EN: <i>we will travel to france next year</i>	Base: we will go to france next year Attn: we considered him next year
6	FR: <i>elle a fini son travail avant de partir</i> EN: <i>she finished her work before leaving</i>	Base: she finished his work by time Attn: she finished her job before leaving leave
7	FR: <i>le livre que tu m'as prete est tres interessant</i> EN: <i>the book that you lent me is very interesting</i>	Base: the book i took that you is the book Attn: the book you lent me very interesting interesting
8	FR: <i>si j'avais su je serais venu plus tot</i> EN: <i>if i had known i would have come earlier</i>	Base: i knew i d be earlier back Attn: if i had known i d come on earlier
9	FR: <i>bien qu'il pleuve ils ont decide de faire une promenade</i> EN: <i>although it is raining they decided to take a walk</i>	Base: although it s raining are raining than a walk Attn: even though they will have decided to take a walk
10	FR: <i>l'algorithme que j'ai ecrit fonctionne parfaitement sur ces donnees</i> EN: <i>the algorithm i wrote works perfectly on this data</i>	Base: the time i wrote this book from your university Attn: what i wrote out of all the facts

3. 结果探讨与现象分析

通过对上述 10 个翻译实例的定性观察，我们可以发掘出模型在实际推理阶段的诸多细节特征：

- **高频短语的精确拟合：**对于 Sentence 4 这种高频且结构固定的日常用语，两个模型均毫无偏差地输出了极其准确的“i don t understand what you re saying”，说明两者对训练集中高频短语的记忆与重构能力都很强。
- **局部信息的有效捕获与幻觉：**观察 Sentence 2 可以发现，Base RNN 出现了严重的语义幻觉，将“沙发 (canape)”错误翻译成了“黑市 (black market)”；而 Attention RNN 准确捕捉并翻译出了“沙发 (couch)”。这再次证明 Attention 机制在对齐源序列局部关键信息时具有显著优势。
- **注意力机制的“重复生成”缺陷：**仔细观察 Attention RNN 在 Sentence 6 (leaving leave) 和 Sentence 7 (interesting interesting) 的输出，均出现了词语连续重复的现象。这是早期 Bahdanau Attention 的一个典型通病：由于缺乏覆盖率机制 (Coverage Penalty)，解码器在生成末期可能会将注意力权重重复分配给源句子的同一个词。
- **未登录词 (OOV) 与长程依赖的局限：**在 Sentence 10 中，面对包含生僻词汇 (algorithme) 的较长句子，两个模型均发生了完全的语义崩溃。Base RNN 强行输出了不相关的“book from your university”，Attention RNN 也仅翻译出零星字词。这暴露出基于受限词表的传统大语料训练 Seq2Seq 模型在面对 OOV 词汇时，极易退化为生成毫无意义的语料库高频词凑数。

3.4 注意力机制可视化分析

为了直观地探究 Attention RNN 在推理时是如何捕捉源语言与目标语言之间的对齐关系，我们提取了模型在生成自定义测试用例 4 (Sentence 4) 时的注意力权重矩阵，并将其可视化热力图。




图 3.2: Sentence 4 翻译过程中的注意力权重热力图 (je ne comprends pas ce que vous dites → i don t understand what you re saying)

如图3.2所示, 矩阵的 X 轴代表编码器端的法语输入 Token, Y 轴代表解码器端的英语输出 Token。颜色的明暗 (从深紫到亮黄) 表征了在生成当前英文单词时, 模型对各个法文单词分配的注意力权重 (Alignment Score) 大小。通过观察热力图, 我们可以得出以下关键结论:

1. 整体的单调对齐趋势 (Monotonic Alignment)

从左上到右下, 热力图呈现出一条明显的亮色对角线。这反映了法语和英语在基础语序上具有较高的一致性 (主谓宾结构)。例如, 输入端的 “je”、“vous”、“dites” 与输出端的 “i”、“you”、“saying” 呈现出极高权重的精准一对一映射。结束符 “EOS” 也完美对齐。

2. 复杂语法结构的软对齐 (Soft Alignment)

热力图最具学术价值的部分在于模型对法语否定句式 “ne ... pas” 的处理。在法语中, 否定词 “ne” 和 “pas” 通常包裹在动词 (comprends) 的两侧。

- 观察 Y 轴的 “don” 和 “t” 可以发现, 它们的注意力权重并没有集中在单一的 Token 上, 而是广泛且较均匀地分布在了 X 轴的 “ne”、“comprends” 和 “pas” 这三个 Token 所在的区域。
- 这清晰地展示了 Bahdanau Attention 的 “软对齐” 优势: 模型没有机械地逐字翻译, 而是通过注意力机制动态地汇聚了局部的上下文信息, 成功理解了法语这种非连续的否定语法组合, 并将其准确重构为英语的助动词否定形式。

3. 短语级别的多对多映射

在处理目标语言的“what”时，注意力机制将其权重主要分配给了源语言的“ce”和“que”两个 Token。这表明模型在训练过程中学习到了隐式的短语映射规则，能够将法语中的复合连接词块作为一个整体语义单元进行翻译。

4 加入注意力机制对模型及实验结果的综合影响

通过对基础 Seq2Seq 模型与 Attention RNN 模型的定量评测与定性可视化分析，本实验充分验证了注意力机制在自然语言处理任务中的核心价值。加入 Bahdanau 注意力机制 [1] 后，模型在内部机制和外在表现上均产生了显著的积极影响，具体总结如下：

4.1 理论层面的突破：打破信息瓶颈与长程依赖建模

在基础 Encoder-Decoder 架构中 [2]，RNN 或 LSTM 网络在处理序列数据时，长序列信息在隐状态随时间步传递的过程中不可避免地会发生梯度衰减与信息遗忘。编码器必须将整个源语言句子的所有语义压缩成一个固定长度的上下文向量，这成为了限制模型性能的“信息瓶颈”。

引入注意力机制后，模型从根本上改变了这一信息聚合方式。解码器在生成每个目标词汇时，不再依赖静态的上下文向量，而是动态地计算当前隐藏状态（Query）与编码器所有时间步隐藏状态（Keys/Values）之间的对齐分数。这种“软对齐”机制使得梯度能够跨越时间步直接反向传播至相关的源词位置，有效缓解了长程依赖问题。值得一提的是，Bahdanau 提出的这种动态交叉注意力理念，不仅解决了本实验中 RNN 的瓶颈，也为后续利用自注意力（Self-Attention）机制 [3] 进行全局依赖建模的先进架构奠定了核心理论基础。

4.2 对实验结果的量化提升

实验数据的对比直观地反映了理论突破带来的收益：

- **收敛速度与拟合优度：**Attention RNN 在训练初期的 Loss 下降更为陡峭，且最终的验证集 Loss（约 1.4）显著低于 Base RNN（约 1.8），证明模型能够更高效地从语料中捕获映射规律。
- **泛化能力与翻译指标：**在标准测试集上，Attention RNN 的 BLEU 分数从 Base RNN 的 0.35 大幅跃升至 0.50；在验证集上更是稳定在 46 以上。这表明模型不仅“背诵”了训练集，在面对未见数据时，其翻译质量和流畅度也得到了本质提升。

4.3 对局部复杂语法的解析能力增强

结合热力图的定性分析（如对法语否定句“ne ... pas”的处理），注意力机制赋予了模型处理非连续语法结构和多对多短语映射的能力。模型能够像人类译者一样，在翻译特定词汇时将“目光”聚焦于源句子中最相关的局部区域，从而大幅减少了基础 RNN 容易出现的语义偏移和幻觉现象。

4.4 存在的局限性

尽管提升显著，但实验也暴露出早期注意力机制的一些局限性。在自定义用例测试中，Attention RNN 出现了“leaving leave”和“interesting interesting”的重复生成现象。这是由于标准 Bahdanau Attention 缺乏对历史对齐信息的记忆（如 Coverage 机制），导致在解码末期注意力权重可能重复聚焦于同一源词。

参考文献

- [1] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. Neural machine translation by jointly learning to align and translate. *arXiv preprint arXiv:1409.0473*, 2014.
- [2] Ilya Sutskever, Oriol Vinyals, and Quoc V Le. Sequence to sequence learning with neural networks. In *Advances in neural information processing systems*, pages 3104–3112, 2014.
- [3] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in neural information processing systems*, pages 5998–6008, 2017.